

# REFERENCIAS ACADÉMICAS Y DOCUMENTOS RECOMENDADOS PARA EL CAPÍTULO 3

Estado del arte sobre predicción de riesgo crediticio,  
Machine Learning, MLOps, Business Intelligence y datamarts

**Tesis: Sistema Integrado de Inteligencia de Negocio para la Predicción de Crisis Crediticias  
mediante técnicas de Inteligencia Artificial e Inteligencia de Negocio**

Autor: Omar Antonio Vélez Bayas  
Tutor: Juan Pablo Astudillo León, Ph.D.  
Julio de 2026

*Documento de apoyo bibliográfico — Se excluyen publicaciones disponibles únicamente como preprints*

## 1. Propósito y alcance

**Objetivo.** Proporcionar una selección exhaustiva y organizada de artículos revisados por pares, documentos técnicos y fuentes regulatorias que pueden fortalecer el Capítulo 3 de la tesis. La lista prioriza publicaciones definitivas de revistas y congresos y excluye trabajos disponibles únicamente como preprints en arXiv, SSRN u otros repositorios.

**Cobertura temática.** La búsqueda cubre revisiones de credit scoring, comparación entre modelos basados en árboles y redes neuronales, predicción multi-periodo, desbalance, interpretabilidad, MLOps, Business Intelligence, datamarts, sistemas de apoyo a decisiones y contexto cooperativo ecuatoriano.

*Nota: en los artículos de publicación anticipada se ha considerado la versión de registro o la versión publicada por la revista. La normativa de la SEPS debe citarse mediante la resolución exacta aplicable al segmento y periodo de estudio.*

## 2. Diagnóstico del Capítulo 3 actual

- El capítulo se presenta como una revisión sistemática, pero no documenta completamente bases de datos, cadenas de búsqueda, criterios de inclusión y exclusión, eliminación de duplicados, conteos ni diagrama de selección.
- La síntesis actual es principalmente narrativa y requiere una comparación transversal por dataset, modelo, horizonte, métricas, interpretabilidad, MLOps, BI y limitaciones.
- Varias referencias actuales son preprints; deben sustituirse por las versiones definitivas publicadas o por trabajos revisados por pares equivalentes.
- La brecha multi-horizonte necesita apoyo específico de literatura sobre predicción multi-periodo, supervivencia y riesgos competitivos.
- La integración MLOps–datamart–dashboard debe discutirse desde el valor de negocio, la gobernanza y la preparación para producción, no únicamente desde las herramientas empleadas.

## 3. Estructura recomendada para el Capítulo 3

**3.1 Metodología de búsqueda bibliográfica.** Bases consultadas, fecha de búsqueda, cadenas, criterios de inclusión/exclusión, duplicados, proceso de cribado y número final de estudios.

**3.2 Revisiones y benchmarks de credit scoring.** Síntesis de revisiones sistemáticas y benchmarks amplios; identificación de tendencias, datasets y prácticas de evaluación.

**3.3 Modelos basados en árboles, boosting y enfoques híbridos.** LightGBM, XGBoost, Random Forest, árboles interpretables y combinaciones con redes neuronales.

**3.4 Redes neuronales y modelos temporales.** MLP, CNN y condiciones en las que las secuencias temporales aportan información útil.

**3.5 Predicción multi-periodo y multi-horizonte.** Modelos multiperiodo, supervivencia, competing risks y degradación del rendimiento según el horizonte.

**3.6 Desbalance, interpretabilidad y riesgo de modelo.** Métricas, costes de falsos negativos, calibración, SHAP, auditabilidad, explicabilidad y gobernanza.

**3.7 MLOps y operacionalización.** Ciclo de vida, CI/CD/CT, versionado, pruebas, monitoreo, drift, aprobación y reentrenamiento.

**3.8 Business Intelligence, datamarts y apoyo a decisiones.** Integración de predicciones, datos históricos y dashboards; adopción, uso y valor para decisiones.

**3.9 Riesgo crediticio en cooperativas ecuatorianas.** Literatura local, regulación del SFPS y particularidades de las cooperativas.

**3.10 Síntesis crítica y brecha de investigación.** Tabla comparativa y formulación prudente de la brecha que la tesis aborda.

## 4. Selección prioritaria para una bibliografía central

Para evitar un capítulo excesivamente extenso, se recomienda trabajar con un núcleo de 28 fuentes y utilizar las demás como respaldo complementario.

| N.º | Fuente                                                                                                      | Función principal                                                                                                                                                                     | Sección sugerida                                                    |
|-----|-------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------|
| 1   | Ayari, H., Guetari, R. y Kraiem, N. (2026). Machine learning powered financial credit scoring: a...         | Revisión sistemática reciente de 63 estudios sobre métodos de aprendizaje automático para credit scoring. Resume modelos, métricas, desbalance, interpretabilidad, dimensionalidad... | 3.2 Revisiones y benchmarks de credit scoring                       |
| 2   | Montevecchi et al. (2024). Advancing credit risk modelling with Machine Learning: A comprehensive review... | Permite presentar el proceso completo de modelado de riesgo crediticio: preparación, selección de variables, optimización, evaluación, interpretabilidad y despliegue.                | 3.2 Revisiones y benchmarks de credit scoring                       |
| 3   | Shi, S., Tse, R., Luo, W. et al. (2022). Machine learning-driven credit risk: a systemic review             | Revisa 76 trabajos y propone una taxonomía de métodos estadísticos, Machine Learning y Deep Learning; discute desbalance, transparencia e inconsistencia de datasets.                 | 3.2 Revisiones y benchmarks de credit scoring                       |
| 4   | Markov, A., Seleznyova, Z. y Lapshin, V. (2022). Credit scoring methods: Latest trends and points to...     | Sintetiza tendencias y buenas prácticas de credit scoring entre 2016 y 2021 y muestra que no existe un algoritmo universalmente superior.                                             | 3.2 Revisiones y benchmarks de credit scoring                       |
| 5   | Dastile, X., Celik, T. y Potsane, M. (2020). Statistical and machine learning models in credit scoring:...  | Referencia fundamental para comparar modelos estadísticos, árboles, ensembles y redes neuronales, incluyendo retos de desbalance e interpretabilidad.                                 | 3.2 Revisiones y benchmarks de credit scoring                       |
| 7   | Lessmann, S., Baesens, B., Seow, H.-V. y Thomas, L. C. (2015). Benchmarking state-of-the-art...             | Benchmark clásico de 41 clasificadores sobre ocho datasets. Sustenta la necesidad de comparar modelos con protocolos homogéneos y varias métricas.                                    | 3.2 Revisiones y benchmarks de credit scoring                       |
| 10  | Gunnarsson, B. R., vanden Broucke, S., Baesens, B., Óskarsdóttir, M. y Lemahieu, W. (2021). Deep...         | Trabajo central para la hipótesis: compara MLP, deep belief network, métodos convencionales y ensembles en varios datasets, usando pruebas estadísticas.                              | 3.3 Árboles, boosting y redes neuronales                            |
| 11  | Kvamme, H., Sellereite, N., Aas, K. y Sjursen, S. (2018). Predicting mortgage default using...              | Ejemplo directo del uso de CNN sobre series temporales ricas de saldos y transacciones. Permite contrastar dichas secuencias con las ventanas mensuales cortas de la tesis.           | 3.4 Redes neuronales y modelos temporales                           |
| 13  | Ampountolas, A., Nde, T., Date, P. y Constantinescu, C. (2021). A Machine Learning Approach for...          | Muy pertinente por su aplicación a microcrédito y por comparar varias familias de modelos en un contexto cercano a inclusión financiera.                                              | 3.3 Árboles, boosting y redes neuronales / 3.9 Contexto cooperativo |
| 14  | Aniceto, M. C., Barboza, F. y Kimura, H. (2020). Machine learning predictivity applied to consumer...       | Compara regresión logística, SVM, árboles, bagging, AdaBoost y Random Forest en una cartera de una economía emergente.                                                                | 3.3 Árboles, boosting y redes neuronales                            |
| 16  | Vieira, J. R. de C., Barboza, F., Sobreiro, V. A. y Kimura, H. (2019). Machine learning models for...       | Estudia predicción de incumplimiento en familias de bajos ingresos y muestra el valor de bagging, boosting y Random Forest.                                                           | 3.3 Modelos y 3.9 Contexto social                                   |
| 20  | Duffie, D., Saita, L. y Wang, K. (2007). Multi-period corporate default prediction with stochastic...       | Referencia seminal para predicción de incumplimiento en múltiples periodos con covariables variables en el tiempo.                                                                    | 3.5 Predicción multi-periodo y multi-                               |

| N.º | Fuente                                                                                                      | Función principal                                                                                                                          | Sección sugerida                                     |
|-----|-------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------|
|     |                                                                                                             |                                                                                                                                            | horizonte                                            |
| 21  | Duan, J.-C., Sun, J. y Wang, T. (2012). Multiperiod corporate default prediction—A forward intensity...     | Fundamenta probabilidades de incumplimiento en distintos horizontes mediante una formulación de intensidad futura.                         | 3.5 Predicción multi-periodo y multi-horizonte       |
| 22  | Orth, W. (2013). Multi-period credit default prediction with time-varying covariates                        | Conecta directamente la predicción multi-periodo con covariables que cambian a través del tiempo.                                          | 3.5 Predicción multi-periodo y multi-horizonte       |
| 23  | Blumenstock, G., Lessmann, S. y Seow, H.-V. (2022). Deep learning for survival and competing risk...        | Muestra una formulación alternativa basada en tiempo hasta el incumplimiento y riesgos competitivos, pertinente para horizontes múltiples. | 3.5 Predicción multi-periodo y multi-horizonte       |
| 24  | Bai, C., Zheng, J. y Shen, Y. (2022). Gradient boosting survival tree with applications in credit scoring   | Vincula gradient boosting con análisis de supervivencia y riesgo temporal.                                                                 | 3.5 Predicción multi-periodo y multi-horizonte       |
| 26  | Bussmann, N., Giudici, P., Marinelli, D. y Papenbrock, J. (2021). Explainable Machine Learning in Credit... | Referencia central para XAI basada en valores de Shapley y relaciones entre variables en gestión del riesgo crediticio.                    | 3.6 Desbalance, interpretabilidad y riesgo de modelo |
| 27  | Chen, C., Calabrese, R. y Martin-Barragan, B. (2024). Interpretable machine learning for imbalanced...      | Combina dos problemas centrales de la tesis: desbalance e interpretabilidad; discute estabilidad de explicaciones en datos desbalanceados. | 3.6 Desbalance, interpretabilidad y riesgo de modelo |
| 30  | Bücker, M., Szepannek, G., Gosiewska, A. y Biecek, P. (2022). Transparency, auditability, and...            | Diferencia transparencia, auditabilidad y explicabilidad en modelos crediticios institucionales.                                           | 3.6 Desbalance, interpretabilidad y riesgo de modelo |
| 31  | Testi, M., Ballabio, M., Frontoni, E., Iannello, G., Moccia, S., Soda, P. y Vessio, G. (2022). MLOps: A...  | Taxonomía y metodología completa para MLOps: problema, datos, entrenamiento, CI/CD/CT, monitoreo, explicabilidad y sostenibilidad.         | 3.7 MLOps y operacionalización                       |
| 32  | Kreuzberger, D., Kühl, N. y Hirschl, S. (2023). Machine Learning Operations (MLOps): Overview,...           | Definición formal de MLOps, roles, componentes, arquitectura y flujos; reemplaza directamente versiones de arXiv.                          | 3.7 MLOps y operacionalización                       |
| 35  | March, S. T. y Hevner, A. R. (2007). Integrated decision support systems: A data warehousing perspective    | Conecta data warehousing, integración de información analítica y apoyo a decisiones.                                                       | 3.8 BI, datamarts y apoyo a decisiones               |
| 36  | Trieu, V.-H. (2017). Getting value from Business Intelligence systems: A review and research agenda         | Sustenta que la mera implementación de dashboards no demuestra valor; se requieren uso, integración y efectos sobre decisiones.            | 3.8 BI, datamarts y apoyo a decisiones               |
| 39  | Luque González, A. y Peñaherrera Melo, J. (2021). Cooperativas de ahorro y crédito en Ecuador: el...        | Contexto institucional, social y organizacional de cooperativas de ahorro y crédito ecuatorianas.                                          | 3.9 Riesgo crediticio en cooperativas ecuatorianas   |
| 44  | Page, M. J. et al. (2021). The PRISMA 2020 statement: an updated guideline for reporting systematic...      | Guía obligatoria si el capítulo mantiene la denominación “revisión sistemática”; exige proceso transparente y reproducible.                | 3.1 Metodología de búsqueda bibliográfica            |
| 45  | National Institute of Standards and Technology (2023). National Institute of Standards and Technology...    | Fundamenta gobernanza, confiabilidad, documentación, monitoreo y gestión de riesgos de sistemas de IA.                                     | 3.6 Riesgo de modelo / 3.7 MLOps                     |

| N.º | Fuente                                                                                                      | Función principal                                                                                              | Sección sugerida                         |
|-----|-------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------|------------------------------------------|
| 46  | European Banking Authority (2023). European Banking Authority (2023). Follow-up Report on the Use of...     | Marco de referencia sobre validación, interpretabilidad, gobernanza y uso prudente de ML en riesgo crediticio. | 3.6 Riesgo de modelo /<br>3.7 Gobernanza |
| 47  | Basel Committee on Banking Supervision (2013). Basel Committee on Banking Supervision (2013). Principles... | Principios sobre integridad, trazabilidad, completitud, oportunidad y calidad de datos y reportes de riesgo.   | 3.8 BI, datamart y gobierno de datos     |

## 5. Catálogo exhaustivo de publicaciones y documentos

### 5.1 Revisiones y estudios de referencia

#### 1. Ayari, H., Guetari, R. y Kraïem, N. (2026). “Machine learning powered financial credit scoring: a systematic literature review”. *Artificial Intelligence Review*, 59, art. 13.

**Utilidad para la tesis:** Revisión sistemática reciente de 63 estudios sobre métodos de aprendizaje automático para credit scoring. Resume modelos, métricas, desbalance, interpretabilidad, dimensionalidad y dificultades de adopción.

**Ubicación recomendada:** 3.2 Revisiones y benchmarks de credit scoring | **Prioridad:** **Esencial**

**Enlace:** [10.1007/s10462-025-11416-2](https://doi.org/10.1007/s10462-025-11416-2)

#### 2. Montevechi et al. (2024). “Advancing credit risk modelling with Machine Learning: A comprehensive review of the state-of-the-art”. *Engineering Applications of Artificial Intelligence*, 137, 109082.

**Utilidad para la tesis:** Permite presentar el proceso completo de modelado de riesgo crediticio: preparación, selección de variables, optimización, evaluación, interpretabilidad y despliegue.

**Ubicación recomendada:** 3.2 Revisiones y benchmarks de credit scoring | **Prioridad:** **Esencial**

**Enlace:** [10.1016/j.engappai.2024.109082](https://doi.org/10.1016/j.engappai.2024.109082)

#### 3. Shi, S., Tse, R., Luo, W. et al. (2022). “Machine learning-driven credit risk: a systemic review”. *Neural Computing and Applications*, 34, 14327–14339.

**Utilidad para la tesis:** Revisa 76 trabajos y propone una taxonomía de métodos estadísticos, Machine Learning y Deep Learning; discute desbalance, transparencia e inconsistencia de datasets.

**Ubicación recomendada:** 3.2 Revisiones y benchmarks de credit scoring | **Prioridad:** **Esencial**

**Enlace:** [10.1007/s00521-022-07472-2](https://doi.org/10.1007/s00521-022-07472-2)

#### 4. Markov, A., Seleznyova, Z. y Lapshin, V. (2022). “Credit scoring methods: Latest trends and points to consider”. *The Journal of Finance and Data Science*, 8, 180–201.

**Utilidad para la tesis:** Sintetiza tendencias y buenas prácticas de credit scoring entre 2016 y 2021 y muestra que no existe un algoritmo universalmente superior.

**Ubicación recomendada:** 3.2 Revisiones y benchmarks de credit scoring | **Prioridad:** **Esencial**

**Enlace:** [10.1016/j.jfds.2022.07.002](https://doi.org/10.1016/j.jfds.2022.07.002)

#### 5. Dastile, X., Celik, T. y Potsane, M. (2020). “Statistical and machine learning models in credit scoring: A systematic literature survey”. *Applied Soft Computing*, 91, 106263.

**Utilidad para la tesis:** Referencia fundamental para comparar modelos estadísticos, árboles, ensembles y redes neuronales, incluyendo retos de desbalance e interpretabilidad.

**Ubicación recomendada:** 3.2 Revisiones y benchmarks de credit scoring | **Prioridad:** **Esencial**

**Enlace:** [10.1016/j.asoc.2020.106263](https://doi.org/10.1016/j.asoc.2020.106263)

6. Bhatore, S., Mohan, L. y Reddy, Y. R. (2020). “Machine learning techniques for credit risk evaluation: a systematic literature review”. *Journal of Banking and Financial Technology*, 4, 111–138.

**Utilidad para la tesis:** Útil para clasificar algoritmos, datasets y métricas empleadas en evaluación del riesgo crediticio.

**Ubicación recomendada:** 3.2 Revisiones y benchmarks de credit scoring | **Prioridad:** Alta

**Enlace:** [10.1007/s42786-020-00020-3](https://doi.org/10.1007/s42786-020-00020-3)

7. Lessmann, S., Baesens, B., Seow, H.-V. y Thomas, L. C. (2015). “Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research”. *European Journal of Operational Research*, 247(1), 124–136.

**Utilidad para la tesis:** Benchmark clásico de 41 clasificadores sobre ocho datasets. Sustenta la necesidad de comparar modelos con protocolos homogéneos y varias métricas.

**Ubicación recomendada:** 3.2 Revisiones y benchmarks de credit scoring | **Prioridad:** Esencial

**Enlace:** [10.1016/j.ejor.2015.05.030](https://doi.org/10.1016/j.ejor.2015.05.030)

8. Moscato, V., Picariello, A. y Sperlì, G. (2021). “A benchmark of machine learning approaches for credit score prediction”. *Expert Systems with Applications*, 165, 113986.

**Utilidad para la tesis:** Apoya la discusión sobre comparaciones reproducibles y selección de algoritmos bajo condiciones experimentales equivalentes.

**Ubicación recomendada:** 3.2 Revisiones y benchmarks de credit scoring | **Prioridad:** Alta

**Enlace:** [10.1016/j.eswa.2020.113986](https://doi.org/10.1016/j.eswa.2020.113986)

9. Khoozani, Z. S., Seera, M. y Lim, C. P. (2026). “Towards transparent financial AI: a systematic review of graph learning and explainable methods for credit risk and fraud detection”. *Artificial Intelligence Review*.

**Utilidad para la tesis:** Revisión muy reciente sobre XAI, grafos, drift, gobernanza y sistemas financieros orientados al despliegue. Es versión publicada anticipadamente por la revista, no preprint.

**Ubicación recomendada:** 3.6 Desbalance, interpretabilidad y riesgo de modelo | **Prioridad:** Alta

**Enlace:** [10.1007/s10462-026-11645-z](https://doi.org/10.1007/s10462-026-11645-z)

## 5.2 Comparación entre árboles, boosting y redes neuronales

10. Gunnarsson, B. R., vanden Broucke, S., Baesens, B., Óskarsdóttir, M. y Lemahieu, W. (2021). “Deep learning for credit scoring: Do or don’t?”. *European Journal of Operational Research*, 295(1), 292–305.

**Utilidad para la tesis:** Trabajo central para la hipótesis: compara MLP, deep belief network, métodos convencionales y ensembles en varios datasets, usando pruebas estadísticas.

**Ubicación recomendada:** 3.3 Árboles, boosting y redes neuronales | **Prioridad:** Esencial

**Enlace:** [10.1016/j.ejor.2021.03.006](https://doi.org/10.1016/j.ejor.2021.03.006)

11. Kvamme, H., Sellereite, N., Aas, K. y Sjursen, S. (2018). “Predicting mortgage default using convolutional neural networks”. *Expert Systems with Applications*, 102, 207–217.

**Utilidad para la tesis:** Ejemplo directo del uso de CNN sobre series temporales ricas de saldos y transacciones. Permite contrastar dichas secuencias con las ventanas mensuales cortas de la tesis.

**Ubicación recomendada:** 3.4 Redes neuronales y modelos temporales | **Prioridad:** Esencial

**Enlace:** [10.1016/j.eswa.2018.02.029](https://doi.org/10.1016/j.eswa.2018.02.029)

12. Dumitrescu, E., Hué, S., Hurlin, C. y Tokpavi, S. (2022). “Machine learning for credit scoring: Improving logistic regression with non-linear decision-tree effects”. *European Journal of Operational Research*, 297(3), 1178–1192.

**Utilidad para la tesis:** Presenta un enfoque híbrido e interpretable que combina reglas de árboles con regresión logística penalizada.

**Ubicación recomendada:** 3.3 Árboles, boosting y redes neuronales | **Prioridad:** **Alta**

**Enlace:** [10.1016/j.ejor.2021.06.053](https://doi.org/10.1016/j.ejor.2021.06.053)

**13. Ampountolas, A., Nde, T., Date, P. y Constantinescu, C. (2021). “A Machine Learning Approach for Micro-Credit Scoring”. *Risks*, 9(3), 50.**

**Utilidad para la tesis:** Muy pertinente por su aplicación a microcrédito y por comparar varias familias de modelos en un contexto cercano a inclusión financiera.

**Ubicación recomendada:** 3.3 Árboles, boosting y redes neuronales / 3.9 Contexto cooperativo | **Prioridad:** **Esencial**

**Enlace:** [10.3390/risks9030050](https://doi.org/10.3390/risks9030050)

**14. Aniceto, M. C., Barboza, F. y Kimura, H. (2020). “Machine learning predictivity applied to consumer creditworthiness”. *Future Business Journal*, 6, art. 37.**

**Utilidad para la tesis:** Compara regresión logística, SVM, árboles, bagging, AdaBoost y Random Forest en una cartera de una economía emergente.

**Ubicación recomendada:** 3.3 Árboles, boosting y redes neuronales | **Prioridad:** **Esencial**

**Enlace:** [10.1186/s43093-020-00041-w](https://doi.org/10.1186/s43093-020-00041-w)

**15. Djeundje et al. (2021). “Enhancing credit scoring with alternative data”. *Expert Systems with Applications*, 163, 113766.**

**Utilidad para la tesis:** Aporta evidencia sobre datos alternativos, prestatarios con historiales limitados e inclusión financiera.

**Ubicación recomendada:** 3.3 Modelos y fuentes de datos para credit scoring | **Prioridad:** **Alta**

**Enlace:** [10.1016/j.eswa.2020.113766](https://doi.org/10.1016/j.eswa.2020.113766)

**16. Vieira, J. R. de C., Barboza, F., Sobreiro, V. A. y Kimura, H. (2019). “Machine learning models for credit analysis improvements: Predicting low-income families’ default”. *Applied Soft Computing*, 83, 105640.**

**Utilidad para la tesis:** Estudia predicción de incumplimiento en familias de bajos ingresos y muestra el valor de bagging, boosting y Random Forest.

**Ubicación recomendada:** 3.3 Modelos y 3.9 Contexto social | **Prioridad:** **Esencial**

**Enlace:** [10.1016/j.asoc.2019.105640](https://doi.org/10.1016/j.asoc.2019.105640)

**17. Zhu, Q., Ding, W., Xiang, M., Hu, M. y Zhang, N. (2023). “Loan Default Prediction Based on Convolutional Neural Network and LightGBM”. *International Journal of Data Warehousing and Mining*, 19(1), 1–16.**

**Utilidad para la tesis:** Ejemplo de arquitectura híbrida CNN–LightGBM; evita presentar ambos enfoques como familias necesariamente excluyentes.

**Ubicación recomendada:** 3.3 Árboles, boosting y redes neuronales | **Prioridad:** **Alta**

**Enlace:** [10.4018/IJDWM.315823](https://doi.org/10.4018/IJDWM.315823)

**18. “A Hybrid XGBoost–MLP Model for Credit Risk Assessment on Digital Supply Chain Finance” (2022). *Forecasting*, 4(1), 184–207.**

**Utilidad para la tesis:** Ejemplo de combinación entre boosting y redes neuronales para evaluación de riesgo.

**Ubicación recomendada:** 3.3 Árboles, boosting y redes neuronales | **Prioridad:** **Media**

**Enlace:** [10.3390/forecast4010011](https://doi.org/10.3390/forecast4010011)

**19. Tu, H. y Wu, Q. (2025). “Inherently interpretable machine learning for credit scoring: Optimal classification tree with hyperplane splits”. *European Journal of Operational Research*, 322(2), 647–664.**

**Utilidad para la tesis:** Alternativa interpretable que permite discutir transparencia sin depender solo de explicaciones post hoc.

**Ubicación recomendada:** 3.6 Interpretabilidad y riesgo de modelo | **Prioridad:** **Alta**

Enlace: [10.1016/j.ejor.2024.10.046](https://doi.org/10.1016/j.ejor.2024.10.046)

## 5.3 Predicción temporal, multi-periodo y multi-horizonte

20. Duffie, D., Saita, L. y Wang, K. (2007). “Multi-period corporate default prediction with stochastic covariates”. *Journal of Financial Economics*, 83(3), 635–665.

**Utilidad para la tesis:** Referencia seminal para predicción de incumplimiento en múltiples periodos con covariables variables en el tiempo.

**Ubicación recomendada:** 3.5 Predicción multi-periodo y multi-horizonte | **Prioridad:** **Esencial**

Enlace: [10.1016/j.jfineco.2005.10.011](https://doi.org/10.1016/j.jfineco.2005.10.011)

21. Duan, J.-C., Sun, J. y Wang, T. (2012). “Multiperiod corporate default prediction—A forward intensity approach”. *Journal of Econometrics*, 170(1), 191–209.

**Utilidad para la tesis:** Fundamenta probabilidades de incumplimiento en distintos horizontes mediante una formulación de intensidad futura.

**Ubicación recomendada:** 3.5 Predicción multi-periodo y multi-horizonte | **Prioridad:** **Esencial**

Enlace: [10.1016/j.jeconom.2012.05.002](https://doi.org/10.1016/j.jeconom.2012.05.002)

22. Orth, W. (2013). “Multi-period credit default prediction with time-varying covariates”. *Journal of Empirical Finance*, 21, 214–222.

**Utilidad para la tesis:** Conecta directamente la predicción multi-periodo con covariables que cambian a través del tiempo.

**Ubicación recomendada:** 3.5 Predicción multi-periodo y multi-horizonte | **Prioridad:** **Esencial**

Enlace: [10.1016/j.jempfin.2013.01.006](https://doi.org/10.1016/j.jempfin.2013.01.006)

23. Blumenstock, G., Lessmann, S. y Seow, H.-V. (2022). “Deep learning for survival and competing risk modelling”. *Journal of the Operational Research Society*, 73(1), 26–38.

**Utilidad para la tesis:** Muestra una formulación alternativa basada en tiempo hasta el incumplimiento y riesgos competitivos, pertinente para horizontes múltiples.

**Ubicación recomendada:** 3.5 Predicción multi-periodo y multi-horizonte | **Prioridad:** **Esencial**

Enlace: [10.1080/01605682.2020.1838960](https://doi.org/10.1080/01605682.2020.1838960)

24. Bai, C., Zheng, J. y Shen, Y. (2022). “Gradient boosting survival tree with applications in credit scoring”. *Journal of the Operational Research Society*, 73(1), 39–55.

**Utilidad para la tesis:** Vincula gradient boosting con análisis de supervivencia y riesgo temporal.

**Ubicación recomendada:** 3.5 Predicción multi-periodo y multi-horizonte | **Prioridad:** **Esencial**

Enlace: [10.1080/01605682.2021.1919035](https://doi.org/10.1080/01605682.2021.1919035)

25. Zhou, J., Wang, C., Ren, F. y Chen, G. (2021). “Inferring multi-stage risk for online consumer credit services: An integrated scheme using data augmentation and model enhancement”. *Decision Support Systems*, 149, 113611.

**Utilidad para la tesis:** Integra clasificación ordinal, ensemble, SHAP y análisis de bienestar para representar etapas del riesgo.

**Ubicación recomendada:** 3.5 Predicción multi-etapa y 3.8 Apoyo a decisiones | **Prioridad:** **Alta**

Enlace: [10.1016/j.dss.2021.113611](https://doi.org/10.1016/j.dss.2021.113611)



## 5.4 Desbalance, interpretabilidad y toma de decisiones

**26. Bussmann, N., Giudici, P., Marinelli, D. y Papenbrock, J. (2021). “Explainable Machine Learning in Credit Risk Management”. *Computational Economics*, 57, 203–216.**

**Utilidad para la tesis:** Referencia central para XAI basada en valores de Shapley y relaciones entre variables en gestión del riesgo crediticio.

**Ubicación recomendada:** 3.6 Desbalance, interpretabilidad y riesgo de modelo | **Prioridad: Esencial**

**Enlace:** [10.1007/s10614-020-10042-0](https://doi.org/10.1007/s10614-020-10042-0)

**27. Chen, C., Calabrese, R. y Martin-Barragan, B. (2024). “Interpretable machine learning for imbalanced credit scoring datasets”. *European Journal of Operational Research*, 312(1), 357–372.**

**Utilidad para la tesis:** Combina dos problemas centrales de la tesis: desbalance e interpretabilidad; discute estabilidad de explicaciones en datos desbalanceados.

**Ubicación recomendada:** 3.6 Desbalance, interpretabilidad y riesgo de modelo | **Prioridad: Esencial**

**Enlace:** [10.1016/j.ejor.2023.06.036](https://doi.org/10.1016/j.ejor.2023.06.036)

**28. Chen et al. (2022). “A holistic approach to interpretability in financial lending: Models, visualizations, and summary-explanations”. *Decision Support Systems*, 152, 113647.**

**Utilidad para la tesis:** Conecta modelos, visualización y apoyo a decisiones, alineándose con la integración de predicciones y dashboards.

**Ubicación recomendada:** 3.6 Interpretabilidad / 3.8 BI y apoyo a decisiones | **Prioridad: Alta**

**Enlace:** [10.1016/j.dss.2021.113647](https://doi.org/10.1016/j.dss.2021.113647)

**29. Dastile, X. y Celik, T. (2021). “Making deep learning-based predictions for credit scoring explainable”. *IEEE Access*, 9, 50426–50440.**

**Utilidad para la tesis:** Complementa la discusión de redes neuronales con mecanismos para explicar sus predicciones.

**Ubicación recomendada:** 3.6 Desbalance, interpretabilidad y riesgo de modelo | **Prioridad: Alta**

**Enlace:** [10.1109/ACCESS.2021.3068854](https://doi.org/10.1109/ACCESS.2021.3068854)

**30. Bücker, M., Szepannek, G., Gosiewska, A. y Biecek, P. (2022). “Transparency, auditability, and explainability of machine learning models in credit scoring”. *Journal of the Operational Research Society*, 73(1), 70–90.**

**Utilidad para la tesis:** Diferencia transparencia, auditabilidad y explicabilidad en modelos crediticios institucionales.

**Ubicación recomendada:** 3.6 Desbalance, interpretabilidad y riesgo de modelo | **Prioridad: Esencial**

**Enlace:** [10.1080/01605682.2021.1922098](https://doi.org/10.1080/01605682.2021.1922098)

## 5.5 MLOps y sistemas de Machine Learning en producción

**31. Testi, M., Ballabio, M., Frontoni, E., Iannello, G., Moccia, S., Soda, P. y Vessio, G. (2022). “MLOps: A Taxonomy and a Methodology”. *IEEE Access*, 10, 63606–63618.**

**Utilidad para la tesis:** Taxonomía y metodología completa para MLOps: problema, datos, entrenamiento, CI/CD/CT, monitoreo, explicabilidad y sostenibilidad.

**Ubicación recomendada:** 3.7 MLOps y operacionalización | **Prioridad: Esencial**

**Enlace:** [10.1109/ACCESS.2022.3181730](https://doi.org/10.1109/ACCESS.2022.3181730)

- 32. Kreuzberger, D., Kühl, N. y Hirschl, S. (2023). “Machine Learning Operations (MLOps): Overview, Definition, and Architecture”. IEEE Access, 11, 31866–31879.**

**Utilidad para la tesis:** Definición formal de MLOps, roles, componentes, arquitectura y flujos; reemplaza directamente versiones de arXiv.

**Ubicación recomendada:** 3.7 MLOps y operacionalización | **Prioridad:** **Esencial**

**Enlace:** [10.1109/ACCESS.2023.3262138](https://doi.org/10.1109/ACCESS.2023.3262138)

- 33. Sculley, D. et al. (2015). “Hidden Technical Debt in Machine Learning Systems”. Advances in Neural Information Processing Systems, 28.**

**Utilidad para la tesis:** Explica dependencias de datos, retroalimentación, configuración y deuda técnica en sistemas reales de ML.

**Ubicación recomendada:** 3.7 MLOps y operacionalización | **Prioridad:** **Alta**

**Enlace:** [Página oficial de NeurIPS](https://arxiv.org/abs/1509.04812)

- 34. Breck, E., Cai, S., Nielsen, E., Salib, M. y Sculley, D. (2017). “The ML Test Score: A Rubric for ML Production Readiness and Technical Debt Reduction”. IEEE International Conference on Big Data, 1123–1132.**

**Utilidad para la tesis:** Rúbrica de pruebas y monitoreo para evaluar preparación de sistemas ML para producción.

**Ubicación recomendada:** 3.7 MLOps y operacionalización | **Prioridad:** **Alta**

**Enlace:** [10.1109/BigData.2017.8258038](https://doi.org/10.1109/BigData.2017.8258038)

## 5.6 Business Intelligence, datamarts y apoyo a decisiones

- 35. March, S. T. y Hevner, A. R. (2007). “Integrated decision support systems: A data warehousing perspective”. Decision Support Systems, 43(3), 1031–1043.**

**Utilidad para la tesis:** Conecta data warehousing, integración de información analítica y apoyo a decisiones.

**Ubicación recomendada:** 3.8 BI, datamarts y apoyo a decisiones | **Prioridad:** **Esencial**

**Enlace:** [10.1016/j.dss.2005.05.029](https://doi.org/10.1016/j.dss.2005.05.029)

- 36. Trieu, V.-H. (2017). “Getting value from Business Intelligence systems: A review and research agenda”. Decision Support Systems, 93, 111–124.**

**Utilidad para la tesis:** Sustenta que la mera implementación de dashboards no demuestra valor; se requieren uso, integración y efectos sobre decisiones.

**Ubicación recomendada:** 3.8 BI, datamarts y apoyo a decisiones | **Prioridad:** **Esencial**

**Enlace:** [10.1016/j.dss.2016.09.019](https://doi.org/10.1016/j.dss.2016.09.019)

- 37. Phillips-Wren, G., Daly, M. y Burstein, F. (2021). “Reconciling business intelligence, analytics and decision support systems: More data, deeper insight”. Decision Support Systems, 146, 113560.**

**Utilidad para la tesis:** Articula BI, analítica y sistemas de apoyo a decisiones; fundamenta la arquitectura integrada propuesta.

**Ubicación recomendada:** 3.8 BI, datamarts y apoyo a decisiones | **Prioridad:** **Alta**

**Enlace:** [10.1016/j.dss.2021.113560](https://doi.org/10.1016/j.dss.2021.113560)

- 38. Ain, N. U., Vaia, G., DeLone, W. H. y Waheed, M. (2019). “Two decades of research on business intelligence system adoption, utilization and success – A systematic literature review”. Decision Support Systems, 125, 113113.**

**Utilidad para la tesis:** Revisa adopción, utilización y éxito de sistemas BI; permite discutir evaluación con usuarios y valor organizacional.

**Ubicación recomendada:** 3.8 BI, datamarts y apoyo a decisiones | **Prioridad:** **Alta**

**Enlace:** [10.1016/j.dss.2019.113113](https://doi.org/10.1016/j.dss.2019.113113)

## 5.7 Cooperativas y economía popular y solidaria del Ecuador

**39. Luque González, A. y Peñaherrera Melo, J. (2021). “Cooperativas de ahorro y crédito en Ecuador: el desafío de ser cooperativas”. REVESCO. Revista de Estudios Cooperativos, 138, e73870.**

**Utilidad para la tesis:** Contexto institucional, social y organizacional de cooperativas de ahorro y crédito ecuatorianas.

**Ubicación recomendada:** 3.9 Riesgo crediticio en cooperativas ecuatorianas | **Prioridad:** **Esencial**

**Enlace:** [10.5209/reve.73870](https://doi.org/10.5209/reve.73870)

**40. Parrales Chóez, C., Zambrano Farías, F. y Valls Martínez, M. C. (2024). “Gestión financiera de las cooperativas de crédito y el sistema bancario privado de Ecuador durante 2015–2020”. REVESCO. Revista de Estudios Cooperativos, 146, e94849.**

**Utilidad para la tesis:** Compara el comportamiento financiero del sector cooperativo y la banca privada en Ecuador.

**Ubicación recomendada:** 3.9 Riesgo crediticio en cooperativas ecuatorianas | **Prioridad:** **Alta**

**Enlace:** [10.5209/reve.94849](https://doi.org/10.5209/reve.94849)

**41. Arévalo Farfán et al. (2025). “Determinantes del riesgo financiero en las cooperativas de ahorro y crédito del Ecuador: Un análisis econométrico de datos panel (2015–2024)”. UTC Prospectivas, 8(2), 123–130.**

**Utilidad para la tesis:** Evidencia ecuatoriana reciente sobre variables asociadas al riesgo financiero y la morosidad.

**Ubicación recomendada:** 3.9 Riesgo crediticio en cooperativas ecuatorianas | **Prioridad:** **Alta**

**Enlace:** [10.61236/utcpsectivas.v8i2.1179](https://doi.org/10.61236/utcpsectivas.v8i2.1179)

**42. Bermeo Siavichay, D. y Rosales Namicela, M. (2026). “Análisis del riesgo de crédito de las cooperativas ecuatorianas del segmento 1, periodo 2021–2023”. Revista Decisión Gerencial, 4(10), 28–39.**

**Utilidad para la tesis:** Aporta contexto reciente sobre riesgo crediticio en cooperativas ecuatorianas del segmento 1.

**Ubicación recomendada:** 3.9 Riesgo crediticio en cooperativas ecuatorianas | **Prioridad:** Media

**Enlace:** [10.26871/rdg.v4i10.73](https://doi.org/10.26871/rdg.v4i10.73)

**43. Villacis-Díaz, M. y Martínez-Ortiz, J. (2026). “Modelo predictivo basado en indicadores financieros históricos para clasificar riesgo en cooperativas ecuatorianas segmento uno”. Revista Metropolitana de Ciencias Aplicadas, 9(3), 208–215.**

**Utilidad para la tesis:** Trabajo local próximo al tema; debe compararse cuidadosamente porque su unidad de análisis parece institucional.

**Ubicación recomendada:** 3.9 Riesgo crediticio en cooperativas ecuatorianas | **Prioridad:** Media

**Enlace:** [10.62452/ew9ns279](https://doi.org/10.62452/ew9ns279)

## 5.8 Documentos metodológicos, técnicos y regulatorios

**44. Page, M. J. et al. (2021). “The PRISMA 2020 statement: an updated guideline for reporting systematic reviews”. BMJ, 372, n71.**

**Utilidad para la tesis:** Guía obligatoria si el capítulo mantiene la denominación “revisión sistemática”; exige proceso transparente y reproducible.

**Ubicación recomendada:** 3.1 Metodología de búsqueda bibliográfica | **Prioridad:** **Esencial**

**Enlace:** [10.1136/bmj.n71](https://doi.org/10.1136/bmj.n71)

**45. National Institute of Standards and Technology (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST AI 100-1.**

**Utilidad para la tesis:** Fundamenta gobernanza, confiabilidad, documentación, monitoreo y gestión de riesgos de sistemas de IA.

**Ubicación recomendada:** 3.6 Riesgo de modelo / 3.7 MLOps | **Prioridad:** **Esencial**

Enlace: [10.6028/NIST.AI.100-1](https://doi.org/10.6028/NIST.AI.100-1)

#### 46. European Banking Authority (2023). Follow-up Report on the Use of Machine Learning for Internal Ratings-Based Models.

**Utilidad para la tesis:** Marco de referencia sobre validación, interpretabilidad, gobernanza y uso prudente de ML en riesgo crediticio.

**Ubicación recomendada:** 3.6 Riesgo de modelo / 3.7 Gobernanza | **Prioridad:** **Esencial**

Enlace: [Documento oficial de la EBA](#)

#### 47. Basel Committee on Banking Supervision (2013). Principles for effective risk data aggregation and risk reporting (BCBS 239).

**Utilidad para la tesis:** Principios sobre integridad, trazabilidad, completitud, oportunidad y calidad de datos y reportes de riesgo.

**Ubicación recomendada:** 3.8 BI, datamart y gobierno de datos | **Prioridad:** **Esencial**

Enlace: [BCBS 239](#)

#### 48. Superintendencia de Economía Popular y Solidaria (SEPS). Normativa vigente para la gestión del riesgo de crédito en las entidades del Sector Financiero Popular y Solidario.

**Utilidad para la tesis:** Fundamenta el contexto regulatorio ecuatoriano. Debe seleccionarse la resolución concreta según segmento, periodo y alcance institucional.

**Ubicación recomendada:** 3.9 Contexto normativo ecuatoriano | **Prioridad:** **Esencial**

Enlace: [Debe citarse la resolución exacta aplicable](#)

## 6. Sustitución de preprints del capítulo actual

| Tema actual                                               | Fuentes publicadas recomendadas                                                                      | Cambio de enfoque                                                                                          |
|-----------------------------------------------------------|------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------|
| Comparación de modelos y supuesta superioridad de árboles | Lessmann et al. (2015); Gunnarsson et al. (2021); Dastile et al. (2020); Moscato et al. (2021).      | Evitar afirmar superioridad universal; presentar resultados condicionados por datos, protocolo y métricas. |
| CNN, MLP y secuencias temporales                          | Kvamme et al. (2018); Gunnarsson et al. (2021); Ampountolas et al. (2021).                           | Diferenciar secuencias diarias ricas de ventanas mensuales cortas y datasets pequeños.                     |
| Predicción multi-horizonte                                | Duffie et al. (2007); Duan et al. (2012); Orth (2013); Blumenstock et al. (2022); Bai et al. (2022). | Sustentar formalmente la predicción multiperiodo y discutir supervivencia como alternativa.                |
| MLOps                                                     | Testi et al. (2022); Kreuzberger et al. (2023); Sculley et al. (2015); Breck et al. (2017).          | Reemplazar preprints por versiones publicadas y evaluar preparación real para producción.                  |
| Ética, explicabilidad y gobernanza                        | Bussmann et al. (2021); Bücker et al. (2022); Chen et al. (2024); NIST AI RMF; EBA.                  | Distinguir interpretabilidad, auditabilidad, fairness, monitoreo y gobernanza.                             |
| Datamart, dashboards y valor de negocio                   | March y Hevner (2007); Trieu (2017); Phillips-Wren et al. (2021); Ain et al. (2019).                 | No equiparar implementación de dashboards con mejora demostrada en decisiones.                             |

## 7. Protocolo de búsqueda recomendado

**Bases de datos sugeridas:** Scopus, Web of Science, IEEE Xplore, ScienceDirect, SpringerLink, ACM Digital Library y, como apoyo, Google Scholar. ArXiv puede utilizarse para descubrir trabajos, pero no debería ser la fuente final cuando existe una versión publicada.

**Periodo sugerido:** 2015–2026 para modelos y MLOps; incluir referencias seminales anteriores cuando sean necesarias para predicción multiperiodo, data warehousing o riesgo crediticio.

### 7.1 Cadenas de búsqueda sugeridas

- ("credit scoring" OR "credit risk" OR "default prediction") AND ("machine learning" OR "deep learning" OR LightGBM OR XGBoost)
- ("credit scoring" OR "default prediction") AND (CNN OR "multilayer perceptron" OR "neural network")
- ("multi-period" OR "multi-horizon" OR survival OR "competing risks") AND (credit OR default)
- (MLOps OR "machine learning operations") AND (finance OR banking OR "credit risk")
- ("business intelligence" OR datamart OR "data warehouse") AND (credit OR banking OR finance)
- (cooperative OR "credit union" OR cooperativa) AND (credit risk OR default OR morosidad) AND Ecuador

### 7.2 Criterios de inclusión

- Artículo de revista o congreso revisado por pares; documento oficial de organismo regulador o técnico reconocido.
- Relación directa con al menos uno de los ejes del capítulo: modelos, temporalidad, desbalance, interpretabilidad, MLOps, BI/datamart o contexto cooperativo.
- Metodología y resultados suficientemente documentados.
- Texto en español o inglés y metadatos bibliográficos verificables.

### 7.3 Criterios de exclusión

- Preprints sin versión publicada definitiva.
- Documentos comerciales o blogs usados como evidencia científica.
- Estudios sin descripción metodológica o sin métricas de evaluación.
- Trabajos de fraude financiero sin conexión clara con riesgo crediticio, salvo revisiones que aporten gobernanza o explicabilidad.
- Duplicados o versiones anteriores de un mismo artículo.

## 8. Matriz comparativa recomendada para el estado del arte

La tabla principal del capítulo debería permitir una comparación transversal, no una sucesión de resúmenes artículo por artículo. Se recomienda utilizar las siguientes columnas:

| Estudio     | Tipo de datos    | Unidad de análisis         | Tamaño/período | Modelos          | Horizonte  | Split temporal | Desbalance  | Métricas            | XAI     | MLOps | BI/datamart | Limitación principal                    |
|-------------|------------------|----------------------------|----------------|------------------|------------|----------------|-------------|---------------------|---------|-------|-------------|-----------------------------------------|
| Autor (año) | Tabular/temporal | Cliente/crédito/bloque-mes | n y periodo    | LightGBM/CNN/MLP | 1–18 meses | Sí/No          | Pesos/SMOTE | AUC, PR-AUC, recall | SHAP/No | Sí/No | Sí/No       | Una institución; sin validación externa |

## 9. Recomendaciones para formular la brecha de investigación

- No afirmar que “no existen trabajos” sin demostrarlo mediante el protocolo de búsqueda y la tabla comparativa.
- Distinguir cuatro dimensiones: evaluación multi-horizonte, comparación controlada de familias de modelos, operacionalización MLOps e integración con BI/datamart.
- Formular la contribución como una integración y evaluación contextual en una institución de la economía social y solidaria, no como demostración universal de superioridad de LightGBM.
- Reconocer que existen trabajos multiperiodo y de supervivencia; la novedad puede residir en la implementación de 18 horizontes y su integración operativa, siempre que se documente y evalúe correctamente.
- Separar la brecha científica de la necesidad institucional: una necesidad local no implica automáticamente una brecha de investigación internacional.

## 10. Ejemplo de redacción de la síntesis crítica

**Propuesta de texto:** “La literatura sobre credit scoring muestra un uso creciente de métodos de ensemble y boosting, que con frecuencia alcanzan un rendimiento competitivo en datos tabulares. No obstante, los resultados dependen del conjunto de datos, del protocolo de validación, del tratamiento del desbalance y de las métricas consideradas, por lo que no existe evidencia suficiente para sostener la superioridad universal de una familia de modelos. Paralelamente, los estudios de predicción multiperiodo y análisis de supervivencia demuestran la relevancia de modelar la evolución temporal del incumplimiento, aunque esta perspectiva aparece con menor frecuencia en implementaciones que integran el ciclo completo de MLOps, almacenamiento analítico y visualización. En el contexto ecuatoriano, la literatura sobre cooperativas se concentra principalmente en indicadores financieros y análisis institucionales, mientras que son limitados los trabajos que documentan de manera conjunta la predicción multi-horizonte, el registro reproducible de experimentos, la inferencia automatizada y la integración de predicciones en un datamart para apoyar el análisis del riesgo. Esta combinación constituye la brecha aplicada que aborda el presente trabajo, dentro de las restricciones de una sola institución y un conjunto de datos específico.”

## 11. Checklist para incorporar las referencias

- ☐ Sustituir cada preprint por la versión publicada definitiva cuando exista.
- ☐ Incluir DOI o URL oficial y verificar autores, año, volumen, páginas y título.
- ☐ Usar al menos una revisión sistemática, un benchmark y un estudio aplicado por cada eje central.
- ☐ No citar artículos solo para afirmar que un algoritmo “es superior”; explicar dataset, protocolo y limitaciones.
- ☐ Incorporar una subsección específica sobre predicción multi-periodo/multi-horizonte.
- ☐ Distinguir estudios de microcrédito, crédito de consumo, hipotecas, empresas y cooperativas.
- ☐ Agregar normativa de SEPS y documentos de gobernanza de riesgo de modelo.
- ☐ Construir una tabla comparativa con todos los estudios principales.
- ☐ Cerrar el capítulo con una síntesis crítica que conduzca directamente a la metodología de la tesis.
- ☐ Revisar que toda fuente citada en el texto aparezca en el archivo .bib y viceversa.

*Control bibliográfico: antes de incorporar las entradas al proyecto de Overleaf, conviene descargar las citas BibTeX desde la página editorial o DOI y normalizar mayúsculas, nombres de revistas y caracteres especiales en LaTeX.*