



UNIVERSIDAD DE INVESTIGACIÓN DE TECNOLOGÍA EXPERIMENTAL YACHAY

Escuela de Ciencias Matemáticas y Computacionales

**Sistema integrado de inteligencia de negocio y MLOps para
la predicción multi-horizonte de crisis crediticias**

Autor:

Omar Antonio Vélez Bayas

Tutor:

Juan Pablo Astudillo León, Ph.D.

Urcuquí, julio de 2026

Autoría

Yo, **Omar Antonio Vélez Bayas**, con cédula de identidad 0102581709, declaro que las ideas, juicios, valoraciones, interpretaciones, consultas bibliográficas, definiciones y conceptualizaciones expuestas en el presente trabajo, así como los procedimientos y las herramientas utilizados en la investigación, son de absoluta responsabilidad del autor del trabajo de titulación. Asimismo, me acojo a los reglamentos internos de la Universidad de Investigación de Tecnología Experimental Yachay.

Urcuquí, julio de 2026.

Omar Antonio Vélez Bayas

C.I.: 0102581709

Autorización de publicación

Yo, **Omar Antonio Vélez Bayas**, con cédula de identidad 0102581709, cedo a la Universidad de Investigación de Tecnología Experimental Yachay los derechos de publicación de la presente obra, sin que deba existir un reconocimiento económico por este concepto. Declaro, además, que el texto del presente trabajo de titulación no podrá ser cedido a ninguna empresa editorial para su publicación u otros fines sin contar previamente con la autorización escrita de la Universidad.

Asimismo, autorizo a la Universidad a digitalizar y publicar este trabajo de titulación en el repositorio institucional, de conformidad con lo dispuesto en el artículo 144 de la Ley Orgánica de Educación Superior.

Urcuquí, julio de 2026.

Omar Antonio Vélez Bayas
C.I.: 0102581709

Dedicatoria

A mis seres queridos, por su comprensión, apoyo y compañía durante este proceso académico.

Omar Antonio Vélez Bayas

Agradecimientos

Agradezco al personal de la maestría por su constante apoyo administrativo; al cuerpo docente, por compartir sus conocimientos y experiencia; y a mi director de tesis, por su guía, paciencia y acompañamiento durante el desarrollo de este proyecto. Expreso también mi gratitud a mis compañeros de trabajo, quienes facilitaron el tiempo y el espacio necesarios para continuar mis estudios.

Omar Antonio Vélez Bayas

Resumen

Esta tesis presenta el diseño y la implementación de un prototipo de inteligencia de negocio para integrar procesamiento de datos crediticios, predicción multi-horizonte, gestión de experimentos y visualización analítica en una institución de la economía social y solidaria del Ecuador. El sistema utiliza PostgreSQL para el almacenamiento y el datamart, Apache Airflow para orquestar los flujos de entrenamiento e inferencia, MLflow para registrar experimentos y Apache Superset para los dashboards. La evaluación compara LightGBM, una red neuronal convolucional y un perceptrón multicapa para dieciocho horizontes temporales. En los resultados reportados, LightGBM alcanzó un AUC-ROC promedio de 0,80, mientras que las implementaciones de CNN y MLP mostraron un AUC-ROC de 0,50. El rendimiento de LightGBM disminuyó con el horizonte y el recall descendió hasta 0,034 a dieciocho meses, lo que limita la interpretación operativa de las predicciones de largo plazo. Bajo la configuración evaluada, LightGBM presentó la mayor capacidad discriminativa; sin embargo, la ausencia de repeticiones, pruebas estadísticas, validación externa y una documentación completa de la etiqueta heurística impide afirmar superioridad general o causalidad. La contribución principal es la integración técnica de un flujo de datos, modelado, registro, almacenamiento analítico y visualización, presentada como un prototipo funcional que requiere validación metodológica y operativa adicional.

Palabras clave: riesgo crediticio; predicción multi-horizonte; LightGBM; redes neuronales; inteligencia de negocio; MLOps; datamart; Apache Airflow.

Abstract

This thesis presents the design and implementation of a business intelligence prototype that integrates credit data processing, multi-horizon prediction, experiment tracking, and analytical visualization for an Ecuadorian social and solidarity economy institution. PostgreSQL is used for storage and the data mart, Apache Airflow orchestrates training and inference workflows, MLflow records experiments, and Apache Superset provides interactive dashboards. The evaluation compares LightGBM, a convolutional neural network, and a multilayer perceptron across eighteen forecasting horizons. In the reported results, LightGBM achieved a mean ROC-AUC of 0.80, whereas the CNN and MLP implementations yielded a ROC-AUC of 0.50. LightGBM performance decreased as the horizon increased, and recall fell to 0.034 at eighteen months, which limits the operational interpretation of long-term predictions. Under the evaluated configuration, LightGBM showed the highest discriminative performance; however, the lack of repeated runs, statistical tests, external validation, and complete documentation of the heuristic target prevents claims of general superiority or causality. The main contribution is the technical integration of data processing, modeling, experiment tracking, analytical storage, and visualization into a functional prototype that requires further methodological and operational validation.

Keywords: credit risk; multi-horizon prediction; LightGBM; neural networks; business intelligence; MLOps; data mart; Apache Airflow.

Índice general

Índice general

Índice de cuadros

Índice de figuras

1. Introducción	1
1.1. Contexto	1
1.2. Motivación	2
1.3. Planteamiento del problema	2
1.4. Pregunta de investigación	2
1.5. Hipótesis	3
1.6. Objetivo general	3
1.7. Objetivos específicos	3
1.8. Contribuciones	4
1.9. Organización del documento	4
2. Marco teórico	5
2.1. Riesgo crediticio y clasificación binaria	5
2.2. Inteligencia de negocio, data warehouse y datamart	5
2.3. Predicción multi-horizonte	6
2.4. Clases desbalanceadas	6
2.5. Modelos evaluados	7
2.5.1. LightGBM	7
2.5.2. Red neuronal convolucional	7
2.5.3. Perceptrón multicapa	7

2.6. Validación temporal y fuga de información	7
2.7. Métricas de evaluación	8
2.8. MLOps y observabilidad	8
3. Revisión de literatura	10
3.1. Estrategia de búsqueda	10
3.2. Predicción de riesgo crediticio	10
3.3. MLOps aplicado al riesgo crediticio	11
3.4. Síntesis comparativa	11
3.5. Brechas y posicionamiento del trabajo	13
4. Metodología	14
4.1. Diseño de la investigación	14
4.2. Diseño y arquitectura del sistema	15
4.3. Fuentes de datos y unidad de análisis	17
4.4. Procesamiento y preparación de datos	17
4.5. Ingeniería de características y variable objetivo	18
4.5.1. Generación de horizontes	19
4.6. Algoritmos seleccionados	19
4.6.1. CNN multi-horizonte	19
4.6.2. MLP multi-horizonte	20
4.6.3. LightGBM multi-horizonte	20
4.7. Hiperparámetros y estrategia de ajuste	20
4.8. Protocolo de entrenamiento, validación y prueba	21
4.9. Métricas y criterio de selección	22
4.10. Pipeline MLOps y registro de experimentos	23
4.11. Puesta en producción e inferencia	23
4.12. Diseño del datamart y dashboards	25
5. Resultados y discusión	26
5.1. Caracterización del conjunto de datos	26
5.2. Resultados del procesamiento y análisis exploratorio	27
5.2.1. Correlaciones	27
5.2.2. Poder predictivo individual	27

5.2.3. Evolución temporal de la clase positiva	28
5.3. Resultados de los modelos	29
5.3.1. LightGBM	29
5.3.2. CNN	31
5.3.3. MLP	32
5.4. Comparación global	32
5.5. Ejecución automatizada y registro	33
5.6. Datamart y dashboards	35
5.7. Discusión	36
6. Conclusiones	38
6.1. Síntesis de los principales hallazgos	38
6.2. Respuesta al objetivo general	38
6.3. Respuesta a los objetivos específicos	38
6.4. Contribuciones	39
6.5. Limitaciones	39
6.6. Trabajo futuro	40
Bibliografía	41
Appendices	45
A. Repositorios y evidencia complementaria	45
A.1. Repositorios del proyecto	45
A.2. Capturas adicionales de dashboards	46
A.3. Información mínima para reproducibilidad	47

Índice de cuadros

3.1. Síntesis de trabajos relacionados según la información reportada en la tesis.	12
4.1. Componentes tecnológicos del sistema.	16
4.2. Fuentes de datos utilizadas en el proceso ETL.	17
4.3. Características identificadas explícitamente en los archivos disponibles. . .	18
4.4. Configuración documentada de los modelos evaluados.	20
5.1. Distribución global de la variable objetivo.	26
5.2. Variables con mayor AUC-ROC individual según el análisis exploratorio. .	28
5.3. Métricas reportadas para LightGBM en horizontes seleccionados.	29
5.4. Comparación de los resultados reportados. Las unidades de resumen no son completamente equivalentes entre modelos.	33
5.5. Resultados reportados para las ejecuciones inicial y automatizada.	33

Índice de figuras

4.1. Flujo metodológico para la preparación del conjunto analítico y la división temporal.	15
4.2. Arquitectura general del prototipo de inteligencia de negocio y MLOps. . .	16
4.3. Representación conceptual de la ventana de entrada y las etiquetas multi-horizonte.	19
4.4. Flujo de entrenamiento, registro y selección implementado en el prototipo.	22
4.5. Flujo de inferencia y actualización analítica.	24
4.6. Esquema conceptual del datamart analítico.	25
5.1. Matriz de correlaciones de las características del conjunto analítico.	27
5.2. AUC-ROC individual reportada para las características analizadas.	28
5.3. Evolución temporal de la proporción de bloques etiquetados como crisis. . .	29
5.4. Evolución de las métricas de LightGBM a través de los horizontes evaluados.	30
5.5. Importancia de características calculada por LightGBM.	31
5.6. Pérdida reportada durante el entrenamiento de la CNN.	32
5.7. Vista del DAG de entrenamiento implementado en Apache Airflow.	34
5.8. Vista del DAG de inferencia implementado en Apache Airflow.	34
5.9. Dashboard para el análisis histórico de la cartera crediticia.	35
5.10. Ejemplos de dashboards para indicadores y segmentación geográfica.	35
5.11. Dashboards para segmentación sectorial y priorización de bloques.	36
A.1. Vista complementaria del dashboard histórico de créditos.	46
A.2. Dashboard de análisis dimensional por riesgo y sector.	46
A.3. Dashboard de evolución temporal de predicciones.	47

Capítulo 1

Introducción

Este capítulo delimita el problema de investigación, presenta la pregunta y la hipótesis, y establece los objetivos y las contribuciones del trabajo. El alcance se concentra en la integración técnica de datos, modelos predictivos, MLOps y visualización; no se evalúa una reducción causal de la mora ni se implementan funciones conversacionales o alertas automáticas.

1.1. Contexto

Las instituciones financieras de la economía social y solidaria administran información de créditos, amortizaciones, recuperaciones y cartera que puede utilizarse para describir el comportamiento histórico y estimar escenarios futuros. En muchos entornos, los indicadores de morosidad, cartera vencida y recuperación se generan a partir de procesos manuales o repositorios separados. Esta fragmentación dificulta la actualización oportuna de los reportes y limita la incorporación de resultados predictivos en los procesos analíticos.

La inteligencia de negocio permite consolidar fuentes operativas en repositorios orientados al análisis y presentar indicadores mediante dashboards. Por su parte, el aprendizaje automático permite estimar probabilidades de incumplimiento a partir de patrones presentes en los datos. La integración de ambas áreas requiere, además, mecanismos para automatizar el procesamiento, registrar experimentos, versionar modelos y ejecutar inferencias de forma controlada. En este trabajo, dicha integración se aborda mediante PostgreSQL, Apache Airflow, MLflow y Apache Superset.

1.2. Motivación

El proyecto surge de una necesidad aplicada: reducir la dependencia de tareas manuales para consolidar información crediticia y disponer de una vista unificada que combine datos históricos y predicciones. La institución considerada contaba con grandes volúmenes de registros operativos, pero no con un flujo integrado que permitiera preparar los datos, comparar modelos, almacenar predicciones multi-horizonte y visualizarlas en un mismo entorno.

La motivación científica se relaciona con dos aspectos. Primero, la comparación entre modelos basados en árboles y redes neuronales bajo datos tabulares, desbalanceados y con secuencias temporales cortas. Segundo, la evaluación del efecto del horizonte temporal sobre el rendimiento predictivo. La motivación técnica consiste en llevar el modelo seleccionado desde el entorno de experimentación hacia un prototipo reproducible de entrenamiento, inferencia, registro y visualización.

1.3. Planteamiento del problema

El problema se define por la ausencia de integración entre las fuentes crediticias, el entrenamiento de modelos y las herramientas de análisis. Los datos se encuentran en tablas con propósitos operativos distintos; la preparación y actualización de reportes requiere intervención técnica; y las predicciones no están incorporadas de manera sistemática en un datamart que permita analizarlas junto con el histórico de cartera.

Esta situación genera tres brechas. La primera es una brecha de datos, porque no existe un flujo único y documentado para integrar, limpiar y agregar la información. La segunda es una brecha analítica, debido a que los modelos no se comparan dentro de un protocolo multi-horizonte común. La tercera es una brecha operativa, ya que los resultados del modelado no se registran, almacenan y visualizan mediante un proceso automatizado.

1.4. Pregunta de investigación

La investigación se guía por la siguiente pregunta:

¿Cómo diseñar e implementar una plataforma de inteligencia de negocio que integre predicción multi-horizonte de riesgo crediticio, un datamart analítico y

dashboards interactivos para apoyar la identificación anticipada de escenarios de mora en una institución de la economía social y solidaria?

La pregunta se limita al diseño, la implementación y la evaluación técnica del prototipo. No implica que la plataforma reduzca por sí misma la mora ni que sustituya la valoración de especialistas.

1.5. Hipótesis

Bajo el conjunto de datos, la división temporal y las configuraciones experimentales utilizadas, se espera que LightGBM alcance una capacidad discriminativa superior a las implementaciones de CNN y MLP para la predicción multi-horizonte de crisis crediticias. Esta hipótesis se evalúa en el contexto específico del estudio y no pretende establecer una superioridad universal de una familia de modelos.

1.6. Objetivo general

Diseñar e implementar un prototipo de inteligencia de negocio crediticia que automatice el procesamiento de datos, compare LightGBM, CNN y MLP para predicción multi-horizonte, y conecte el modelo seleccionado con un datamart y dashboards interactivos.

1.7. Objetivos específicos

1. Analizar los factores plausibles asociados con el rendimiento observado de las arquitecturas neuronales en el conjunto de datos evaluado.
2. Comparar LightGBM, CNN y MLP mediante las métricas y configuraciones documentadas para el escenario de estudio.
3. Evaluar la variación del rendimiento predictivo conforme aumenta el horizonte temporal.
4. Diseñar e implementar un datamart en esquema estrella y dashboards que integren datos históricos y predicciones.

1.8. Contribuciones

El trabajo aporta una arquitectura de extremo a extremo que conecta ingesta, preparación de datos, entrenamiento, registro de experimentos, inferencia, almacenamiento analítico y visualización. También presenta una comparación multi-horizonte entre tres familias de modelos y documenta el deterioro de las métricas en horizontes largos. Finalmente, implementa un datamart con dimensiones de tiempo, riesgo, sector y sucursal, junto con dashboards orientados al análisis de cartera y predicciones.

Estas contribuciones deben interpretarse como resultados de un prototipo evaluado en una institución. La validación con otras entidades, las pruebas de utilidad con usuarios y la auditoría completa de la variable objetivo permanecen como trabajo posterior.

1.9. Organización del documento

El Capítulo 2 presenta los fundamentos de riesgo crediticio, inteligencia de negocio, predicción multi-horizonte, modelos y métricas. El Capítulo 3 resume la literatura utilizada y delimita las brechas abordadas. El Capítulo 4 describe el diseño de la investigación, el procesamiento de datos, los modelos, la configuración experimental y los flujos MLOps. El Capítulo 5 presenta y discute los resultados del análisis exploratorio, el entrenamiento, la comparación de modelos y la implementación. El Capítulo 6 sintetiza los hallazgos, responde a los objetivos y expone las limitaciones y líneas de trabajo futuro.

Capítulo 2

Marco teórico

Este capítulo presenta los conceptos necesarios para comprender el diseño del sistema y la evaluación experimental. Se priorizan los fundamentos relacionados con el problema y se separan de la descripción operativa de las herramientas, que se desarrolla en la metodología.

2.1. Riesgo crediticio y clasificación binaria

El riesgo crediticio representa la posibilidad de que una obligación no sea atendida según las condiciones pactadas. En este trabajo, el problema se formula como una tarea de clasificación binaria en la que cada unidad de análisis recibe una etiqueta de crisis o no crisis. La etiqueta no corresponde directamente a una decisión regulatoria universal, sino a una regla heurística construida para el contexto institucional analizado.

En una clasificación binaria, los resultados se organizan en verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos. En riesgo crediticio, los falsos negativos son especialmente relevantes porque representan casos de crisis que el modelo no identifica. Por ello, una exactitud elevada puede resultar engañosa cuando la clase positiva es minoritaria.

2.2. Inteligencia de negocio, data warehouse y data-mart

La inteligencia de negocio comprende procesos y tecnologías que transforman datos operativos en información analítica para apoyar decisiones [1]. Un data warehouse integra

información de múltiples fuentes y conserva una estructura orientada al análisis. Un datamart es un subconjunto enfocado en un dominio específico, como cartera o riesgo crediticio [2].

El esquema estrella organiza una tabla de hechos central y varias tablas de dimensiones. Las tablas de hechos almacenan medidas cuantitativas y claves foráneas; las dimensiones proporcionan contexto temporal, geográfico o de negocio. En esta tesis, las dimensiones corresponden a tiempo, riesgo, sector y sucursal, mientras que las tablas de hechos contienen agregados mensuales y predicciones.

2.3. Predicción multi-horizonte

La predicción multi-horizonte estima el estado futuro de una variable para varios plazos. Si x_t representa la información disponible hasta el mes t , el objetivo consiste en estimar una probabilidad $\hat{p}_{t+h}$ para cada horizonte $h \in \{1, \dots, 18\}$. Los horizontes cortos y largos no necesariamente presentan la misma dificultad, porque la relación entre la información actual y el evento futuro puede debilitarse con el tiempo.

El proyecto utiliza dos estrategias. CNN y MLP producen dieciocho salidas simultáneas, una por horizonte. LightGBM utiliza dieciocho clasificadores independientes. Estas estrategias no son idénticas: la salida conjunta puede compartir representaciones entre horizontes, mientras que los modelos independientes optimizan cada plazo por separado. Esta diferencia debe considerarse al interpretar la comparación.

2.4. Clases desbalanceadas

Un conjunto está desbalanceado cuando una clase contiene muchas más observaciones que la otra. Este escenario puede inducir modelos que predicen casi siempre la clase mayoritaria y, aun así, obtienen una exactitud alta. He y Garcia [3] describen técnicas de reponderación, remuestreo y aprendizaje sensible al costo para enfrentar este problema.

En LightGBM se utilizó el parámetro `scale_pos_weight`. En las redes neuronales se reporta el uso de pesos de muestra, aunque los artefactos disponibles no documentan con suficiente detalle su cálculo ni su aplicación. La comparación debe considerar que cada modelo puede responder de manera distinta al desbalance.

2.5. Modelos evaluados

2.5.1. LightGBM

LightGBM es una implementación eficiente de árboles de decisión potenciados por gradiente [4]. El método construye secuencialmente árboles que corrigen los errores del conjunto anterior, siguiendo el principio general de gradient boosting [5]. Entre sus ventajas para datos tabulares se encuentran el manejo de relaciones no lineales, interacciones entre variables y escalas heterogéneas. Sin embargo, también puede sobreajustar y amplificar fugas de información si una característica contiene señales derivadas directa o indirectamente de la etiqueta.

2.5.2. Red neuronal convolucional

Las redes neuronales convolucionales aprenden filtros locales y representaciones jerárquicas [6]. En series temporales, una convolución unidimensional puede identificar patrones entre meses consecutivos. La utilidad de este enfoque depende del número de secuencias, la longitud temporal, el tratamiento del desbalance, la regularización y la configuración del entrenamiento.

2.5.3. Perceptrón multicapa

El perceptrón multicapa transforma la entrada mediante capas densas y funciones no lineales. Para una ventana de seis meses y veintiuna características, la entrada contiene $6 \times 21 = 126$ valores antes de cualquier transformación adicional. La arquitectura utilizada produce dieciocho probabilidades mediante activación sigmoide. El desempeño depende, entre otros factores, del escalado, la función de pérdida, el tamaño de lote, la tasa de aprendizaje y la cantidad de muestras.

2.6. Validación temporal y fuga de información

Cuando los datos tienen orden temporal, la división aleatoria puede permitir que información futura influya en el entrenamiento. Una división temporal conserva las observaciones más antiguas para entrenamiento y las más recientes para evaluación. El conjunto de prueba

debe permanecer aislado de la selección de hiperparámetros, del early stopping y de la selección del umbral.

La fuga de información ocurre cuando una característica contiene datos que no estarían disponibles en el momento real de la predicción o cuando deriva de la misma regla utilizada para construir la etiqueta. En este estudio, las variables judiciales requieren una auditoría específica porque presentan alta importancia predictiva y podrían estar relacionadas con las condiciones que definen `crisis_flag`.

2.7. Métricas de evaluación

La exactitud, precisión, recall y F1-score se definen como:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad (2.1)$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad (2.2)$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (2.3)$$

$$F_1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (2.4)$$

El AUC-ROC resume la capacidad del modelo para ordenar positivos por encima de negativos a través de diferentes umbrales [7]. Un valor cercano a 0,5 indica discriminación equivalente al azar, mientras que un valor mayor no garantiza por sí solo una utilidad operativa. En conjuntos desbalanceados también es recomendable examinar PR-AUC, matrices de confusión, calibración y errores por horizonte. Estas evaluaciones no están disponibles de forma completa en los resultados originales y se reconocen como limitaciones.

2.8. MLOps y observabilidad

MLOps integra prácticas de desarrollo, datos y operación para gestionar el ciclo de vida de modelos. En este trabajo, Apache Airflow orquesta tareas; MLflow registra parámetros, métricas y artefactos; PostgreSQL almacena datos y predicciones; y Apache Superset consulta el datamart. La presencia de estas herramientas no demuestra por sí sola reproducibilidad

o calidad operativa: también se requieren versiones, semillas, validaciones, manejo de fallos, monitoreo de datos y pruebas funcionales.

Capítulo 3

Revisión de literatura

Este capítulo presenta una revisión de literatura orientada a identificar enfoques de predicción de riesgo crediticio, herramientas MLOps e integración analítica. No se denomina revisión sistemática, porque los artefactos disponibles no incluyen un protocolo completo de selección, conteos de estudios ni un diagrama reproducible de filtrado.

3.1. Estrategia de búsqueda

La búsqueda reportada utilizó arXiv, Google Scholar y bases de datos científicas, con términos relacionados con *credit risk prediction*, *LightGBM*, *credit scoring*, *MLOps* y *data warehouse*. El periodo priorizado fue 2021–2026. Debido a que no se conservaron los conteos de resultados, los criterios detallados de inclusión y exclusión ni la fecha exacta de cada consulta, el capítulo debe interpretarse como una revisión narrativa de las fuentes seleccionadas.

3.2. Predicción de riesgo crediticio

Yu et al. [8] evaluaron LightGBM, XGBoost y TabNet junto con SMOTEENN. Zhu et al. [9] combinaron modelos de boosting y conjuntos de características. Yang et al. [10] estudiaron ensambles e interpretabilidad mediante SHAP. Estos trabajos muestran el uso frecuente de modelos basados en árboles para datos tabulares y resaltan la importancia del tratamiento del desbalance y de la interpretabilidad.

La literatura revisada no respalda una superioridad universal de los árboles. Arram et

al. [11], por ejemplo, reportaron un mejor resultado del MLP en su conjunto de datos. Esta diferencia evidencia que el rendimiento depende del tamaño de muestra, las variables, la distribución, el protocolo de evaluación y la configuración de cada modelo.

Shreya y Pathak [12] compararon XGBoost, LightGBM y Random Forest con técnicas explicativas. Nayak [13] combinó calibración, restricciones de equidad y gradient boosting. AlMarri et al. [14] compararon clasificadores basados en modelos de lenguaje con LightGBM y analizaron la alineación de sus explicaciones.

3.3. MLOps aplicado al riesgo crediticio

Marcos-Mercadé et al. [15] evaluaron herramientas como MLflow, Metaflow, Apache Airflow y Kubeflow Pipelines. Micallef et al. [16] analizaron la cobertura del ciclo de vida en herramientas MLOps, mientras que Zampetti et al. [17] estudiaron su uso en proyectos de código abierto. En conjunto, estas fuentes sugieren que la orquestación, el registro de experimentos y el versionado suelen combinarse mediante varias herramientas.

Amed et al. [18] propusieron un flujo adaptativo para riesgo crediticio digital con monitoreo y reentrenamiento. Hossain et al. [19] incorporaron controles de equidad y condiciones para bloquear despliegues. Estos enfoques muestran que un pipeline MLOps no debe limitarse a automatizar tareas; también debe incorporar validaciones, seguimiento de cambios y criterios de aprobación.

3.4. Síntesis comparativa

Estudio	Datos	Modelos/enfoque	Horizonte	Métricas reportadas	MLOps/BI	Limitación para esta tesis
Yu et al. [8]	Banco comercial	LightGBM, XGBoost, TabNet, SMOTEENN	No especificado en la tesis	Rendimiento predictivo	No	Datos y protocolo distintos.
Zhu et al. [9]	Riesgo de incumplimiento	Ensamble de boosting	No especificado	Rendimiento predictivo	No	No evalúa integración con datamart.
Arram et al. [11]	Tarjetas de crédito	LR, árboles, RF, MLP, XGBoost, LightGBM	Único	AUC y precisión	No	El MLP obtiene el mejor resultado; confirma dependencia del conjunto.
Nayak [13]	Home Credit	Gradient boosting calibrado	Único	AUC, calibración y equidad	Parcial	No reproduce el escenario multi-horizonte institucional.
Amed et al. [18]	Préstamos digitales	Modelos adaptativos y MLOps	No especificado	Métricas predictivas	Sí	Arquitectura y datos distintos.
Marcos-Mercadé et al. [15]	Herramientas MLOps	MLflow, Airflow y otras	No aplica	Evaluación de herramientas	Sí	No evalúa riesgo crediticio ni dashboards.

Cuadro 3.1: Síntesis de trabajos relacionados según la información reportada en la tesis.

3.5. Brechas y posicionamiento del trabajo

En el conjunto de fuentes revisado se observa una separación entre los estudios de modelado predictivo y los trabajos sobre MLOps. También existe poca evidencia, dentro de la selección disponible, sobre predicción simultánea para dieciocho horizontes y su integración con un datamart institucional. La tesis se posiciona en esa intersección mediante un prototipo que conecta fuentes crediticias, comparación de modelos, registro de experimentos, almacenamiento de predicciones y dashboards.

La contribución no consiste en demostrar que LightGBM es universalmente superior, sino en documentar su comportamiento frente a dos arquitecturas neuronales dentro de un escenario concreto. La brecha pendiente es metodológica: se requiere un protocolo reproducible, comparaciones equivalentes, auditoría de fuga de información, validación externa y evaluación operativa con usuarios.

Capítulo 4

Metodología

Este capítulo describe el diseño de la investigación, la arquitectura del prototipo, la preparación de datos, los modelos y el protocolo de evaluación. Los resultados numéricos y su interpretación se presentan exclusivamente en el Capítulo 5.

4.1. Diseño de la investigación

El estudio es aplicado, cuantitativo y experimental en el sentido de que implementa y compara tres modelos sobre una división temporal del mismo conjunto de datos. La unidad analítica corresponde a un *bloque-mes*, definido por la combinación de mes, nivel de riesgo, sector económico y sucursal. Sobre cada bloque se calculan características agregadas y una etiqueta binaria de crisis.

El flujo metodológico comprende: integración de fuentes, agregación mensual, construcción de características y etiqueta, generación de ventanas temporales, entrenamiento de modelos, evaluación por horizonte, selección del modelo, registro en MLflow, inferencia, almacenamiento de predicciones y visualización.




Figura 4.1: Flujo metodológico para la preparación del conjunto analítico y la división temporal.

4.2. Diseño y arquitectura del sistema

La arquitectura integra cinco componentes: PostgreSQL 15 como repositorio operativo y analítico; Apache Airflow 2.10 como orquestador; Python 3.12 y Jupyter para el desarrollo de modelos; MLflow para el registro de experimentos; y Apache Superset para la visualización. La Figura 4.2 resume las interacciones.




Figura 4.2: Arquitectura general del prototipo de inteligencia de negocio y MLOps.

Componente	Tecnología		Función en el prototipo
Base de datos	PostgreSQL	15 [20]	Almacenar tablas fuente, vista materializada, hechos, dimensiones y predicciones.
Orquestación	Apache Airflow	2.10 [21]	Programar y coordinar los DAG de entrenamiento e inferencia.
Experimentación	Python Jupyter	3.12 y	Preparar datos y desarrollar LightGBM, CNN y MLP.
Registro	MLflow	[22]	Registrar parámetros, métricas y artefactos asociados a las ejecuciones.
Visualización	Apache Superset	[23]	Consultar el datamart y construir dashboards interactivos.

Cuadro 4.1: Componentes tecnológicos del sistema.

La implementación incluye un flujo mensual de entrenamiento y un flujo diario de inferencia. Esta frecuencia corresponde a la configuración del prototipo; la tesis no presenta

una evaluación de carga que demuestre que dichas periodicidades sean óptimas.

4.3. Fuentes de datos y unidad de análisis

El proceso ETL integra tres fuentes institucionales. La Tabla 4.2 presenta los nombres y magnitudes aproximadas documentadas en el proyecto.

Fuente	Magnitud re- portada	Contenido
CABECERA_PRESTAMOS	Aproximadamente 500.000 filas	Información maestra de créditos, periodo 2015–2026.
AMORTIZACAL_PRESTAMOS	Aproximadamente 2.000.000 de filas	Tabla de amortización mensual.
RECUPERACION_PRESTAMOS	Aproximadamente 100.000 filas	Información de juicios y recuperaciones.

Cuadro 4.2: Fuentes de datos utilizadas en el proceso ETL.

Los registros se integran mediante carga masiva y operaciones *upsert* con **ON CONFLICT**. Después de la integración, la información se agrega por mes, riesgo, sector y sucursal. La versión original reporta 20.025 bloques-mes en el conjunto consolidado y menciona 293 muestras de entrenamiento tras la generación de secuencias. Sin embargo, no conserva un cuadro de trazabilidad con los conteos intermedios; por tanto, la relación exacta entre registros fuente, bloques válidos, ventanas y muestras finales no puede reproducirse únicamente con el manuscrito.

4.4. Procesamiento y preparación de datos

El procesamiento se implementa en una vista materializada y en tareas del DAG. Las etapas documentadas son: integración de las tres fuentes, validación de claves, prevención de duplicados mediante *upsert*, agregación mensual y cálculo de características. El proyecto no aporta un registro completo de filas eliminadas, valores faltantes, criterios de tratamiento de atípicos ni conteos posteriores a cada filtro. Estas decisiones deben versionarse junto con el código para garantizar reproducibilidad.

Las redes neuronales requieren una representación secuencial. Para cada bloque se utiliza una ventana de seis meses con veintiuna características por mes, lo que corresponde a una

matriz de 6×21 y a 126 valores antes de cualquier transformación adicional. La referencia original a 128 valores se corrige porque no se documentan dos variables adicionales.

4.5. Ingeniería de características y variable objetivo

El proyecto indica que se calculan veintiuna características numéricas. No obstante, el manuscrito fuente solo identifica explícitamente las variables de la Tabla 4.3. Esta tabla no debe confundirse con un diccionario completo.

Variable documentada	Grupo	Interpretación general
num_creditos	Volumen	Número de créditos agregados en el bloque-mes.
monto_total	Volumen	Suma del monto crediticio.
monto_promedio	Volumen	Monto promedio de los créditos.
plazo_promedio	Condición	Plazo promedio de las operaciones.
tasa_interes_promedio	Condición	Tasa de interés promedio.
tasa_judicial	Riesgo	Proporción asociada con operaciones judicializadas.
creditos_judiciales	Riesgo	Número de créditos judicializados.
mora_promedio	Riesgo	Medida agregada de mora.
coef_variacion_montos	Derivada	Variabilidad relativa de los montos.
tasa_crecimiento_creditos	Derivada	Cambio relativo en el número de créditos.
tasa_crecimiento_monto	Derivada	Cambio relativo del monto agregado.

Cuadro 4.3: Características identificadas explícitamente en los archivos disponibles.

La variable binaria `crisis_flag` se construye mediante ocho condiciones heurísticas que, según el documento original, fueron validadas por juicio experto. Los artefactos proporcionados no especifican las ocho reglas, sus umbrales, los perfiles de los expertos ni el procedimiento de aprobación. En consecuencia, la definición de la etiqueta no es completamente reproducible y constituye una limitación central.

También existe un posible riesgo de fuga de información. Las variables `tasa_judicial` y `creditos_judiciales` muestran un poder predictivo elevado; si alguna de las ocho condiciones de `crisis_flag` utiliza información judicial del mismo periodo o posterior, el modelo podría aprender una señal derivada del evento en lugar de anticiparlo. La auditoría apropiada consiste en documentar las reglas, verificar la disponibilidad temporal de cada variable y repetir la evaluación excluyendo las variables potencialmente dependientes de la etiqueta.

4.5.1. Generación de horizontes

La salida considera dieciocho horizontes mensuales. Para una ventana que termina en t , la etiqueta del horizonte h corresponde al estado futuro en $t + h$. CNN y MLP generan un vector de dieciocho probabilidades, mientras que LightGBM entrena un clasificador independiente por horizonte.




Figura 4.3: Representación conceptual de la ventana de entrada y las etiquetas multi-horizonte.

4.6. Algoritmos seleccionados

Se comparan tres familias para representar enfoques distintos sobre los mismos datos tabulares y temporales.

4.6.1. CNN multi-horizonte

La CNN utiliza dos capas convolucionales unidimensionales con 64 y 128 filtros, normalización por lotes, dropout, max pooling, aplanamiento y dos capas densas de 128 y 64 unidades. La capa de salida contiene dieciocho unidades sigmoideas. Se reporta Adam con tasa de aprendizaje 0,001, un máximo de 100 épocas y early stopping con paciencia de 10 épocas. El tamaño de kernel, el porcentaje de dropout, el tamaño de lote, la función de pérdida y la estrategia exacta de ponderación no aparecen en el manuscrito disponible.

4.6.2. MLP multi-horizonte

El MLP contiene capas densas de 256 y 128 unidades, normalización por lotes, dropout y una salida de dieciocho unidades sigmoidales. Se reporta Adam con tasa de aprendizaje 0,001. El número máximo de épocas, la paciencia, el tamaño de lote, la función de pérdida y las tasas de dropout no se documentan de forma completa.

4.6.3. LightGBM multi-horizonte

LightGBM se implementa mediante dieciocho clasificadores independientes, uno por horizonte, siguiendo los principios de gradient boosting [5, 4]. La configuración reportada incluye `num_leaves=31`, `learning_rate=0,05`, `feature_fraction=0,8`, `bagging_fraction=0,8`, `bagging_freq=5` y `scale_pos_weight=5,67`. Se utiliza early stopping después de 50 iteraciones sin mejora.

Elemento	LightGBM	CNN	MLP
Salida	18 modelos binarios independientes	18 salidas sigmoidales	18 salidas sigmoidales
Arquitectura	Árboles potenciados	Conv1D(64), BN, dropout, Conv1D(128), max pooling, densas 128/64	Densas 256/128, BN y dropout
Optimizador	Boosting con <i>learning rate</i> 0,05	Adam, 0,001	Adam, 0,001
Balanceo	<code>scale_pos_weight=5,67</code>	Pesos reportados, detalle no disponible	Pesos reportados, detalle no disponible
Early stopping	50 rondas	Paciencia 10	No documentado
Semillas y repeticiones	No documentadas	No documentadas	No documentadas

Cuadro 4.4: Configuración documentada de los modelos evaluados.

4.7. Hiperparámetros y estrategia de ajuste

Los hiperparámetros de LightGBM se seleccionaron mediante búsqueda manual. No se documentan el espacio explorado, el número de configuraciones ni la regla utilizada para detener la búsqueda. Para CNN y MLP se reportan las arquitecturas principales, pero no un procedimiento equivalente de ajuste. Por ello, la comparación refleja las implementaciones disponibles y no una búsqueda equilibrada de la mejor configuración de cada familia.

El valor `scale_pos_weight=5,67` es consistente con una razón aproximada entre clases negativa y positiva, pero el cálculo exacto debe realizarse únicamente con el conjunto de entrenamiento de cada horizonte. El proyecto no presenta los conteos por horizonte necesarios para verificarlo.

4.8. Protocolo de entrenamiento, validación y prueba

La división temporal utiliza el 70 % más antiguo, correspondiente al periodo 2015–2022, para entrenamiento, y el 30 % más reciente, correspondiente a 2023–2026, para prueba. Esta decisión evita mezclar aleatoriamente observaciones futuras con pasadas.

La versión disponible no identifica un conjunto de validación independiente. Tampoco demuestra si el conjunto de prueba se mantuvo aislado durante la búsqueda manual y el early stopping. Por tanto, los resultados deben interpretarse como una evaluación preliminar. Un protocolo completo debería incluir entrenamiento, validación y prueba temporal; registrar los conteos por horizonte; fijar semillas; repetir las ejecuciones; y preservar el test para una única evaluación final.




Figura 4.4: Flujo de entrenamiento, registro y selección implementado en el prototipo.

4.9. Métricas y criterio de selección

Los modelos se evalúan mediante accuracy, precision, recall, F1-score y AUC-ROC. El criterio principal implementado para seleccionar el modelo es el AUC-ROC promedio de los dieciocho horizontes registrado en MLflow. En la discusión se examina también el recall,

debido a que un AUC moderado puede coexistir con una baja detección de crisis bajo el umbral utilizado.

No se reportan intervalos de confianza, pruebas estadísticas, PR-AUC ni calibración. En consecuencia, no se utiliza el término *significativo* en sentido estadístico y no se atribuyen diferencias observadas a una causa específica.

4.10. Pipeline MLOps y registro de experimentos

El DAG de entrenamiento se programa para el primer día de cada mes a las 03:00. Sus tareas cubren extracción, carga, preparación, entrenamiento, cálculo de métricas y registro de artefactos. La versión original ejecuta los modelos en paralelo; este diseño puede aumentar la utilización de recursos, pero no se dispone de mediciones de CPU, memoria o temperatura que permitan cuantificar el impacto.

MLflow almacena los resultados de las ejecuciones y permite recuperar el modelo seleccionado. La tesis no documenta un esquema de aprobación humana verificable, reglas de promoción, hash de datos, commit del código ni política de reversión. Por ello, el sistema se presenta como prototipo MLOps y no como una operación regulada en producción.

4.11. Puesta en producción e inferencia

El DAG de inferencia se ejecuta diariamente a las 06:00. Actualiza la vista materializada, carga el modelo registrado, genera probabilidades para los dieciocho horizontes y realiza *upsert* en `fact_predicciones_mensual`. La Figura 4.5 resume el flujo.




Figura 4.5: Flujo de inferencia y actualización analítica.

La tabla de predicciones contiene probabilidades prob_h01–prob_h18, predicciones

binarias `pred_h01`–`pred_h18` con umbral 0,5, medidas resumen y metadatos de ejecución. El proyecto no presenta evaluación de calibración ni optimización del umbral, por lo que el valor 0,5 se considera una decisión de implementación y no un umbral de negocio validado.

4.12. Diseño del datamart y dashboards

El datamart adopta un esquema estrella con `dim_tiempo`, `dim_riesgo`, `dim_sector` y `dim_sucursal`. Las tablas `fact_creditos_mensual` y `fact_predicciones_mensual` almacenan los agregados históricos y las predicciones. Apache Superset consulta estas tablas para construir siete dashboards: histórico de créditos, análisis dimensional, KPIs generales, predicciones por sucursal, predicciones por sector, evolución temporal y bloques de mayor riesgo. Las capturas y la descripción funcional se presentan en los resultados y en el Apéndice, porque constituyen evidencia de la implementación y no del procedimiento metodológico.




Figura 4.6: Esquema conceptual del datamart analítico.

Capítulo 5

Resultados y discusión

Este capítulo presenta los resultados disponibles y los interpreta en relación con los objetivos. Las afirmaciones se limitan a la configuración evaluada. No se declara significancia estadística porque no se reportan repeticiones ni pruebas de hipótesis.

5.1. Caracterización del conjunto de datos

El conjunto consolidado contiene 20.025 registros a nivel bloque-mes y veintiuna características numéricas. La distribución reportada para la variable objetivo es de 17.010 registros sin crisis (85 %) y 3.015 con crisis (15 %). Esta proporción evidencia un desbalance que hace necesario interpretar la exactitud junto con precision, recall y AUC-ROC.

Clase	Registros	Proporción
No crisis	17.010	85 %
Crisis	3.015	15 %
Total	20.025	100 %

Cuadro 5.1: Distribución global de la variable objetivo.

El número de registros agregados no equivale directamente al número de secuencias utilizadas para entrenar los modelos. La versión original menciona 293 muestras de entrenamiento, pero no incluye los conteos necesarios para reproducir la transformación. Por esta razón, la muestra efectiva y la distribución por horizonte deben verificarse antes de considerar definitiva la evaluación.

5.2. Resultados del procesamiento y análisis exploratorio

5.2.1. Correlaciones

La Figura 5.1 muestra correlaciones elevadas entre algunas variables. En particular, el documento original reporta una relación cercana a 1 entre `num_credits` y `credits_cerrados`, así como entre `monto_total` y `monto_promedio`. Estas relaciones pueden generar redundancia, aunque la multicolinealidad no afecta de la misma manera a árboles y redes neuronales. Los valores de VIF mencionados en la versión original no se conservan como evidencia principal porque no se documenta su cálculo completo.




Figura 5.1: Matriz de correlaciones de las características del conjunto analítico.

5.2.2. Poder predictivo individual

El análisis univariado identifica `tasa_judicial` y `credits_judiciales` como las variables con mayor AUC-ROC individual. La Tabla 5.2 presenta los valores reportados. Las

categorías cualitativas “muy alto” y “medio” se eliminan porque la tesis no define umbrales formales para ellas.

Variable	AUC-ROC individual
tasa_judicial	0,926
creditos_judiciales	0,912
saldo_promedio	0,666
monto_total	0,651

Cuadro 5.2: Variables con mayor AUC-ROC individual según el análisis exploratorio.




Figura 5.2: AUC-ROC individual reportada para las características analizadas.

Estos resultados requieren una lectura prudente. Una alta capacidad discriminativa de variables judiciales puede ser válida si la información está disponible antes del horizonte predicho; también puede revelar fuga de información si esas variables forman parte de la etiqueta o reflejan un evento contemporáneo. Sin las ocho reglas de `crisis_flag`, no es posible distinguir entre ambas explicaciones.

5.2.3. Evolución temporal de la clase positiva

La Figura 5.3 muestra cambios en la proporción de crisis a lo largo del periodo. El documento original describe niveles de 5–7 % antes de 2020, un pico de 20–24 % durante 2020–2021 y una estabilización cercana al 15 % posteriormente. Esta coincidencia temporal

no permite atribuir el cambio a la pandemia sin un análisis causal y fuentes externas; por ello, se reporta únicamente como patrón descriptivo.




Figura 5.3: Evolución temporal de la proporción de bloques etiquetados como crisis.

5.3. Resultados de los modelos

5.3.1. LightGBM

LightGBM produjo resultados para los dieciocho horizontes. La Tabla 5.3 reproduce los horizontes documentados y el promedio reportado. El AUC-ROC disminuye de 0,874 a un mes a 0,702 a dieciocho meses. El recall se reduce de 0,542 a 0,034, lo que indica que, con el umbral utilizado, el modelo identifica muy pocos casos positivos en el horizonte más largo.

Horizonte	Accuracy	Precision	Recall	AUC-ROC
1 mes	0,937	0,694	0,542	0,874
3 meses	0,942	0,837	0,512	0,869
6 meses	0,927	0,632	0,525	0,838
12 meses	0,906	0,447	0,369	0,765
18 meses	0,897	0,500	0,034	0,702
Promedio reportado	0,917	0,571	0,391	0,800

Cuadro 5.3: Métricas reportadas para LightGBM en horizontes seleccionados.




Figura 5.4: Evolución de las métricas de LightGBM a través de los horizontes evaluados.

La Figura 5.5 muestra la importancia interna de las características. La predominancia de variables judiciales coincide con el análisis univariado, pero no demuestra causalidad ni garantiza que la señal esté disponible antes de la predicción.




Figura 5.5: Importancia de características calculada por LightGBM.

5.3.2. CNN

La implementación de CNN reportó un AUC-ROC de 0,50 y una pérdida que se mantuvo alrededor de 12,5. También se observaron oscilaciones extremas en accuracy, precision y recall, compatibles con predicciones concentradas en una sola clase. Un AUC-ROC de 0,50 indica ausencia de discriminación en la evaluación; por sí solo no demuestra una causa ni permite concluir que todas las CNN sean inadecuadas para este problema.




Figura 5.6: Pérdida reportada durante el entrenamiento de la CNN.

La magnitud de la pérdida requiere revisar la función utilizada, las dimensiones de etiquetas y salidas, el escalado, los pesos de clase y el tamaño de lote. Estos elementos no están documentados con suficiente detalle para identificar el origen del comportamiento.

5.3.3. MLP

El MLP reportó una pérdida cercana a 12,47, AUC-ROC de 0,50 y predicciones concentradas en la clase no crisis, con precision y recall iguales a cero para la clase positiva. Este resultado describe el comportamiento de la implementación evaluada, pero no identifica sus causas. Entre los factores plausibles se encuentran el desbalance, el número de secuencias, la configuración de la pérdida, los pesos de muestra, el escalado y el ajuste de hiperparámetros.

5.4. Comparación global

La Tabla 5.4 corrige la inconsistencia de la tabla original: los valores de LightGBM son promedios de horizontes y no corresponden exclusivamente al horizonte de un mes. CNN y MLP se presentan con los valores globales reportados, por lo que la comparación no reemplaza una tabla completa por modelo y horizonte.

Modelo	Accuracy	Precision	Recall	AUC-ROC
LightGBM, promedio de horizontes	0,917	0,571	0,391	0,800
CNN, resultado global reportado	0,090	0,090	1,000	0,500
MLP, resultado global reportado	0,910	0,000	0,000	0,500

Cuadro 5.4: Comparación de los resultados reportados. Las unidades de resumen no son completamente equivalentes entre modelos.

Bajo el criterio implementado de AUC-ROC promedio, LightGBM fue seleccionado para el flujo de inferencia. La selección es coherente con los resultados disponibles, pero debe considerarse provisional por cuatro razones: no se documentan repeticiones; no existe una prueba estadística; el ajuste de hiperparámetros no fue equivalente; y las salidas de LightGBM y de las redes se estructuran de manera diferente.

5.5. Ejecución automatizada y registro

El pipeline de Airflow produjo una ejecución posterior con accuracy promedio de 0,878 y AUC-ROC promedio de 0,846, mientras que el entrenamiento inicial reportó 0,917 y 0,800, respectivamente.

Métrica	Ejecución inicial	Ejecución automatizada
Accuracy promedio	0,917	0,878
AUC-ROC promedio	0,800	0,846

Cuadro 5.5: Resultados reportados para las ejecuciones inicial y automatizada.

La diferencia no debe atribuirse a Apache Airflow. Airflow orquesta el procedimiento, pero no mejora por sí mismo un modelo. La variación puede relacionarse con cambios en datos, particiones, configuración o aleatoriedad; estos factores no quedaron documentados. El resultado sí evidencia que el flujo automatizado fue capaz de ejecutar el entrenamiento y registrar una salida.




Figura 5.7: Vista del DAG de entrenamiento implementado en Apache Airflow.




Figura 5.8: Vista del DAG de inferencia implementado en Apache Airflow.

5.6. Datamart y dashboards

La implementación almacena las predicciones en `fact_predicciones_mensual` y las expone mediante Apache Superset. Las Figuras 5.9–5.11 muestran ejemplos de los dashboards construidos.






Figura 5.9: Dashboard para el análisis histórico de la cartera crediticia.



(a) Indicadores generales.

(b) Predicciones por sucursal.

Figura 5.10: Ejemplos de dashboards para indicadores y segmentación geográfica.



(a) Predicciones por sector.

(b) Bloques con mayor riesgo.

Figura 5.11: Dashboards para segmentación sectorial y priorización de bloques.

Las capturas demuestran que las vistas fueron implementadas, pero no constituyen una validación de utilidad. No se reportan tiempos de actualización, pruebas de integridad, disponibilidad, errores, número de usuarios ni estudios de usabilidad. La afirmación defendible es que el prototipo integra visualmente datos históricos y predicciones; su impacto en decisiones y mora requiere evaluación posterior.

5.7. Discusión

Los resultados disponibles favorecen a LightGBM en el escenario evaluado, lo que es compatible con trabajos que reportan buen desempeño de modelos de boosting en datos tabulares [8, 9]. Sin embargo, la literatura también incluye escenarios en los que un MLP supera a los árboles [11]. Por ello, las diferencias observadas deben atribuirse al conjunto de datos y a las configuraciones utilizadas, no a una propiedad universal de los algoritmos.

El deterioro con el horizonte es visible en AUC-ROC y, con mayor intensidad, en recall. La cifra de recall igual a 0,034 a dieciocho meses significa que la clasificación binaria bajo el umbral 0,5 recupera una fracción muy pequeña de las crisis. Aunque el AUC-ROC se mantiene por encima de 0,70, no es suficiente para calificar estas predicciones como confiables o útiles sin análisis de umbral, calibración y costos de error.

El bajo rendimiento de CNN y MLP puede asociarse con la muestra secuencial reducida, el desbalance, las secuencias de seis meses y la configuración de entrenamiento. No obstante, no se realizaron ablaciones que modifiquen sistemáticamente estos factores. En consecuencia, se consideran explicaciones plausibles y no causas demostradas.

La principal fortaleza del trabajo es la integración de componentes. Su principal debili-

dad es la trazabilidad experimental. La ausencia de las reglas de etiqueta, de un diccionario completo, de un conjunto de validación documentado y de repeticiones limita la reproducibilidad y la generalización. Estas limitaciones deben resolverse antes de utilizar el sistema como soporte para decisiones de crédito en producción.

Capítulo 6

Conclusiones

6.1. Síntesis de los principales hallazgos

La investigación permitió implementar un prototipo que integra procesamiento de datos crediticios, entrenamiento automatizado, registro de experimentos, almacenamiento analítico y visualización. En la evaluación presentada, LightGBM mostró una mayor capacidad discriminativa que las implementaciones de CNN y MLP. El rendimiento de LightGBM disminuyó conforme aumentó el horizonte, y el recall presentó una reducción especialmente relevante en los plazos largos.

6.2. Respuesta al objetivo general

El objetivo general se alcanzó en lo relativo al diseño y la integración técnica de los componentes principales. Se implementaron flujos de entrenamiento e inferencia en Apache Airflow, registro en MLflow, almacenamiento en PostgreSQL y dashboards en Apache Superset. El resultado debe presentarse como un prototipo funcional. La evidencia disponible no permite concluir que la plataforma controle la mora, reduzca pérdidas o haya sido validada para apoyar decisiones en un entorno productivo.

6.3. Respuesta a los objetivos específicos

Respecto al primer objetivo, se identificaron factores plausibles asociados con el comportamiento de las redes neuronales: una muestra secuencial reportada como reducida,

desbalance de clases, ventanas de seis meses y documentación incompleta de la configuración. No se realizaron experimentos de ablación, por lo que estos factores no pueden declararse causas demostradas.

En relación con el segundo objetivo, LightGBM alcanzó el mayor AUC-ROC bajo las configuraciones disponibles. Esta comparación no demuestra que los modelos basados en árboles sean superiores en todos los conjuntos tabulares, porque no se documentó una búsqueda equivalente de hiperparámetros ni repeticiones para cada familia.

Para el tercer objetivo, se observó una disminución del rendimiento de LightGBM con el horizonte. El AUC-ROC pasó de 0,874 a un mes a 0,702 a dieciocho meses, mientras que el recall descendió de 0,542 a 0,034. Por tanto, los horizontes largos deben interpretarse con cautela y no pueden considerarse operativamente útiles sin calibración, selección de umbral y análisis de costos de error.

El cuarto objetivo se cumplió como implementación técnica. El datamart integra dimensiones de tiempo, riesgo, sector y sucursal, y los dashboards permiten consultar información histórica y predicciones. No se evaluó la utilidad con usuarios, la latencia ni el impacto sobre decisiones, por lo que esas dimensiones permanecen pendientes.

6.4. Contribuciones

La primera contribución es una arquitectura de extremo a extremo que enlaza ETL, modelado, MLOps, datamart y visualización. La segunda es la comparación de tres enfoques para dieciocho horizontes, junto con el análisis de la degradación temporal. La tercera es la implementación de un esquema estrella y dashboards que integran predicciones y agregados históricos.

Las contribuciones se circunscriben al prototipo y a la institución analizada. No se afirma superioridad universal de LightGBM ni se generalizan los resultados a otras entidades financieras.

6.5. Limitaciones

El estudio presenta limitaciones metodológicas y de generalización. La construcción de las 293 muestras reportadas no es trazable desde los 20.025 bloques-mes; las ocho condiciones de `crisis_flag` no están documentadas; y existe riesgo de fuga de información asociado

con variables judiciales. Tampoco se identifica un conjunto de validación independiente ni se demuestra que el test permaneció aislado durante el ajuste.

La evaluación se basa en ejecuciones sin repeticiones, intervalos de confianza o pruebas estadísticas. No se reportan PR-AUC, calibración, curvas por umbral ni análisis detallado de falsos negativos. La comparación entre modelos utiliza arquitecturas de salida y procedimientos de ajuste distintos. Además, el estudio se realizó en una sola institución y no incluye validación externa.

Desde la perspectiva operativa, las capturas demuestran la implementación de los flujos y dashboards, pero no se presentan pruebas de rendimiento, disponibilidad, recuperación ante fallos, integridad de datos o usabilidad. Estas limitaciones impiden considerar el prototipo como un sistema productivo validado.

6.6. Trabajo futuro

El trabajo futuro debe priorizar la reproducibilidad. Se requiere publicar un diccionario completo de las veintiuna variables, documentar las ocho reglas de crisis, registrar conteos por etapa y horizonte, y versionar datos, código, entornos y semillas. También es necesario repetir la evaluación excluyendo variables potencialmente asociadas con la etiqueta.

La comparación de modelos debe utilizar una división temporal de entrenamiento, validación y prueba; presupuestos de ajuste equivalentes; múltiples semillas; intervalos de confianza; PR-AUC; calibración; y selección de umbrales basada en costos. Para analizar las redes neuronales, se recomienda realizar ablaciones sobre longitud de ventana, balanceo, pérdida, escalado y arquitectura.

Finalmente, el prototipo debe evaluarse con datos de otras instituciones y mediante pruebas funcionales y de usabilidad. Solo después de estas validaciones sería posible estimar su contribución a procesos de decisión, alertas o gestión de cartera.

Bibliografía

- [1] G. H. N. Laursen and J. Thorlund, *Business Analytics for Managers: Taking Business Intelligence Beyond Reporting*, 2nd ed. Wiley, 2017.
- [2] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Wiley, 2013.
- [3] H. He and E. A. Garcia, “Learning from imbalanced data,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
- [4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “Lightgbm: A highly efficient gradient boosting decision tree,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [5] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [6] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [7] T. Fawcett, “An introduction to roc analysis,” *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.
- [8] C. Yu, Y. Jin, Q. Xing, Y. Zhang, S. Guo, and S. Meng, “Advanced user credit risk prediction model using lightgbm, xgboost and tabnet with smoteenn,” *arXiv preprint arXiv:2408.03497*, 2024. [Online]. Available: <https://arxiv.org/abs/2408.03497>
- [9] M. Zhu, Y. Zhang, Y. Gong, K. Xing, X. Yan, and J. Song, “Ensemble methodology: Innovations in credit default prediction using lightgbm, xgboost, and localensemble,” *arXiv preprint arXiv:2402.17979*, 2024. [Online]. Available: <https://arxiv.org/abs/2402.17979>

- [10] S. Yang, Z. Huang, W. Xiao, and X. Shen, “Interpretable credit default prediction with ensemble learning and shap,” *arXiv preprint arXiv:2505.20815*, 2025. [Online]. Available: <https://arxiv.org/abs/2505.20815>
- [11] A. Arram, M. Ayob, M. A. A. Albadr, A. Sulaiman, and D. Albashish, “Credit card score prediction using machine learning models: A new dataset,” *arXiv preprint arXiv:2310.02956*, 2023. [Online]. Available: <https://arxiv.org/abs/2310.02956>
- [12] Shreya and H. Pathak, “Explainable artificial intelligence credit risk assessment using machine learning,” *arXiv preprint arXiv:2506.19383*, 2025. [Online]. Available: <https://arxiv.org/abs/2506.19383>
- [13] S. Nayak, “Calibrated credit intelligence: Shift-robust and fair risk scoring with bayesian uncertainty and gradient boosting,” *arXiv preprint arXiv:2603.06733*, 2026. [Online]. Available: <https://arxiv.org/abs/2603.06733>
- [14] S. AlMarri, K. Juhasz, M. Ravaut, G. Marti, H. Al Ahbabi, and I. Elfadel, “Interpreting llms as credit risk classifiers: Do their feature explanations align with classical ml?” *arXiv preprint arXiv:2510.25701*, 2025. [Online]. Available: <https://arxiv.org/abs/2510.25701>
- [15] J. Marcos-Mercadé, U. Lopez-Novoa, and M. Egaña Aranguren, “An empirical evaluation of modern mlops frameworks,” *arXiv preprint arXiv:2601.20415*, 2026. [Online]. Available: <https://arxiv.org/abs/2601.20415>
- [16] Z. Micallef, K. Rajenthiram, and I. Gerostathopoulos, “A systematic review of mlops tools: Tool adoption, lifecycle coverage, and critical insights,” *arXiv preprint arXiv:2604.16371*, 2026. [Online]. Available: <https://arxiv.org/abs/2604.16371>
- [17] F. Zampetti, F. Stocchetti, F. Razzano, D. A. Tamburri, and M. Di Penta, “How are mlops frameworks used in open source projects? an empirical characterization,” *arXiv preprint arXiv:2601.18591*, 2026. [Online]. Available: <https://arxiv.org/abs/2601.18591>
- [18] S. Amed, C. Yu Hang, and S. Banerjee, “Pdx – adaptive credit risk forecasting model in digital lending using machine learning operations,” *arXiv preprint arXiv:2512.22305*, 2025. [Online]. Available: <https://arxiv.org/abs/2512.22305>

- [19] R. Hossain, M. M. Khan, L. A. Amin, D. Parikh, F. Afroz, and B. S. Ahmed, “Ethical and explainable ai in reusable mlops pipelines,” *arXiv preprint arXiv:2603.03341*, 2026. [Online]. Available: <https://arxiv.org/abs/2603.03341>
- [20] The PostgreSQL Global Development Group, “Postgresql 15 documentation,” <https://www.postgresql.org/docs/15/>, 2024, accessed: 2024-01-15.
- [21] Apache Software Foundation, “Apache airflow documentation,” <https://airflow.apache.org/docs/>, 2024, accessed: 2024-01-15.
- [22] MLflow Contributors, “Mlflow documentation,” <https://mlflow.org/docs/latest/>, 2024, accessed: 2024-01-15.
- [23] Apache Software Foundation, “Apache superset documentation,” <https://superset.apache.org/docs/>, 2024, accessed: 2024-01-15.

Apéndices

Apéndice A

Repositorios y evidencia complementaria

A.1. Repositorios del proyecto

Los recursos técnicos proporcionados se encuentran en los siguientes repositorios:

- Contenedores Docker: <https://github.com/YahayUniversidad/IADegreeThesis/tree/main/Contenedores>
- Desarrollo de la solución: <https://github.com/YahayUniversidad/IADegreeThesis/tree/main/Desarrollo>
- Documentación relacionada: <https://github.com/YahayUniversidad/IADegreeThesis/tree/main/DocumentosBase>

Para una reproducción verificable, la versión final debe asociar los enlaces con un commit o etiqueta estable e indicar qué script genera cada tabla, figura y modelo.

A.2. Capturas adicionales de dashboards




Figura A.1: Vista complementaria del dashboard histórico de créditos.




Figura A.2: Dashboard de análisis dimensional por riesgo y sector.




Figura A.3: Dashboard de evolución temporal de predicciones.

A.3. Información mínima para reproducibilidad

La documentación final del repositorio debería incluir: definición de las ocho reglas de `crisis_flag`; diccionario de las veintiuna características; conteos de registros y secuencias por etapa; particiones temporales; configuración completa de CNN, MLP y LightGBM; semillas; versiones de librerías; especificaciones de hardware; hashes o versiones de datos; métricas por horizonte; y procedimientos para ejecutar los DAG y reconstruir los dashboards.