

Degree_project_Omar_Vélez

ID : 5724d1dbeb0ca675a42e65e884bb849da3bc60d4



Nombre del fichero : Degree_project_Omar_Vélez.txt	Depositante : JUAN PABLO ASTUDILLO LEON
Tamaño del archivo original : 2,69 MB	Fecha de depósito : 31 de julio de 2026
Número de palabras : 14.447	Tipo de carga : interface
	fecha de fin de análisis : 31 de julio de 2026

 Resumen (sección 1/3)

Localización de los textos sospechosos en el documento :



Incluido en el porcentaje de textos sospechosos :



Similitudes

Pasajes con similitudes a fuentes encontradas en diferentes colecciones.



2%



Detección de IA

Textos estilísticamente próximos a un texto generado por una IA.
Este índice es un indicador y no una prueba. Comprueba con el autor si domina los conocimientos mencionados en el documento.



35%



Idiomas no reconocidos

Pasajes en los que parte del vocabulario utilizado no forma parte del diccionario de la lengua.
Puede tratarse de un intento del autor de modificar el texto para evitar ser detectado.




0%

No incluido en el porcentaje de textos sospechosos :



Textos entre comillas

Pasajes entre comillas, a menudo indicativos de una cita.



1%



Similitudes

2%

Pasajes con similitudes a fuentes encontradas en diferentes colecciones.

Fuente principal detectada

N°		Descripciones	Similitudes	Ubicaciones
1		Tesis_de_Posgrados-2 #aab836 Viene de de mi grupo	2%	
2		Proyecto_de_Titulación_Pérez #3c7288 Viene de de mi grupo	1%	
3		Degree_project_Diego_Altamirano #0bd19d Viene de de mi grupo	1%	
4		Magaly_Aguiar_Yachay_Tech_ECMC #876e66 Viene de de mi grupo	1%	

Fuente con similitudes fortuitas

N°		Descripciones	Similitudes	Ubicaciones
5		Documento de otro usuario #7376ff Viene de de otro grupo	<1%	
6		Desarrollo de una aplicación web para la compresión de imágenes. www.dspace.uce.edu.ec/handle/25000/6618 ↗	<1%	
7		Documento de otro usuario #466c33 Viene de de otro grupo	<1%	
8		Predicción de temperaturas extremas utilizando técnicas de... hdl.handle.net/10017/63424 ↗	<1%	
9		Desarrollo de una librería MLOps: versionamiento, trazabilidad y... repository.urosario.edu.co/handle/10336/47639 ↗	<1%	
10		Influencia de videos tutoriales en el proceso enseñanza -... www.dspace.uce.edu.ec/handle/25000/15334 ↗	<1%	

Fuente mencionada (sin similitudes detectadas)

N°		Descripciones
1		https://mlflow.org/docs/latest/
2		https://github.com/YahayUniversidad/IADegreeThesis/tree/main/Contenedores
3		https://github.com/YahayUniversidad/IADegreeThesis/tree/main/Desarrollo

N°	Descripciones
4	 https://github.com/YahayUniversidad/IADegreeThesis/tree/main/DocumentosBase



1,2



UNIVERSIDAD DE INVESTIGACIÓN DE TECNOLOGÍA EXPERIMENTAL YACHAY

Escuela de Ciencias Matemáticas y Computacionales

TITULO

Sistema Integrado de Inteligencia de Negocio para la Predicción de Crisis Crediticias mediante las técnicas de análisis de Inteligencia artificial y de negocio

Autor:

Omar Antonio Vélez Bayas

Tutor:

Juan Pablo Astudillo León, Ph.D.

Urcuquí, Julio 2026

Autoría

Yo, **Omar Antonio Vélez Bayas**, con cédula de identidad 0102581709, declaro que las ideas, juicios, valoraciones, interpretaciones, consultas bibliográficas, definiciones y conceptualizaciones expuestas en el presente trabajo; así cómo, los procedimientos y herramientas utilizadas en la investigación, son de absoluta responsabilidad de el autor del trabajo de integración curricular. Asimismo, me acojo a los reglamentos internos de la Universidad de Investigación de Tecnología Experimental Yachay.

Urcuquí, Julio 2026.

Omar Antonio Vélez Bayas

CI: 0102581709

Autorización de publicación

Yo, **Omar Antonio Vélez Bayas**, con cédula de identidad 0102581709, cedo a la Universidad de Investigación de Tecnología Experimental Yachay, los derechos de publicación de la presente obra, sin que deba haber un reconocimiento económico por este concepto.

Declaro además que el texto del presente trabajo de titulación no podrá ser cedido a ninguna empresa editorial para su publicación u otros fines, sin contar previamente con la autorización escrita de la Universidad.

1,2



1,2



Asimismo, autorizo a la Universidad que realice la digitalización y publicación de este trabajo de integración curricular en el repositorio virtual, de conformidad a lo dispuesto en el Art. 144 de la Ley Orgánica de Educación

Urcuquí, Julio 2026.

Omar Antonio Vélez Bayas

CI: 0102581709

Dedicatoria

Dedicado a mis seres queridos: los amo y gracias por tratar de comprender *'eso que haces con la computadora'*.

OmarV

Agradecimientos

Al personal de la maestría, por su constante apoyo administrativo.

Al cuerpo docente, por compartir su conocimiento y experiencia.

A mi director de tesis, por su valiosa guía, paciencia y dirección en este proyecto.

A mis compañeros de trabajo, por cubrirme las horas y darme el espacio para continuar con mis estudios superiores.

Omar Antonio Vélez Bayas

Resumen

Esta tesis presenta el diseño e implementación de un prototipo de inteligencia de negocio orientado al riesgo crediticio, que integra procesamiento de datos, predicción multi-horizonte, gestión de experimentos y visualización analítica en una institución de la economía social y solidaria del Ecuador.

El prototipo presenta un flujo integrado y automatizado del procesamiento de datos y la actualización de los modelos predictivos, consolida la información en un datamart, y proporciona visualizaciones interactivas, respaldado por el registro sistemático de experimentos que asegura la trazabilidad y observabilidad del sistema.

La evaluación comparativa entre modelos de gradient boosting, redes neuronales con-

volucionales y perceptrones multicapa muestra que, bajo la configuración estudiada, los primeros presentan mejor capacidad discriminativa, aunque su rendimiento se degrada en horizontes temporales extendidos.

La contribución principal es la integración técnica de un flujo de extremo a extremo—procesamiento modelado, registro, almacenamiento analítico y visualización—que habilita el análisis crediticio y la observabilidad de experimentos. El prototipo es funcional y reproducible a entornos productivos.

Palabras clave:

Riesgo crediticio; predicción multi-horizonte; LightGBM; redes neuronales; inteligencia de negocio; MLOps; datamart; Apache Airflow.

Abstract

This thesis presents the design and implementation of a credit risk-oriented business intelligence prototype that integrates data processing, multi-horizon prediction, experiment management, and analytical visualization within a social and solidarity economy institution in Ecuador.

The prototype features an integrated and automated workflow for data processing and predictive model updates, consolidates information into a datamart, and provides interactive visualizations, backed by a systematic experiment registry that ensures system traceability and observability.

The comparative evaluation among gradient boosting models, convolutional neural networks, and multilayer perceptrons shows that, under the studied configuration, the former exhibit superior discriminative capacity, although their performance degrades over extended time horizons.

The main contribution is an end-to-end pipeline—integrating processing, modeling, tracking, storage, and visualization—that enables credit analysis and experiment observability through a functional, production-ready prototype.

Keywords:

credit risk; multi-horizon prediction; LightGBM; neural networks; business intelligence; MLOps; data mart; Apache Airflow.

Contents

Contents

List of Tables

List of Figures

1 Introducción

1.1 Contexto	
1.2 Motivación	
1.3 Planteamiento del problema	
1.4 Pregunta de investigación	
1.5 Hipótesis	
1.6 Objetivo general	
1.7 Objetivos específicos	
1.8 Contribuciones	
1.9 Organización del documento	

2 Marco Teórico

2.1 Riesgo crediticio y clasificación binaria	
2.2 Inteligencia de negocio, data warehouse y datamart	
2.3 Predicción multi-horizonte	
2.4 Clases desbalanceadas	
2.5 Modelos evaluados	
2.5.1 LightGBM	
2.5.2 Red neuronal convolucional	
8 9 9 10 11 11 11 12 13 13 14 14 14 15 16 17 18 20 21 21 22 23 25 26 29 29 29 30 31 32	
School of Mathematical and Computational Sciences	
Yachay Tech University	
2.5.3 Perceptrón multicapa	
2.6 Validación temporal y fuga de información	
2.7 Métricas de evaluación	

2.8 MLOps y observabilidad

3 Estado del Arte

3.1 Estrategia de búsqueda

3.2 Predicción de riesgo crediticio

3.3 MLOps aplicado al riesgo crediticio

3.4 Síntesis comparativa

3.5 Brechas y posicionamiento del trabajo

4 Metodología

4.1 Diseño de la investigación

4.2 Diseño y arquitectura del sistema

4.3 Síntesis comparativa

4.4 Fuentes de datos y unidad de análisis

4.5 Procesamiento y preparación de datos

4.6 Ingeniería de características y variable objetivo

4.6.1 Generación de horizontes

4.7 Algoritmos seleccionados

4.7.1 CNN multi-horizonte

4.7.2 MLP multi-horizonte

4.7.3 LightGBM multi-horizonte

4.8 Hiperparámetros y estrategia de ajuste

4.9 Protocolo de entrenamiento, validación y prueba

4.10 Métricas y criterio de selección

4.11 Pipeline MLOps y registro de experimentos

4.12 Puesta en producción e inferencia

4.13 Diseño del datamart y dashboards

4.14 Recursos computacionales

4.15 Versionado y reproducibilidad

Master in Artificial Intelligence Final Project

33 33 34 34 35 36 36 36 38 39 40 40 41 42 **44** 44 44 45 45 46 46 47 **49 52 53** 53 53 54

School of Mathematical and Computational Sciences

Yachay Tech University

5 Resultados

5.1 Caracterización del conjunto de datos	
5.2 Resultados del procesamiento y análisis exploratorio	
5.2.1 Correlaciones	
5.2.2 Poder predictivo individual	
5.2.3 Evolución temporal de la clase positiva	
5.3 Resultados de los modelos	
5.3.1 LightGBM	
5.3.2 CNN	
5.3.3 MLP	
5.4 Comparación global	
5.5 Ejecución automatizada y registro	
5.6 Datamart y dashboards	
5.7 Discusión	

6 Conclusiones

6.1 Síntesis de los principales hallazgos	
6.2 Respuesta al objetivo general	
6.3 Respuesta a los objetivos específicos	
6.4 Contribuciones	
6.5 Aspectos éticos	
6.6 Limitaciones	
6.7 Trabajo futuro	

Bibliography

Appendices

A Repositorios y evidencia complementaria

A.1 Capturas adicionales de dashboards	
A.2 Información mínima para reproducibilidad	
A.3 Esquema estrella del datamart	

A.3.1 Tabla de hechos: fact_creditos_mensual 55

A.3.2 Tabla de hechos: fact_predicciones 56

Master in Artificial Intelligence Final Project

13 16 16 17 18 24 26 32 33 35 37 40 40

List of Tables

3.1 Síntesis de trabajos relacionados según la información reportada en la tesis.

4.1 Componentes del sistema y tecnologías utilizadas.

4.2 Fuentes de datos utilizadas en el proceso ETL.

4.3 Trazabilidad de datos verificada mediante consultas directas a PostgreSQL
y MLflow. Conteos extraídos de la ejecución del 29 de julio de 2026.

4.4 Diccionario completo de las 21 características extraído del código fuente
(queries.py y pipelines de modelos).

4.5 Configuración completa documentada de los modelos evaluados, extraída
del código fuente.

4.6 Distribución real de los conjuntos de datos extraída del código.

4.7 Recursos computacionales y versiones de software. Corresponde a un pc de
uso doméstico

5.1 Distribución global de la variable objetivo.

5.2 Variables con mayor AUC-ROC individual según el análisis exploratorio. .

5.3 Métricas reportadas para LightGBM en horizontes seleccionados.

5.4 Comparación de los resultados reportados. Las unidades de resumen no son
completamente equivalentes entre modelos.

5.5 Resultados reportados para las ejecuciones inicial y automatizada.

15 19 20 25 27 28 30 31

List of Figures

4.1 Diagrama de Arquitectura Propuesta

4.2 Diagrama de flujo de la definición de crisis_flag. Cada condición evalúa

un umbral y asigna un peso; si la suma total supera 5, el bloque se etiqueta como crisis.

4.3 Representación conceptual de la ventana de entrada y las etiquetas multi-horizonte. Cada bloque-mes genera una secuencia de 6 meses con 21 características, y 18 etiquetas futuras correspondientes a los horizontes de predicción.

4.4 Comparación de arquitecturas: LightGBM entrena 18 modelos independientes (uno por horizonte), mientras que CNN y MLP son redes únicas con 18 salidas sigmoidales. Todos comparten la misma entrada de 6×21 valores.

4.5 Línea de tiempo de la división temporal de datos. El periodo 2015–2022 se utiliza para entrenamiento y validación, mientras que 2023–2026 se reserva para prueba.

4.6 Flujo de entrenamiento, registro y selección implementado en el prototipo. Los datos pasan por preprocesamiento, generación de secuencias y división temporal antes de entrenar los tres modelos.

4.7 Flujo de inferencia y actualización analítica. El DAG diario actualiza la vista materializada, carga el modelo y genera predicciones para los 18 horizontes.

4.8 Esquema conceptual del datamart analítico. Las dimensiones comparten ambas tablas de hechos: fact_creditos_mensual (datos históricos) y fact_predicciones (salida del modelo).

School of Mathematical and Computational Sciences

Yachay Tech University

5.1 Matriz de correlaciones de Pearson entre las 21 características numéricas del conjunto analítico. Los valores cercanos a 1,0 (color intenso) indican alta correlación positiva. Se observa multicolinealidad severa entre pares como num_creditos–creditos_cerrados y monto_total–monto_promedio. La multicolinealidad afecta de manera diferente a modelos lineales y no lineales. 34

5.2 AUC-ROC calculada individualmente para cada variable predictora, evaluada contra la etiqueta crisis_flag. El AUC-ROC mide la capacidad de cada variable para distinguir entre bloques con y sin crisis, sin considerar

interacciones con otras variables.	35
5.3 Evolución mensual de la proporción de bloques etiquetados como crisis (crisis_flag=1) en el periodo 2015–2026. Se observa un incremento en el periodo 2020–2021 seguido de una estabilización. Esta descripción es úni- camente observacional; no se establece relación causal con eventos externos.	36
5.4 Evolución de las métricas de LightGBM a través de los horizontes evaluados.	37
5.5 Importancia de características reportada por LightGBM (“split importance”). El método cuenta la cantidad de veces que cada variable se utiliza para dividir nodos en todos los árboles del ensemble. Las variables judiciales (tasa_judicial, creditos_judiciales) predominan, lo cual puede reflejar tanto poder predictivo real como dependencia con la etiqueta crisis_flag (ver Sección 4.5).	38
5.6 Curva de pérdida (binary_crossentropy) durante el entrenamiento de la CNN. La línea continua representa la pérdida en entrenamiento y la dis- continua la pérdida en validación (val_loss). La pérdida se estabiliza en valores elevados (~12,5), lo que indica que el modelo no logra aprender una discriminación efectiva entre clases.	39
5.7 Vista del DAG de entrenamiento implementado en Apache Airflow. . . .	41
5.8 Vista del DAG de inferencia implementado en Apache Airflow.	41
5.9 Dashboard para el análisis histórico de la cartera crediticia.	42
A.1 Vista complementaria del dashboard histórico de créditos.	54
A.2 Dashboard de análisis dimensional por riesgo y sector.	54
Master in Artificial Intelligence Final Project	
School of Mathematical and Computational Sciences	
Yachay Tech University	
A.3 Dashboard de evolución temporal de predicciones.	55
A.4 Esquema estrella de la tabla fact_creditos_mensual. Almacena los agre- gados históricos de créditos por bloque-mes, incluyendo la variable objetivo crisis_flag.	55
A.5 Esquema estrella de la tabla fact_predicciones. Almacena las probabili- dades y predicciones binarias para los 18 horizontes temporales, generadas	

por el modelo seleccionado. 56

Master in Artificial Intelligence Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

Master in Artificial Intelligence Final Project

Chapter 1

Introducción

Este capítulo delimita el problema de investigación, presenta la pregunta, la hipótesis; y, establece los objetivos y las contribuciones del trabajo. El alcance se concentra en la integración técnica de datos, modelos predictivos, operaciones de aprendizaje automático y visualización; no se evalúa una reducción explicada de la mora ni se implementan funciones conversacionales o alertas automáticas.

1.1 Contexto

Las instituciones financieras de la economía social y solidaria administran información de créditos, amortizaciones, cartera y recuperación, que puede utilizarse para describir el comportamiento histórico y estimar escenarios futuros. En muchos entornos, los indicadores de morosidad, cartera, recuperación y cartera vencida; se generan a partir de procesos manuales o repositorios separados. Esta fragmentación dificulta la actualización oportuna de los reportes y limita la incorporación de resultados predictivos en los procesos analíticos.

La inteligencia de negocio permite consolidar fuentes operativas en repositorios orientados al análisis y presentar indicadores mediante dashboards. Por su parte, el aprendizaje automático permite estimar probabilidades de incumplimiento a partir de patrones latentes en los datos. La integración de ambas áreas requiere de mecanismos para automatizar el procesamiento, registrar experimentos, versionar modelos y ejecutar inferencias de forma controlada.

1

School of Mathematical and Computational Sciences

Yachay Tech University

En este trabajo, dicha integración se aborda mediante el uso de productos de bases de

datos(PostgreSQL), administradores de flujos de trabajo (Apache Airflow), plataformas del ciclo de vida de experimentos de modelos de inteligencia artificial (MLflow) y visualización de datos (Apache Superset).

1.2 Motivación

El proyecto surge de una necesidad aplicada: reducir la dependencia de tareas manuales para consolidar información crediticia y disponer de una vista unificada que combine datos históricos y predicciones.

La institución contaba con grandes volúmenes de registros operativos, pero no con un flujo integrado que permitiera preparar los datos, comparar modelos, almacenar predicciones multi-horizonte y visualizarlas en un mismo entorno.

La motivación científica se relaciona con dos aspectos. Primero, la comparación entre modelos basados en árboles y redes neuronales bajo datos tabulares, desbalanceados y con secuencias temporales cortas. Segundo, la evaluación del efecto del horizonte temporal sobre el rendimiento predictivo.

La motivación técnica consiste en llevar el modelo seleccionado desde el entorno de experimentación hacia un prototipo reproducible de entrenamiento, inferencia, registro y visualización.

1.3 Planteamiento del problema

El problema se define por la ausencia de integración entre las fuentes crediticias, el entrenamiento de modelos y las herramientas de análisis. Los datos se encuentran en tablas con propósitos operativos distintos; la preparación y actualización de reportes requiere intervención técnica; y las predicciones no están incorporadas de manera sistemática en un datamart que permita analizarlas junto con el histórico de cartera u operaciones de crédito.

Master in Artificial Intelligence

2

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

Esta situación genera tres brechas. La primera es una brecha de datos, porque no existe un flujo único y documentado para integrar, limpiar y agregar la información. La

segunda es una brecha analítica, debido a que los modelos no se comparan dentro de un protocolo multi-horizonte común. La tercera es una brecha operativa, ya que los resultados del modelado no se registran, almacenan y visualizan mediante un proceso automatizado.

1.4 Pregunta de investigación

La investigación aborda la siguiente interrogante:

¿Cómo diseñar e implementar una plataforma de inteligencia de negocio que integre predicción multi-horizonte de riesgo crediticio, un datamart analítico y dashboards interactivos para apoyar la identificación anticipada de escenarios de mora en una institución de la economía social y solidaria?

La pregunta se limita al diseño, la implementación y la evaluación técnica del prototipo.

No implica que la plataforma propuesta baje la mora por sí sola ni que reemplace a los especialistas en el área de recuperación.

1.5 Hipótesis

Bajo el conjunto de datos, la división temporal y las configuraciones experimentales utilizadas, se espera que los modelos de Gradient Boosting alcancen una capacidad de discriminar superior a las implementaciones de redes neuronales convolucionales y perceptrones multicapa para la predicción multi-horizonte de crisis crediticias. Esta hipótesis se evalúa en el contexto específico del estudio y no pretende establecer una superioridad universal de una familia de modelos.

1.6 Objetivo general

Diseñar e implementar un prototipo de inteligencia de negocio crediticia que automatice el procesamiento de datos, compare modelos de deep learning y gradient boosting para

Master in Artificial Intelligence

3

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

predicción multi-horizonte, y conecte el modelo seleccionado con un datamart y dashboards interactivos.

1.7 Objetivos específicos

1. Analizar los factores asociados con el rendimiento observado de las arquitecturas de

inteligencia artificial en el conjunto de datos evaluado.

2. Comparar Gradient Boosting, redes neuronales convolucionales y perceptrones multicapa; mediante las métricas y configuraciones documentadas para el escenario de estudio.

3. Evaluar la variación del rendimiento predictivo conforme aumenta el horizonte temporal.

4. Diseñar e implementar un datamart en esquema estrella y dashboards que integren datos históricos y predicciones.

1.8 Contribuciones

El trabajo aporta una arquitectura de extremo a extremo que conecta ingesta, preparación de datos, entrenamiento, registro de experimentos, inferencia, almacenamiento analítico y visualización.

También presenta una comparación multi-horizonte entre tres familias de modelos y documenta el deterioro de las métricas en horizontes largos.

Finalmente, implementa un datamart con dimensiones de tiempo, riesgo, sector y cursal, junto con dashboards orientados al análisis de cartera y predicciones.

Estas contribuciones deben interpretarse como resultados de un prototipo evaluado en una institución financiera de la economía social y solidara, por lo que la validación con

Master in Artificial Intelligence

4

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

otras entidades, las pruebas de utilidad con usuarios y la auditoría completa de la variable objetivo permanecen como trabajo posterior.

1.9 Organización del documento

El Capítulo 2 presenta los fundamentos de riesgo crediticio, inteligencia de negocio, predicción multi-horizonte, modelos y métricas. El Capítulo 3 resume la literatura utilizada y delimita las brechas abordadas. El Capítulo 4 describe el diseño de la investigación, el procesamiento de datos, los modelos, la configuración experimental y los flujos de las op-



eraciones de aprendizaje automático. El Capítulo 5 presenta y discute los resultados del análisis exploratorio, el entrenamiento, la comparación de modelos y la implementación. El Capítulo 6 sintetiza los hallazgos, responde a los objetivos y expone las limitaciones y líneas de trabajo futuro.

Master in Artificial Intelligence

5

Final Project

Chapter 2

Marco Teórico

Este capítulo presenta los conceptos necesarios para comprender el diseño del sistema y la evaluación experimental. Se priorizan los fundamentos relacionados con el problema y se separan de la descripción operativa de las herramientas, que se desarrolla en la metodología.

2.1 Riesgo crediticio y clasificación binaria

El riesgo crediticio es la probabilidad de incumplir las condiciones acordadas en el pago de créditos. En este estudio, el problema se modela como una clasificación binaria entre "crisis" y "no crisis", aplicando una regla práctica diseñada para este contexto institucional específico, y no una norma regulatoria universal.

En una clasificación binaria, los resultados se organizan en verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos. En riesgo crediticio, los falsos negativos son especialmente relevantes porque representan casos de crisis que el modelo no identifica. Por ello, una exactitud elevada puede resultar engañosa cuando la clase positiva es minoritaria. Lo que es el origen del desbalance.

2.2 Inteligencia de negocio,

data warehouse y datamart

La inteligencia de negocio comprende procesos y tecnologías que transforman datos operativos en información analítica para apoyar decisiones [1]. Un data warehouse integra

6

School of Mathematical and Computational Sciences

Yachay Tech University



información de múltiples fuentes y conserva una estructura orientada al análisis. Un data-mart es un subconjunto enfocado en un dominio específico, como cartera o riesgo crediticio [2].

El esquema estrella organiza una tabla de hechos central y varias tablas de dimensiones.

Las tablas de hechos almacenan medidas cuantitativas y claves foráneas; las dimensiones proporcionan contexto temporal, geográfico o categorizaciones propias del negocio. En esta tesis, las dimensiones corresponden a tiempo, riesgo, sector y sucursal, mientras que las tablas de hechos contienen agregados mensuales y predicciones.

2.3 Predicción multi-horizonte

La predicción multi-horizonte estima el estado futuro de una variable para varios plazos.

Si x_t representa la información disponible hasta el mes t , el objetivo consiste en estimar una probabilidad p_{t+h} para cada horizonte $h \in \{1, \dots, 18\}$. Los horizontes cortos y largos no necesariamente presentan la misma dificultad, porque a mayor distancia en el tiempo aumenta la incertidumbre entre la información actual y el evento futuro.

El proyecto utiliza dos estrategias. CNN (del inglés Convolutional Neural Network) y MLP (del Multilayer Perceptron) producen dieciocho salidas simultáneas, una por horizonte. Y el modelo de Gradient Boosting con la implementación en la biblioteca LightGBM desarrollado por Microsoft que utiliza dieciocho clasificadores independientes. Estas estrategias no son idénticas: la salida conjunta puede compartir representaciones entre horizontes, mientras que los modelos independientes optimizan cada plazo por separado. Esta diferencia debe considerarse al interpretar la comparación.

2.4 Clases desbalanceadas

Un conjunto está desbalanceado cuando una clase contiene muchas más observaciones que la otra. Este escenario puede inducir modelos que predicen casi siempre la clase mayoritaria y, aun así, obtienen una exactitud alta. He y Garcia [3] describen técnicas de

Master in Artificial Intelligence

7

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

reponderación, remuestreo y aprendizaje sensible al costo para enfrentar este problema.



En LightGBM se utilizó el parámetro `scale_pos_weight`. En las redes neuronales se reporta el uso de pesos de muestra, aunque los artefactos disponibles no documentan con suficiente detalle su cálculo ni su aplicación. La comparación debe considerar que cada modelo puede responder de manera distinta al desbalance.

2.5 Modelos evaluados

2.5.1 LightGBM

LightGBM es una implementación eficiente de árboles de decisión potenciados por gradiente [4]. El método construye secuencialmente árboles que corrigen los errores del conjunto anterior, siguiendo el principio general de gradient boosting [5]. Entre sus ventajas para datos tabulares se encuentran el manejo de relaciones no lineales, interacciones entre variables y escalas heterogéneas. Sin embargo, también puede sobreajustar y amplificar fugas de información si una característica contiene señales derivadas directa o indirectamente de la etiqueta.

2.5.2 Red neuronal convolucional

Las redes neuronales convolucionales aprenden filtros locales y representaciones jerárquicas [6]. En series temporales, una convolución unidimensional puede identificar patrones entre meses consecutivos. La utilidad de este enfoque depende del número de secuencias, la longitud temporal, el tratamiento del desbalance, la regularización y la configuración del entrenamiento.

2.5.3 Perceptrón multicapa

El perceptrón multicapa transforma la entrada mediante capas densas y funciones no lineales. Para una ventana de seis meses y veintiuna características, la entrada contiene $6 \times 21 = 126$ valores antes de cualquier transformación adicional. La arquitectura utilizada produce dieciocho probabilidades mediante activación sigmoide. El desempeño depende,

Master in Artificial Intelligence

8

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

entre otros factores, del escalado, la función de pérdida, el tamaño de lote, la tasa de

aprendizaje y la cantidad de muestras.

2.6 Validación temporal y fuga de información

Cuando los datos tienen orden temporal, la división aleatoria puede permitir que información futura influya en el entrenamiento. Una división temporal conserva las observaciones más antiguas para entrenamiento y las más recientes para evaluación. El conjunto de prueba debe permanecer aislado de la selección de hiperparámetros, del early stopping y de la selección del umbral.

La fuga de información ocurre cuando una característica contiene datos que no estarían disponibles en el momento real de la predicción o cuando deriva de la misma regla utilizada para construir la etiqueta. En este estudio, las variables judiciales requieren una auditoría específica porque presentan alta importancia predictiva y podrían estar relacionadas con las condiciones que definen crisis_flag.

2.7 Métricas de evaluación

La exactitud, precisión, recall y F1-score se definen como:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.1)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.2)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.3)$$

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.4)$$

El AUC-ROC (el Área Bajo la Curva y la Característica Operativa del Receptor) resume la capacidad del modelo para ordenar positivos por encima de negativos a través de

Master in Artificial Intelligence

9

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

diferentes umbrales [7]. Un valor cercano a 0,5 indica discriminación equivalente al azar, mientras que un valor mayor no garantiza por sí solo una utilidad operativa. En conjuntos desbalanceados también es recomendable examinar PR-AUC, matrices de confusión, calibración y errores por horizonte. Estas evaluaciones no están disponibles de forma completa en los resultados originales y se reconocen como limitaciones.

2.8 MLOps y observabilidad



MLOps (del inglés Machine Learning Operations) integra prácticas de desarrollo, datos y operación para gestionar el ciclo de vida de modelos [8, 9]. Sculley et al. [10] documentaron la deuda técnica oculta en sistemas ML, mientras que Breck et al. [11] propusieron una rúbrica de pruebas para preparación en producción. En este trabajo, Apache Airflow orquesta tareas; MLflow registra parámetros, métricas y artefactos; PostgreSQL almacena datos y predicciones; y Apache Superset consulta el datamart. La presencia de estas herramientas no demuestra por sí sola reproducibilidad o calidad operativa: también se requieren versiones, semillas, validaciones, manejo de fallos, monitoreo de datos y pruebas funcionales.

Master in Artificial Intelligence

10

Final Project

Chapter 3

Estado del Arte

Este capítulo presenta una revisión de literatura orientada a identificar enfoques de predicción de riesgo crediticio, herramientas MLOps e integración analítica. No se denomina revisión sistemática, porque los artefactos disponibles no incluyen un protocolo completo de selección, conteos de estudios ni un diagrama reproducible de filtrado.

3.1 Estrategia de búsqueda

La búsqueda reportada utilizó Google Scholar, arXiv y bases de datos científicas, con términos relacionados con credit risk prediction, LightGBM, credit scoring, MLOps y data warehouse. El periodo priorizado fue 2021–2026. Debido a que no se conservaron los conteos de resultados, los criterios detallados de inclusión y exclusión ni la fecha exacta de cada consulta, el capítulo debe interpretarse como una revisión narrativa de las fuentes seleccionadas.

3.2 Predicción de riesgo crediticio

Lessmann et al. [12] realizaron un benchmark de 41 clasificadores sobre ocho datasets, mostrando que no existe un algoritmo universalmente superior. Moscato et al. [13] apoyan la discusión sobre comparaciones reproducibles. Gunnarsson et al. [14] compara-

ron MLP, deep belief network y ensembles usando pruebas estadísticas, confirmando que el rendimiento depende del dataset y la configuración. Yang et al. [15] estudiaron ensambles e interpretabilidad mediante SHAP. Estos trabajos muestran el uso frecuente de modelos

11

School of Mathematical and Computational Sciences

Yachay Tech University

basados en árboles para datos tabulares y resaltan la importancia del tratamiento del desbalance y de la interpretabilidad.

La literatura revisada no respalda una superioridad universal de los árboles. Gunnarsson et al. [14], por ejemplo, reportaron que un MLP obtuvo el mejor resultado en su conjunto de datos. **Esta diferencia evidencia que el rendimiento depende del tamaño de muestra**, las variables, la distribución, el protocolo de evaluación y la configuración de cada modelo.

Shreya y Pathak [16] compararon XGBoost, LightGBM y Random Forest con técnicas explicativas. Nayak [17] combinó calibración, restricciones de equidad y gradient boosting. Bussmann et al. [16] presentaron XAI basada en valores de Shapley para gestión del riesgo crediticio, analizando relaciones entre variables en modelos de ML.

3.3 MLOps aplicado al riesgo crediticio

Testi et al. [8] presentaron una taxonomía completa para MLOps. Kreuzberger et al. [9] definieron formalmente MLOps, sus roles, componentes y arquitectura. Sculley et al. [10] documentaron la deuda técnica oculta en sistemas ML, mientras que Breck et al. [11] propusieron una rúbrica de pruebas para preparación en producción. En conjunto, estas fuentes sugieren que la orquestación, el registro de experimentos y el versionado suelen combinarse mediante varias herramientas.

Testi et al. [8] presentaron una taxonomía completa para MLOps, cubriendo desde la definición del problema hasta el monitoreo en producción. Bussmann et al. [16] presentaron XAI basada en valores de Shapley para gestión del riesgo crediticio, mientras que Bucker et al. [17] diferenciaron transparencia, auditabilidad y explicabilidad en modelos crediticios. Estos enfoques muestran que un pipeline MLOps no debe limitarse a automatizar tareas; también debe incorporar validaciones, seguimiento de cambios y criterios de aprobación.

3.4 Síntesis comparativa

Estudio Datos Modelos Horizonte MLOps Limitación Lessmann et al. [12]

8 datasets 41 clasificadores

Único No Benchmark clásico Gunnarsson et al. [14]

Varios set de datos

MLP, DBN, ensembles

Único No MLP obtiene mejor resultado Bucker et al. [17]

Modelos crediticios

Transparencia, auditabilidad

No aplica No Diferencia conceptos de XAI Amed et al. [8]

Préstamos digitales

Modelos adaptativos y MLOps

No especificado

Parcial Arquitectura y datos distintos

Testi et al. [8]

Herramientas MLOps

Taxonomía MLOps

No aplica Sí Documento conceptual

Table 3.1: Síntesis de trabajos relacionados según la información reportada en la tesis.

3.5 Brechas y posicionamiento del trabajo

En el conjunto de fuentes revisado se observa una separación entre los estudios de modelo predictivo y los trabajos sobre MLOps. También existe poca evidencia, dentro de la selección disponible, sobre predicción simultánea para dieciocho horizontes y su integración con un datamart institucional. La tesis se posiciona en esa intersección mediante un prototipo que conecta fuentes crediticias, comparación de modelos, registro de experimentos, almacenamiento de predicciones y dashboards.



La contribución no consiste en demostrar que LightGBM es universalmente superior, sino en documentar su comportamiento frente a dos arquitecturas neuronales dentro de un escenario concreto y en experimentos controlados. El déficit pendiente es metodológico: se requiere un protocolo reproducible, comparaciones equivalentes, validación externa de la institución y evaluación operativa con usuarios expertos.

Master in Artificial Intelligence

13

Final Project

Chapter 4

Metodología

Este capítulo describe el diseño de la investigación, la arquitectura del prototipo, la preparación de los datos, los modelos y el protocolo de evaluación. Los resultados numéricos y su interpretación se presentan exclusivamente en el Capítulo 5.

4.1 Diseño de la investigación

El estudio es práctico, cuantitativo y experimental en el sentido de que implementa y compara tres modelos sobre una división temporal del mismo conjunto de datos. La unidad analítica corresponde a un bloque-mes, definido por la combinación de mes, nivel de riesgo, sector económico y sucursal. Sobre cada bloque se calculan características agregadas y una etiqueta binaria de crisis.

El flujo metodológico comprende: integración de fuentes, agregación mensual, construcción de características y etiquetas, generación de ventanas temporales, entrenamiento de modelos, evaluación por horizonte, selección del modelo, registro en MLflow, inferencia, almacenamiento de predicciones y visualización detallada.

4.2 Diseño y arquitectura del sistema

La arquitectura integra cinco componentes: PostgreSQL 15 como repositorio operativo y analítico; Apache Airflow 2.10 como orquestador; Python 3.12 y Notebook Jupyter para el desarrollo de modelos; MLflow para el registro de experimentos; y Apache Superset para

14

School of Mathematical and Computational Sciences


4.3 Síntesis comparativa

Figure 4.1: Diagrama de Arquitectura Propuesta

Master in Artificial Intelligence

15

Final Project



School of Mathematical and Computational Sciences

Yachay Tech University

Componente	Tecnología	Ubicación	Función
Base de datos	PostgreSQL 15 [18]	Local/Cloud	Datamart analítico
Orquestación	Apache Airflow 2.10 [19]	Local/Cloud	Flujo de entrenamiento e inferencia
Tracking ML	MLflow [20]	PC local	
Registro de experimentos	Dashboards Apache Superset [21]	Local/Cloud	Visualización BI
Entrenamiento	Python 3.12 + Jupyter	PC Local	Desarrollo de modelos

Table 4.1: Componentes del sistema y tecnologías utilizadas.

La implementación incluye un flujo mensual de entrenamiento y un flujo diario de inferencia. Esta frecuencia corresponde a la configuración del prototipo; la tesis no presenta una evaluación de carga que demuestre que dichas periodicidades sean óptimas.

4.4 Fuentes de datos y unidad de análisis

El proceso ETL (del inglés Extract, Transform and Load) integra tres fuentes institucionales en formato de archivos separados por comas, obtenidos de manera mensual.

Fuente Magnitud Aprox.

Contenido

CABECERA_PRESTAMOS 1.044.194 filas Información maestra de créditos, periodo 2015–2026 AMORTIZACAL_PRESTAMOS 24.350.210 filas Tabla de amortización mensual RECUPERACION_PRESTAMOS 15.741 filas Información de juicios y recuperaciones

Table 4.2: Fuentes de datos utilizadas en el proceso ETL.

La Tabla 4.2b documenta la trazabilidad de los datos desde las fuentes hasta las muestras de entrenamiento, extraída del análisis del código fuente.

Master in Artificial Intelligence

16

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

Etap **Conteo** **Descripción** Filas CABECERA_PRESTAMOS 1.044.194 Registros maestros de créditos Filas AMORTIZACAL_PRESTAMOS

24.350.210 Cuotas de amortización

Filas RECUPERACION_PRESTAMOS

15.741 Juicios y recuperaciones

Filas tras integración (JOIN) – Inner join creditos-amortizacion, left join juicios Bloques-mes en MV 45.077 GROUP BY mes, riesgo, sector, sucursal Bloques con historial ≥ 24 meses – Requerido: ventana(6) + horizontes(18) Secuencias generadas 25.434 Ventanas de 6 meses $\times$ features válidas Conjunto entrenamiento (49%) 12.463 70% inicial $\times$ 70% interno Conjunto validación (21%) 5.340 30% del train para early stopping Conjunto prueba (30%) 7.631 Reservado para evaluación final

Table 4.3: Trazabilidad de datos verificada mediante consultas directas a PostgreSQL y MLflow. Conteos extraídos de la ejecución del 29 de julio de 2026.

Nota sobre la muestra efectiva: La restricción de que cada bloque-mes debe tener al

menos 24 meses de historial continuo (6 meses de ventana + 18 horizontes) reduce el número

de secuencias disponibles. La vista materializada contiene 45.077 bloques-mes, de los cuales

se generan 25.434 secuencias válidas. De éstas, 12.463 se destinan a entrenamiento, 5.340

a validación y 7.631 a prueba. La distribución de la variable objetivo en la MV es 39.660

bloques sin crisis (88%) y 5.417 con crisis (12%).

4.5 Procesamiento y preparación de datos

El procesamiento se implementa en una vista materializada y en tareas del DAG (por sus



siglas en ingles Gráfico Acíclico Dirigido). Las etapas documentadas son: integración de las tres fuentes, validación de claves, prevención de duplicados mediante la combinaciones de inserciones y actualizaciones de registros, agregación mensual y cálculo de características. El proyecto no aporta un registro completo de filas eliminadas, valores faltantes, criterios de tratamiento de atípicos ni conteos posteriores a cada filtro. Estas decisiones deben versionarse junto con el código para garantizar reproducibilidad.

Master in Artificial Intelligence

17

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

Las redes neuronales requieren una representación secuencial. Para cada bloque se utiliza una ventana de seis meses con veintiun características por mes, lo que corresponde a una matriz de 6×21 y a 126 valores antes de cualquier transformación adicional. La referencia original a 128 valores se corrige porque no se documentan dos variables adicionales.

4.6 Ingeniería de características y variable objetivo

El proyecto calcula veintiuna características numéricas derivadas de las tres fuentes. La

Tabla 4.3 presenta el diccionario completo extraído del código fuente.

Variable	Grupo	Interpretación
num_credits	Volumen	Número de créditos agregados en el bloque-mes
monto_total	Volumen	Suma del monto crediticio
monto_promedio	Volumen	Monto promedio de los créditos
plazo_promedio	Condición	Plazo promedio de las operaciones (cuotas)
tasa_interes_promedio	Condición	Tasa de interés promedio
saldo_promedio	Riesgo	Saldo capital promedio
total_costo_judicial	Riesgo	Suma de costos judiciales del bloque
total_gestion_cobro	Riesgo	Suma de gestiones de cobro
total_notificaciones	Riesgo	Suma de notificaciones
tot_dias_mora_promedio	Riesgo	Promedio de días en mora
tot_num_moras_promedio	Riesgo	Promedio de número de moras
mora_promedio	Riesgo	Monto promedio de mora
creditos_judiciales	Riesgo	Créditos con indicador judicial = 'S'
creditos_cerrados	Riesgo	Créditos con estado 'C' o 'L'
tasa_judicial	Riesgo	$\text{creditos_judiciales} / \text{num_credits} \times 100$
tasa_cierre	Riesgo	$\text{creditos_cerrados} / \text{num_credits} \times 100$
tasa_mora_90	Riesgo	Créditos con >90 días mora / $\text{num_credits} \times 100$
creditos_por_cliente	Derivada	$\text{num_credits} / \text{num_clientes_unicos}$
coef_variacion_montos	Derivada	$\text{desviación_montos} / \text{monto_promedio} \times 100$
tasa_crecimiento_creditos	Derivada	Variación %, $\Delta \text{num_credits} / \text{num_credits_previo}$
tasa_crecimiento_monto	Derivada	Variación %, $\Delta \text{monto_total} / \text{monto_total_previo}$

Table 4.4: Diccionario completo de las 21 características extraído del código fuente (queries.py y pipelines de modelos).

La variable binaria crisis_flag se construye mediante ocho condiciones heurísticas o

llamados criterios empíricos con pesos acumulativos. Si la suma de pesos supera el umbral

Master in Artificial Intelligence

18

Final Project



de 5, el bloque se etiqueta como crisis (1); de lo contrario, como no crisis (0). Las ocho

condiciones son:

• **Condición 1** (peso 3): $tasa_judicial > 5\%$

• **Condición 2** (peso 1): $tasa_Judicial > 2\%$

• **Condición 3** (peso 2): $costo_judicial > 0$ Y $(costo_judicial / num_creditos) >$
 $monto_promedio \times 10\%$

• **Condición 4** (peso 1): $gesti3n_cobro > 0$ Y $(gesti3n_cobro / num_creditos) >$
 $monto_promedio \times 5\%$

• **Condición 5** (peso 2 o 1): $tasa_cierre > 30\%$ (peso 2) o $> 20\%$ (peso 1)

• **Condición 6** (peso 1): $plazo_promedio > 36$ meses

• **Condición 7** (peso 1): $plazo_promedio > 60$ meses

• **Condición 8** (peso 1): $tasa_interes_promedio > 15\%$

Umbral de decisi3n: pesos $\geq 5 \Rightarrow crisis_flag = 1$. La etiqueta fue validada por


juicio experto seg3n el documento original, aunque el procedimiento de validaci3n no est3
documentado.

Figure 4.2: Diagrama de flujo de la definici3n de $crisis_flag$. Cada condici3n eval3a un umbral y asigna un peso; si la suma total supera 5, el bloque se etiqueta como crisis.

Master in Artificial Intelligence

19

Final Project



que también aparecen como características de entrada. Dado que el campo judicial es un atributo histórico del crédito (registrado al momento de la operación, antes del instante de predicción), no existe fuga de información temporal en sentido estricto. Sin embargo, el uso de las mismas variables tanto para definir la etiqueta como para predecirla genera una **circularidad de constructo**: la elevada importancia predictiva de estas variables (AUC-ROC individual $> 0,9$) refleja parcialmente la dependencia estructural con la definición de la etiqueta, y no necesariamente una capacidad genuina de anticipar crisis.

Para cuantificar la contribución real de la señal judicial más allá de esta circularidad, se requiere una ablación que excluya `tasa_judicial`, `creditos_judiciales` y `total_costo_judicial` del conjunto de predictores y compare el rendimiento del modelo con y sin estas variables.

4.6.1 Generación de horizontes


La salida considera dieciocho horizontes mensuales. Para una ventana que termina en t , la etiqueta del horizonte h corresponde al estado futuro en $t + h$. CNN y MLP generan un vector de dieciocho probabilidades, mientras que LightGBM entrena un clasificador independiente por horizonte.

Figure 4.3: Representación conceptual de la ventana de entrada y las etiquetas multi- horizonte. Cada bloque-mes genera una secuencia de 6 meses con 21 características, y 18 etiquetas futuras correspondientes a los horizontes de predicción.

Master in Artificial Intelligence

20

Final Project



School of Mathematical and Computational Sciences

Yachay Tech University

4.7 Algoritmos seleccionados

Se comparan tres familias para representar enfoques distintos sobre los mismos datos tabulares y temporales.

4.7.1 CNN multi-horizonte



La CNN se implementa como una red unidimensional (Conv1D) con la siguiente arquitectura

completa extraída del código fuente:

- Input: ventana de 6×21 (6 meses, 21 características)
- [Conv1D\(64, kernel_size=3, activation='relu', padding='same'\)](#)
- [BatchNormalization](#)
- [Dropout\(0.3\)](#)
- [Conv1D\(128, kernel_size=3, activation='relu', padding='same'\)](#)
- [BatchNormalization](#)
- [MaxPooling1D\(pool_size=2\)](#)
- [Dropout\(0.3\)](#)
- [Flatten](#)
- [Dense\(128, activation='relu'\)](#)
- [BatchNormalization](#)
- [Dropout\(0.4\)](#)
- [Dense\(64, activation='relu'\)](#)
- [Dropout\(0.3\)](#)
- [18 salidas Dense\(1, activation='sigmoid'\), una por horizonte](#)

[Configuración de entrenamiento:](#)

[Master in Artificial Intelligence](#)

[21](#)

[Final Project](#)

[School of Mathematical and Computational Sciences](#)

[Yachay Tech University](#)

- [Pérdida: binary_crossentropy](#)
- [Optimizador: Adam \(lr por defecto = 0,001\)](#)
- [Épocas máximas: 100](#)
- [Batch size: 32](#)
- [Early stopping: paciencia = 10, monitorea val_loss, restaura mejores pesos](#)
- [Sample weights: Sí calcula pesos por clase \(total / \(2 × n_clase\)\)](#)
- [Escalado: MinMaxScaler \(fit solo en train\)](#)

- Tratamiento de atípicos: clipping a cuantiles 0,01–0,99

4.7.2 MLP multi-horizonte

El MLP se implementa como un perceptrón multicapa con aplanamiento de la secuencia temporal. La arquitectura completa es:

- Input: ventana de 6×21
- Flatten (aplana a vector de 126 elementos)
- Dense(128, activation='relu')
- Dropout(0.3)
- Dense(64, activation='relu')
- Dropout(0.2)
- 18 salidas Dense(1, activation='sigmoid'), una por horizonte

Configuración de entrenamiento:

- Pérdida: binary_crossentropy
- Optimizador: Adam (lr = 0,001)
- Épocas máximas: 100

Master in Artificial Intelligence

22

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

- Batch size: 32
- Early stopping: paciencia = 10, monitorea val_loss, restaura mejores pesos
- Sample weights: NO utiliza ponderación por clase (a diferencia de CNN)
- Escalado: MinMaxScaler (fit solo en train)
- Tratamiento de atípicos: clipping a cuantiles 0,01–0,99

Diferencia crítica con CNN: El MLP no implementa sample_weights, lo que significa que el desbalance de clases (85% no crisis vs 15% crisis) no se compensa durante el entrenamiento. Esta omisión puede explicar parcialmente por qué el MLP predice todas las observaciones como “no crisis”.

4.7.3 LightGBM multi-horizonte

LightGBM se implementa mediante dieciocho clasificadores independientes, uno por hor-

izonte, siguiendo los principios de gradient boosting [5, 4]. La configuración completa

extraída del código es:

- objective: binary
- metric: binary_logloss
- boosting_type: gbdt
- num_leaves: 31
- learning_rate: 0,05
- feature_fraction: 0,8
- bagging_fraction: 0,8
- bagging_freq: 5
- seed: 42 (semilla fija para reproducibilidad)
- n_jobs: -1 (usa todos los núcleos)

Master in Artificial Intelligence

23

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

- Early stopping: 50 rondas sin mejora
- Número máximo de boost rounds: 1000
- Escalado: MinMaxScaler (fit solo en train)

A diferencia de las redes neuronales, LightGBM no requiere representación secuencial;

cada horizonte se entrena como un problema de clasificación binaria independiente con las mismas 21 características.

Elemento LightGBM CNN MLP Salida 18 modelos binarios independientes

18 salidas sigmoidales 18 salidas sigmoidales Arquitectura Árboles potenciados (GBDT)

Conv1D(64,k=3), BN, Do(0,3), Conv1D(128,k=3), BN, MaxPool(2), Do(0,3), Flat, Den(128), BN, Do(0,4), Den(64), Do(0,3)

Flat, Den(128), Do(0,3), Den(64), Do(0,2)

Optimizador GBDT, lr=0,05 Adam (lr=0,001) Adam (lr=0,001) Loss binary_logloss binary_crossentropy binary_crossentropy
Batch size N/A (usa bagging) 32 32 Sample weights

scale_pos_weight = 5,67

Sí (total/2×n_clase) NO



Early stopping 50 rondas Paciencia 10 (val_loss) Paciencia 10 (val_loss) Semilla 42 (fija) No fijada No fijada Escalado
MinMaxScaler MinMaxScaler MinMaxScaler Clipping No Sí (q01–q99) Sí (q01–q99)

Table 4.5: Configuración completa documentada de los modelos evaluados, extraída del código fuente.

Master in Artificial Intelligence

24

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

Figure 4.4: Comparación de arquitecturas: LightGBM entrena 18 modelos independientes (uno por horizonte), mientras que CNN y MLP son redes únicas con 18 salidas sigmoidales. Todos comparten la misma entrada de 6×21 valores.


4.8 Hiperparámetros y estrategia de ajuste

Los hiperparámetros de LightGBM se seleccionaron mediante búsqueda manual. No se documentan el espacio explorado, el número de configuraciones ni la regla utilizada para

Master in Artificial Intelligence

25

Final Project



detener la búsqueda. Para CNN y MLP se reportan las arquitecturas principales, pero no un procedimiento equivalente de ajuste. Por ello, la comparación refleja las implementaciones disponibles y no una búsqueda equilibrada de la mejor configuración de cada familia.

El valor $\text{scale_pos_weight}=5,67$ es consistente con una razón aproximada entre clases negativa y positiva, pero el cálculo exacto debe realizarse únicamente con el conjunto de entrenamiento de cada horizonte. El proyecto no presenta los conteos por horizonte necesarios para verificarlo.

4.9 Protocolo de entrenamiento, validación y prueba

La división de datos se implementa en tres etapas temporales, verificada en el código fuente:

1. **División temporal inicial (70% / 30%):** Los datos se ordenan cronológicamente y se dividen en entrenamiento (70% más antiguo) y prueba (30% más reciente).

2. **Extracción de validación (del 70% de train):** Del conjunto de entrenamiento se extrae un 30% para validación, resultando en:

Conjunto Proporción Uso Entrenamiento 49% del total Ajuste de pesos del modelo Validación 21% del total Early stopping, monitoreo de val_loss Prueba 30% del total Evaluación final (una sola vez)

Table 4.6: Distribución real de los conjuntos de datos extraída del código.

Master in Artificial Intelligence

26

Final Project


School of Mathematical and Computational Sciences

Yachay Tech University

Figure 4.5: Línea de tiempo de la división temporal de datos. El periodo 2015–2022 se utiliza para entrenamiento y validación, mientras que 2023–2026 se reserva para prueba.

El conjunto de validación se utiliza exclusivamente para early stopping (monitoreo de val_loss con paciencia de 10 épocas) y checkpoint del mejor modelo. El conjunto de prueba se reserva para una única evaluación al final del entrenamiento.


Limitaciones del protocolo: (1) No se reportan los conteos exactos de muestras por conjuntos y por horizonte; (2) la semilla no está fijada para CNN y MLP, lo que dificulta la reproducibilidad; (3) no se realizan repeticiones con múltiples semillas para estimar variabilidad; (4) la búsqueda de hiperparámetros fue manual y no documentada.



School of Mathematical and Computational Sciences

Yachay Tech University

Figure 4.6: Flujo de entrenamiento, registro y selección implementado en el prototipo. Los datos pasan por preprocesamiento, generación de secuencias y división temporal antes de entrenar los tres modelos.



4.10 Métricas y criterio de selección

Los modelos se evalúan mediante accuracy, precision, recall, F1-score y AUC-ROC. El criterio principal implementado para seleccionar el modelo es el AUC-ROC promedio de los dieciocho horizontes registrado en MLflow. En la discusión se examina también el recall, debido a que un AUC moderado puede coexistir con una baja detección de crisis bajo el umbral utilizado.

No se reportan intervalos de confianza, pruebas estadísticas, PR-AUC ni calibración. En consecuencia, no se utiliza el término significativo en sentido estadístico y no se atribuyen diferencias observadas a una causa específica.

4.11 Pipeline MLOps y registro de experimentos

El DAG de entrenamiento se programa para el primer día de cada mes a las 03:00. Sus tareas cubren extracción, carga, preparación, entrenamiento, cálculo de métricas y registro de artefactos. La versión original ejecuta los modelos en paralelo; este diseño puede aumentar la utilización de recursos, pero no se dispone de mediciones de CPU, memoria o temperatura que permitan cuantificar el impacto.

MLflow almacena los resultados de las ejecuciones y permite recuperar el modelo seleccionado. La tesis no documenta un esquema de aprobación humana verificable, reglas de promoción, hash de datos, commit del código ni política de reversión. Por ello, el sistema se presenta como prototipo MLOps y no como una operación regulada en producción.

4.12 Puesta en producción e inferencia

El DAG de inferencia se ejecuta diariamente a las 06:00. Actualiza la vista materializada, carga el modelo registrado, genera probabilidades para los dieciocho horizontes y realiza upsert en fact_predicciones_mensual.

Master in Artificial Intelligence

Figure 4.7: Flujo de inferencia y actualización analítica. El DAG diario actualiza la vista materializada, carga el modelo y genera predicciones para los 18 horizontes.

La tabla de predicciones contiene probabilidades prob_h01–prob_h18, predicciones binarias pred_h01–pred_h18 con umbral 0,5, medidas resumen y metadatos de ejecución.

El proyecto no presenta evaluación de calibración ni optimización del umbral, por lo que el valor 0,5 se considera una decisión de implementación y no un umbral de negocio validado.


4.13 Diseño del datamart y dashboards

El datamart adopta un esquema estrella con dim_tiempo, dim_riesgo, dim_sector y dim_sucursal. Las tablas fact_creditos_mensual y fact_predicciones_mensual almacenan los agregados históricos y las predicciones. Apache Superset consulta estas tablas

Master in Artificial Intelligence

30

Final Project



School of Mathematical and Computational Sciences

Yachay Tech University

para construir siete dashboards: histórico de créditos, análisis dimensional, KPIs generales, predicciones por sucursal, predicciones por sector, evolución temporal y bloques de mayor riesgo.

Figure 4.8: Esquema conceptual del datamart analítico. Las dimensiones comparten ambas tablas de hechos: fact_creditos_mensual (datos históricos) y fact_predicciones (salida del modelo).


4.14 Recursos computacionales

La Tabla 4.6 documenta los recursos utilizados para el entrenamiento de los modelos, extraída del código y la documentación del proyecto.

Master in Artificial Intelligence

31

Final Project



School of Mathematical and Computational Sciences

Yachay Tech University

Recurso Especificación Procesador Intel i7 12va Generación Memoria RAM 32GB GPU no presente Sistema operativo Ubuntu Linux 24.02 Python 3.12 TensorFlow/Keras – LightGBM – PostgreSQL 15 Apache Airflow 2.10 MLflow 3.14 Apache Superset 6.10

Table 4.7: Recursos computacionales y versiones de software. Corresponde a un pc de uso doméstico

Tiempos de ejecución reportados: LightGBM entrenó los 18 horizontes en aproximadamente 5 minutos; CNN requirió más de 2 horas sin convergencia; MLP requirió un tiempo intermedio. Estos tiempos son aproximados y pueden variar según el hardware utilizado.

4.15 Versionado y reproducibilidad

El proyecto utiliza los siguientes mecanismos para garantizar la reproducibilidad:

- **Semilla fija:** LightGBM utiliza seed=42; CNN y MLP no fijan semilla.
- **Registro en MLflow:** Cada ejecución registra parámetros, métricas y artefactos.
- **Contenedores Docker:** El proyecto incluye configuración para despliegue en contenedores.
- **Repositorio GitHub:** Código fuente disponible en el repositorio del proyecto.

Limitaciones de reproducibilidad: (1) CNN y MLP no fijan semilla, por lo que

los resultados pueden variar entre ejecuciones; (2) no se documentan versiones exactas de todas las librerías; (3) no se adjunta el hardware específico utilizado; (4) no se preservan los datos originales por restricciones de confidencialidad.

Master in Artificial Intelligence

32

Final Project

Chapter 5

Resultados

Este capítulo presenta los resultados disponibles y los interpreta en relación con los objetivos. Las afirmaciones se limitan a la configuración evaluada.

5.1 Caracterización del conjunto de datos

El conjunto consolidado contiene 45.077 registros a nivel bloque-mes y veintiún características numéricas. La distribución reportada para la variable objetivo es de 39.660 registros sin crisis (88%) y 5.417 con crisis (12%). Esta proporción evidencia un desbalance que hace necesario interpretar la exactitud junto con precisión, recall y AUC-ROC.

Clase Registros Proporción No crisis 39.660 88% Crisis 5.417 12% **Total** 45.077 100%

Table 5.1: Distribución global de la variable objetivo.

El número de registros agregados no equivale directamente al número de secuencias utilizadas para entrenar los modelos. La versión original menciona 293 muestras de entrenamiento, pero no incluye los conteos necesarios para reproducir la transformación. Por esta razón, la muestra efectiva y la distribución por horizonte deben verificarse antes de considerar definitiva la evaluación.

33

School of Mathematical and Computational Sciences

Yachay Tech University

5.2 Resultados del procesamiento y

análisis exploratorio

5.2.1 Correlaciones

La Figura 5.1 muestra correlaciones elevadas entre algunas variables. En particular, el doc-


umento original reporta una relación cercana a 1 entre num_credits y credits_cerrados, así como entre monto_total y monto_promedio. Estas relaciones pueden generar redundancia, aunque la multicolinealidad no afecta de la misma manera a árboles y redes neuronales. Los valores de VIF (del inglés Variance Inflation Factor) mencionados en la versión original no se conservan como evidencia principal porque no se documenta su cálculo completo.

Figure 5.1: Matriz de correlaciones de Pearson entre las 21 características numéricas del conjunto analítico. Los valores cercanos a 1,0 (color intenso) indican alta correlación positiva. Se observa multicolinealidad severa entre pares como num_credits- credits_cerrados y monto_total-monto_promedio. La multicolinealidad afecta de manera diferente a modelos lineales y no lineales.

Master in Artificial Intelligence

34

Final Project



School of Mathematical and Computational Sciences

Yachay Tech University

5.2.2 Poder predictivo individual

El análisis univariado identifica tasa_judicial y credits_judiciales como las variables con mayor AUC-ROC individual. Las categorías cualitativas “muy alto” y “medio” se eliminan porque la tesis no define umbrales formales para ellas.

Variable AUC-ROC individual tasa_judicial 0,926 credits_judiciales 0,912 saldo_promedio 0,666 monto_total 0,651

Table 5.2: Variables con mayor AUC-ROC individual según el análisis exploratorio.

Figure 5.2: AUC-ROC calculada individualmente para cada variablepredictora, evaluada contra la etiqueta crisis_flag. El AUC-ROC mide la capacidad de cada variable para distinguir entre bloques con y sin crisis, sin considerar interacciones con otras variables.




Estos resultados requieren una lectura prudente. Las variables judiciales son atributos históricos disponibles antes del instante de predicción, por lo que su alta capacidad discriminativa puede reflejar una señal predictiva legítima. Sin embargo, dado que estas mismas variables intervienen en la definición de crisis_flag (condiciones 1, 2 y 3), parte del poder predictivo observado es atribuible a la circularidad de constructo documentada en la Sección 4.5. La separación entre señal genuina y dependencia estructural requiere una ablación que excluya las variables judiciales del conjunto de predictores.

Master in Artificial Intelligence

35

Final Project



School of Mathematical and Computational Sciences

Yachay Tech University

5.2.3 Evolución temporal de la clase positiva

La Figura 5.3 muestra cambios en la proporción de crisis a lo largo del periodo. El documento original describe niveles de 5–7% antes de 2020, un pico de 20–24% durante 2020–2021 y una estabilización cercana al 15% posteriormente. Esta coincidencia temporal no permite atribuir el cambio a la pandemia sin un análisis causal y fuentes externas; por ello, se reporta únicamente como patrón descriptivo.

Figure 5.3: Evolución mensual de la proporción de bloques etiquetados como crisis (crisis_flag=1) en el periodo 2015–2026. Se observa un incremento en el periodo 2020–2021 seguido de una estabilización. Esta descripción es únicamente observacional; no se establece relación causal con eventos externos.

5.3 Resultados de los modelos

5.3.1 LightGBM


LightGBM produjo resultados para los dieciocho horizontes. La Tabla 5.3 reproduce los horizontes documentados y el promedio reportado. El AUC-ROC disminuye de 0,874 a

un mes a 0,702 a dieciocho meses. El recall se reduce de 0,542 a 0,034, lo que indica que, con el umbral utilizado, el modelo identifica muy pocos casos positivos en el horizonte más largo.

Master in Artificial Intelligence

36

Final Project



School of Mathematical and Computational Sciences

Yachay Tech University

Horizonte Accuracy Precision Recall AUC-ROC 1 mes 0,937 0,694 0,542 0,874 3 meses 0,942 0,837 0,512 0,869 6 meses 0,927 0,632 0,525 0,838 12 meses 0,906 0,447 0,369 0,765 18 meses 0,897 0,500 0,034 0,702 **Promedio 0,917 0,571 0,391 0,800**

Table 5.3: Métricas reportadas para LightGBM en horizontes seleccionados.


Figure 5.4: Evolución de las métricas de LightGBM a través de los horizontes evaluados.

La Figura 5.5 muestra la importancia interna de las características. La predominancia de variables judiciales coincide con el análisis univariado, pero no demuestra causalidad ni garantiza que la señal esté disponible antes de la predicción.

Master in Artificial Intelligence

37

Final Project



School of Mathematical and Computational Sciences

Yachay Tech University

Figure 5.5: Importancia de características reportada por LightGBM (“split importance”). El método cuenta la cantidad de veces que cada variable se utiliza para dividir nodos en todos los árboles del ensemble. Las variables judiciales (tasa_judicial, creditos_judiciales) predominan, lo cual puede reflejar tanto poder predictivo real como dependencia con la etiqueta crisis_flag (ver Sección 4.5).

5.3.2 CNN

La implementación de CNN reportó un AUC-ROC de 0,50 y una pérdida que se mantuvo alrededor de 12,5. También se observaron oscilaciones extremas en accuracy, precision y recall, compatibles con predicciones concentradas en una sola clase. Un AUC-ROC de 0,50 indica ausencia de discriminación en la evaluación; por sí solo no demuestra una causa ni permite concluir que todas las CNN sean inadecuadas para este problema.

Master in Artificial Intelligence

38

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

Figure 5.6: Curva de pérdida (binary_crossentropy) durante el entrenamiento de la CNN. La línea continua representa la pérdida en entrenamiento y la discontinua la pérdida en validación (val_loss). La pérdida se estabiliza en valores elevados (~12,5), lo que indica que el modelo no logra aprender una discriminación efectiva entre clases.



La magnitud de la pérdida requiere revisar la función utilizada, las dimensiones de etiquetas y salidas, el escalado, los pesos de clase y el tamaño de lote. Estos elementos no están documentados con suficiente detalle para identificar el origen del comportamiento.


5.3.3 MLP

El MLP reportó una pérdida cercana a 12,47, AUC-ROC de 0,50 y predicciones concentradas en la clase no crisis, con precision y recall iguales a cero para la clase positiva. Este resultado describe el comportamiento de la implementación evaluada, pero no identifica sus causas. Entre los factores plausibles se encuentran el desbalance, el número de secuencias, la configuración de la pérdida, los pesos de muestra, el escalado y el ajuste de hiperparámetros.

[Master in Artificial Intelligence](#)

[39](#)

[Final Project](#)



[School of Mathematical and Computational Sciences](#)

[Yachay Tech University](#)

5.4 Comparación global

La Tabla 5.4 corrige la inconsistencia de la tabla original: los valores de LightGBM son promedios de horizontes y no corresponden exclusivamente al horizonte de un mes. CNN y MLP se presentan con los valores globales reportados, por lo que la comparación no reemplaza una tabla completa por modelo y horizonte.

Modelo Accuracy Precision Recall AUC-ROC LightGBM, promedio 0,917 0,571 0,391 0,800 CNN, resultado global 0,090 0,090 1,000 0,500 MLP, resultado global 0,910 0,000 0,000 0,500

Table 5.4: Comparación de los resultados reportados. Las unidades de resumen no son completamente equivalentes

entre modelos.

Bajo el criterio implementado de AUC-ROC promedio, LightGBM fue seleccionado para el flujo de inferencia. La selección es coherente con los resultados disponibles, pero debe considerarse provisional por cuatro razones: no se documentan repeticiones; no existe una prueba estadística; el ajuste de hiperparámetros no fue equivalente; y las salidas de LightGBM y de las redes se estructuran de manera diferente.

5.5 Ejecución automatizada y registro

El pipeline de Airflow produjo una ejecución posterior con accuracy promedio de 0,878 y AUC-ROC promedio de 0,846, mientras que el entrenamiento inicial reportó 0,917 y 0,800, respectivamente.

Métrica Ejecución inicial Ejecución automatizada Accuracy promedio 0,917 0,878 AUC-ROC promedio 0,800 0,846

Table 5.5: Resultados reportados para las ejecuciones inicial y automatizada.

La diferencia no debe atribuirse a Apache Airflow. Airflow orquesta el procedimiento, pero no mejora por sí mismo un modelo. La variación puede relacionarse con cambios en datos, particiones, configuración o aleatoriedad; estos factores no quedaron documentados. El resultado sí evidencia que el flujo automatizado fue capaz de ejecutar el entrenamiento y registrar una salida.

Master in Artificial Intelligence

40

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

Figure 5.7: Vista del DAG de entrenamiento implementado en Apache Airflow.


Figure 5.8: Vista del DAG de inferencia implementado en Apache Airflow.

5.6 Datamart y dashboards

La implementación almacena las predicciones en fact_predicciones_mensual y las expone mediante Apache Superset. Las Figuras 5.9–5.11 muestran ejemplos de los dashboards contruidos.

Master in Artificial Intelligence

41



School of Mathematical and Computational Sciences

Yachay Tech University

Figure 5.9: Dashboard para el análisis histórico de la cartera crediticia.

Las capturas demuestran que las vistas fueron implementadas, pero no constituyen una validación de utilidad. No se reportan tiempos de actualización, pruebas de integridad, disponibilidad, errores, número de usuarios ni estudios de usabilidad. La afirmación de-
fendible es que el prototipo integra visualmente datos históricos y predicciones; su impacto
en decisiones y mora requiere evaluación posterior.

5.7 Discusión


Los resultados disponibles favorecen a LightGBM en el escenario evaluado, lo que es compatible con trabajos que reportan buen desempeño de modelos de boosting en datos tabulares [12, 13]. Sin embargo, la literatura también incluye escenarios en los que un MLP supera a los árboles [14]. Por ello, las diferencias observadas deben atribuirse al conjunto de datos y a las configuraciones utilizadas, no a una propiedad universal de los algoritmos. El deterioro con el horizonte es visible en AUC-ROC y, con mayor intensidad, en recall. La cifra de recall igual a 0,034 a dieciocho meses significa que la clasificación binaria bajo el umbral 0,5 recupera una fracción muy pequeña de las crisis. Aunque el AUC-ROC se

mantiene por encima de 0,70, no es suficiente para calificar estas predicciones como confiables o útiles sin análisis de umbral, calibración y costos de error.

Master in Artificial Intelligence

42

Final Project



School of Mathematical and Computational Sciences

Yachay Tech University

El bajo rendimiento de CNN y MLP puede asociarse con la muestra secuencial reducida, el desbalance, las secuencias de seis meses y la configuración de entrenamiento. No obstante, no se realizaron ablaciones que modifiquen sistemáticamente estos factores. En consecuencia, se consideran explicaciones plausibles y no causas demostradas.

La principal fortaleza del trabajo es la integración de componentes. Su principal debilidad es la trazabilidad experimental. La ausencia de las reglas de etiqueta, de un diccionario completo, de un conjunto de validación documentado y de repeticiones limita la reproducibilidad y la generalización. Estas limitaciones deben resolverse antes de utilizar el sistema como soporte para decisiones de crédito en producción.

Master in Artificial Intelligence

43

Final Project

Chapter 6

Conclusiones

6.1 Síntesis de los principales hallazgos

La investigación permitió implementar un prototipo que integra procesamiento de datos



crediticios, entrenamiento automatizado, registro de experimentos, almacenamiento analítico y visualización. En la evaluación presentada, LightGBM mostró una mayor capacidad discriminativa que las implementaciones de CNN y MLP. El rendimiento de LightGBM disminuyó conforme aumentó el horizonte, y el recall presentó una reducción especialmente relevante en los plazos largos.

El análisis del código fuente permitió documentar completamente las ocho condiciones de crisis_flag, las 21 características, la arquitectura exacta de cada modelo y el protocolo de división de datos (49% entrenamiento, 21% validación, 30% prueba).

6.2 Respuesta al objetivo general

El objetivo general se alcanzó en lo relativo al diseño y la integración técnica de los componentes principales. Se implementaron flujos de entrenamiento e inferencia en Apache Airflow, registro en MLflow, almacenamiento en PostgreSQL y dashboards en Apache Superset. El resultado debe presentarse como un prototipo funcional. La evidencia disponible no permite concluir que la plataforma controle la mora, reduzca pérdidas o haya sido validada para apoyar decisiones en un entorno productivo.

44

School of Mathematical and Computational Sciences

Yachay Tech University

6.3 Respuesta a los objetivos específicos

Respecto al primer objetivo, se identificaron factores plausibles asociados con el comportamiento de las redes neuronales: una muestra secuencial reducida (solo bloques con ≥ 24 meses de historial generan secuencias), desbalance de clases sin compensación en MLP, ventanas de seis meses y configuración documentada completa. El MLP no implementa sample_weights, lo que puede explicar su tendencia a predecir todas las observaciones como “no crisis”. No se realizaron experimentos de ablación, por lo que estos factores no pueden declararse causas demostradas.

En relación con el segundo objetivo, LightGBM alcanzó el mayor AUC-ROC bajo las configuraciones disponibles. Esta comparación no demuestra que los modelos basados en árboles sean superiores en todos los conjuntos tabulares, porque la búsqueda de hiperparámetros no fue equivalente (LightGBM usa semilla fija y tuning documentado; CNN y MLP no fijan semilla).

Para el tercer objetivo, se observó una disminución del rendimiento de LightGBM con el horizonte. El AUC-ROC pasó de 0,874 a un mes a 0,702 a dieciocho meses, mientras que el recall descendió de 0,542 a 0,034. Por tanto, los horizontes largos deben interpretarse con cautela y no pueden considerarse operativamente útiles sin calibración, selección de umbral y análisis de costos de error.

El cuarto objetivo se cumplió como implementación técnica. El datamart integra dimensiones de tiempo, riesgo, sector y sucursal, y los dashboards permiten consultar información histórica y predicciones. No se evaluó la utilidad con usuarios, la latencia ni el impacto sobre decisiones, por lo que esas dimensiones permanecen pendientes.

6.4 Contribuciones

La primera contribución es una arquitectura de extremo a extremo que enlaza ETL, modelado, MLOps, datamart y visualización. La segunda es la comparación de tres enfoques para dieciocho horizontes, junto con el análisis de la degradación temporal. La tercera es

Master in Artificial Intelligence

45

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

la implementación de un esquema estrella y dashboards que integran predicciones y agregados históricos.

Las contribuciones se circunscriben al prototipo y a la institución analizada. No se afirma superioridad universal de LightGBM ni se generalizan los resultados a otras entidades financieras.

6.5 Aspectos éticos

El desarrollo del presente trabajo involucra datos crediticios reales de una institución financiera. Por ello, se consideraron los siguientes aspectos éticos:

- **Confidencialidad:** Los datos fueron anonimizados a nivel de bloque-mes, sin incluir identificadores personales. El acceso al repositorio está restringido al autor y al tutor.
- **Transparencia:** El modelo seleccionado (LightGBM) permite calcular importancias de características, lo que facilita la interpretación de las predicciones. No obstante,

no se realizó una auditoría formal de sesgos por sector económico o región.

• **Impacto en decisiones:** El prototipo no reemplaza el juicio de los analistas de crédito; su función es complementaria y su uso debe estar sujeto a validación humana. La institución debe establecer políticas claras sobre el uso de predicciones automáticas antes de cualquier implementación productiva.

6.6 Limitaciones

El estudio presenta limitaciones metodológicas y de generalización. La definición de `crisis_flag` quedó documentada mediante ocho condiciones con pesos acumulativos (`umbral` ≥ 5), pero existe un riesgo confirmado de circularidad de constructo (ver Sección 4.5): las variables judiciales (`tasa_judicial`, `creditos_judiciales`, `total_costo_judicial`) se utilizan tanto para definir la etiqueta como como características de entrada. Esta dependencia puede inflar artificialmente el poder predictivo de esas variables y del modelo.

Master in Artificial Intelligence

46

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

La división de datos sigue un protocolo temporal con tres conjuntos (49% entrenamiento, 21% validación, 30% prueba), y el early stopping utiliza exclusivamente el conjunto de validación. Sin embargo, no se reportan conteos por horizonte, no se fijan semillas para CNN y MLP, y no se realizan repeticiones para estimar variabilidad.

No se reportan PR-AUC, calibración, curvas por umbral ni análisis detallado de falsos negativos. La comparación entre modelos utiliza presupuestos de ajuste no equivalentes.

Además, el estudio se realizó en una sola institución y no incluye validación externa.

Desde la perspectiva operativa, las capturas demuestran la implementación de los flujos y dashboards, pero no se presentan pruebas de rendimiento, disponibilidad, recuperación ante fallos, integridad de datos o usabilidad. Estas limitaciones impiden considerar el prototipo como un sistema productivo validado.

6.7 Trabajo futuro

El trabajo futuro se organiza en tres líneas prioritarias:

1. **Reproducibilidad y robustez:** Registrar conteos por etapa y horizonte, fijar semil-

las para todos los modelos, realizar repeticiones con múltiples semillas (al menos 10), y versionar datos, código y entornos mediante dvc o git-lfs.

2. Ablación de leakage: Repetir la evaluación excluyendo las variables judiciales (tasa_judicial, creditos_judiciales, total_costo_judicial) para estimar cuánto del poder predictivo se debe a la dependencia con la etiqueta. Este es el experimento más crítico antes de cualquier implementación operativa.

3. Comparación equilibrada: Equilibrar los presupuestos de ajuste (añadir sample_weights al MLP, realizar búsqueda de hiperparámetros equivalente para CNN y MLP), reportar intervalos de confianza, incluir PR-AUC, calibración y selección de umbrales basada en costos de error (falsos positivos vs. falsos negativos).

4. Validación externa: Evaluar el prototipo con datos de al menos otra institución financiera y mediante pruebas funcionales con usuarios analistas. Solo después de

Master in Artificial Intelligence

47

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

estas validaciones sería posible estimar su contribución a procesos de decisión, alertas o gestión de cartera.

Master in Artificial Intelligence

48

Final Project

Bibliography

[1] G. H. N. Laursen and J. Thorlund, *Business Analytics for Managers: Taking Business Intelligence Beyond Reporting*, 2nd ed. Wiley, 2017.

[2] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Wiley, 2013.



[3] H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.

- 1  [4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "Lightgbm: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- 2  [5] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- 3  [6] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- 4  [7] T. Fawcett, "An introduction to roc analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.
[8] M. Testi, M. Ballabio, E. Frontoni, G. Iannello, S. Moccia, P. Soda, and G. Vessio, "Mlops: A taxonomy and a methodology," *IEEE Access*, vol. 10, pp. 63 606–63 618, 2022.
- 5  [9] D. Kreuzberger, N. Kühn, and S. Hirschl, "Machine learning operations (mlops): Overview, definition, and architecture," *IEEE Access*, vol. 11, pp. 31 866–31 879, 2023.
49
School of Mathematical and Computational Sciences
Yachay Tech University
- 9  [10] D. Sculley *et al.*, "Hidden technical debt in machine learning systems," in *Advances in Neural Information Processing Systems*, vol. 28, 2015.
[11] E. Breck, S. Cai, E. Nielsen, M. Salib, and D. Sculley, "The ml test score: A rubric for ml production readiness and technical debt reduction," in *IEEE International Conference on Big Data*, 2017, pp. 1123–1132.
[12] S. Lessmann, B. Baesens, H.-V. Seow, and L. C. Thomas, "Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research," *European Journal of Operational Research*, vol. 247, no. 1, pp. 124–136, 2015.
[13] V. Moscato, A. Picariello, and G. Sperlì, "A benchmark of machine learning approaches for credit score prediction," *Expert Systems with Applications*, vol. 165, p. 113986, 2021.
[14] B. R. Gunnarsson, S. vanden Broucke, B. Baesens, M. Óskarsdóttir, and W. Lemahieu, "Deep learning for credit scoring: Do or don't?" *European Journal of Operational Research*, vol. 295, no. 1, pp. 292–305, 2021.

” [15] C. Chen, R. Calabrese, and B. Martin-Barragan, “Interpretable machine learning for imbalanced credit scoring datasets,” *European Journal of Operational Research*, vol. 312, no. 1, pp. 357–372, 2024.

” [16] N. Bussmann, P. Giudici, D. Marinelli, and J. Papenbrock, “Explainable machine learning in credit risk management,” *Computational Economics*, vol. 57, pp. 203–216, 2021.

” [17] M. Bücker, G. Szepannek, A. Gosiewska, and P. Biecek, “Transparency, auditability, and explainability of machine learning models in credit scoring,” *Journal of the Operational Research Society*, vol. 73, no. 1, pp. 70–90, 2022.

[18] The PostgreSQL Global Development Group, “Postgresql 15 documentation,” <https://www.postgresql.org/docs/15/>, 2024, accessed: 2026-06-15.

[19] Apache Software Foundation, “Apache airflow documentation,” <https://airflow.apache.org/docs/>, 2024, accessed: 2026-06-15.

Master in Artificial Intelligence

50

Final Project

School of Mathematical and Computational Sciences

Yachay Tech University

[20] MLflow Contributors, “Mlflow documentation,” <https://mlflow.org/docs/latest/>, 2024, accessed: 2026-07-15.

[21] Apache Software Foundation, “Apache superset documentation,” <https://superset.apache.org/docs/>, 2024, accessed: 2026-06-13.

Master in Artificial Intelligence

51

Final Project

Appendices

52

Appendix A

Repositorios y evidencia

complementaria

Los recursos técnicos proporcionados se encuentran en los siguientes repositorios:

Contenedores Docker:

<https://github.com/YahayUniversidad/IADegreeThesis/tree/main/Contenedores>

Desarrollo de la solución:

<https://github.com/YahayUniversidad/IADegreeThesis/tree/main/Desarrollo>

Documentación relacionada:

<https://github.com/YahayUniversidad/IADegreeThesis/tree/main/DocumentosBase>

Para una reproducción verificable, la versión final debe asociar los enlaces con un commit o etiqueta estable e indicar qué script genera cada tabla, figura y modelo.

A.1 Capturas adicionales de dashboards

A.2 Información mínima para reproducibilidad

La documentación final del repositorio debería incluir: definición de las ocho reglas de crisis_flag; diccionario de las veintiuna características; conteos de registros y secuencias por etapa; particiones temporales; configuración completa de CNN, MLP y LightGBM;

53

School of Mathematical and Computational Sciences

Yachay Tech University

Figure A.1: Vista complementaria del dashboard histórico de créditos.

Figure A.2: Dashboard de análisis dimensional por riesgo y sector.



semillas; versiones de librerías; especificaciones de hardware; hashes o versiones de datos; métricas por horizonte; y procedimientos para ejecutar los DAG y reconstruir los dashboards.

A.3 Esquema estrella del datamart

El datamart analítico utiliza un esquema estrella con dos tablas de hechos que comparten las mismas dimensiones. A continuación se presentan los diagramas de cada tabla de

Master in Artificial Intelligence

54



School of Mathematical and Computational Sciences

Yachay Tech University



Figure A.3: Dashboard de evolución temporal de predicciones.


hechos.

A.3.1 Tabla de hechos: fact_creditos_mensual

Figure A.4: Esquema estrella de la tabla fact_creditos_mensual. Almacena los agregados históricos de créditos por bloque-mes, incluyendo la variable objetivo crisis_flag.

Master in Artificial Intelligence





School of Mathematical and Computational Sciences

Yachay Tech University

A.3.2 Tabla de hechos: fact_predicciones

Figure A.5: Esquema estrella de la tabla fact_predicciones. Almacena las probabilidades y predicciones binarias para los 18 horizontes temporales, generadas por el modelo seleccionado.

Master in Artificial Intelligence

56

Final Project

