

Sistema Integrado de Inteligencia de Negocio para la Predicción de Crisis Crediticias

Trabajo de titulación

Omar Vélez Bayas

omar.velez@yachaytech.edu.ec

Juan Astudillo

Tutor

Universidad Yachay Tech

Maestría en Inteligencia Artificial

Octubre 2026

1. Introducción

Contexto y Motivación

La **mora crediticia** es un indicador de riesgo que todo el sistema financiero debe controlar. Un índice saludable es $< 5\%$, ya que un valor superior puede afectar la liquidez de la institución y su capacidad de otorgar nuevos créditos.

Las instituciones de **economía social y solidaria** administran grandes volúmenes de información crediticia, pero los indicadores se generan mediante procesos manuales y repositorios separados.

Datos

La data fue proporcionada por la **Cooperativa de Ahorro y Crédito Jardín Azuayo** y contiene información de préstamos, amortizaciones y juicios desde el 2019 hasta el 2026.

La misma ya fue entregada con un proceso previo de **anonimizado**: sin datos de cuentas, ni información personal de los socios y clientes, en fiel cumplimiento con normas internas de seguridad y leyes vigentes.

La media de registros es de 1.8 millones por año

Planteamiento del Problema

Tres brechas identificadas:

1. **Brecha de datos:** no existe un flujo único para integrar, limpiar y agregar la información crediticia
2. **Brecha analítica:** los modelos no se comparan bajo un protocolo multi-horizonte común
3. **Brecha operativa:** los resultados del modelado no se registran, almacenan y visualizan de forma automatizada

Pregunta de Investigación

¿Cómo integrar datos crediticios, modelos de aprendizaje automático y herramientas de inteligencia de negocio en un sistema automatizado que permita predecir crisis crediticias en múltiples horizontes temporales y visualizar los resultados para la toma de decisiones?

Hipótesis

Un pipeline end-to-end que combine ETL automatizado, modelos multi-horizonte y dashboards interactivos permite generar predicciones accionables con rendimiento competitivo frente a enfoques individuales.

Objetivos

Objetivo General

Diseñar e implementar un sistema integrado de inteligencia de negocio para la predicción de crisis crediticias en el sector de economía social y solidaria.

Objetivos Específicos

1. Construir un **pipeline ETL** automatizado con Apache Airflow
2. Diseñar un **datamart analítico** con esquema estrella en PostgreSQL
3. Evaluar **modelos de IA** (CNN, MLP, LightGBM) para predicción multi-horizonte
4. Implementar **dashboards interactivos** con Apache Superset
5. Automatizar **entrenamiento, inferencia y registro** con MLflow

2. Marco Teórico

Conceptos Clave

Concepto	Descripción
Riesgo crediticio	Probabilidad de incumplimiento de obligaciones financieras
Inteligencia de negocio	Consolidación de datos en datamarts + dashboards
Predicción multi-horizonte	Estimación de probabilidad de crisis a 1, 2, ..., 18 meses
Clases desbalanceadas	La clase positiva (crisis) es minoritaria en los datos
Validación temporal	Split cronológico para evitar fuga de información
MLOps	Automatización del ciclo de vida de modelos ML

Modelos Evaluados

Modelo	Tipo	Salida
CNN	Red neuronal convolucional 1D	18 neuronas sigmoid (h1–h18)
MLP	Perceptrón multicapa	18 neuronas sigmoid (h1–h18)
LightGBM	Gradient boosting	18 clasificadores independientes

Variable objetivo: `crisis_flag` (score heurístico ≥ 4)

Métricas de evaluación: AUC-ROC, Precision, Recall, F1-Score

3. Estado del Arte


Brechas Identificadas

Brecha	Descripción
Multi-horizonte	Pocos trabajos predicen simultáneamente en múltiples ventanas temporales
Integración end-to-end	La mayoría se enfoca en el modelo, no en el pipeline completo
MLOps aplicado	Escasa automatización de entrenamiento, registro e inferencia
Visualización	Limitada integración de predicciones en dashboards de negocio

Posicionamiento: este trabajo integra las tres brechas en un sistema reproducible y automatizado.

4. Metodología

Arquitectura del Sistema



Stack: Airflow · PostgreSQL · MLflow · TensorFlow · LightGBM · Polars · Superset

ETL y Datamart

ETL (Extracción, Transformación, Carga)

- **51 archivos CSV:** préstamos, amortizaciones, juicios (2015–2026)
- Carga masiva con `COPY` + proceso incremental `ON CONFLICT DO UPDATE`

Datamart (Esquema Estrella)

Dimensión / Hecho	Contenido
dim_tiempo	Mes, año, trimestre
dim_riesgo	Código y descripción de riesgo
dim_sector	Código y descripción de sector
dim_sucursal	Sucursal y provincia
fact_creditos_mensual	27 métricas por bloque
fact_predicciones	Predicciones multi-horizonte (56.541 filas)

Análisis EVA (Evaluación de Variables Analíticas)

Módulo Python reutilizable

- `pipeline.py` — Orquestador EVA (modo notebook/MLflow)
- `analisis_riguroso.py` — Motor de análisis estadístico

Métrica	Uso
Pearson, Spearman	Correlación lineal y monótona
VIF	Multicolinealidad
Chi-cuadrado	Asociación categórica
Cohen's d, t-test	Diferencia entre grupos
Shapiro-Wilk, KS	Normalidad

Dashboard 3×3: heatmap de correlaciones, distribución target, boxplots de mora, VIF, recomendaciones automáticas (INCLUIR/EXCLUIR)

EDA Optimizado

Problema

La consulta SQL genera **12M+ registros** que agotan la memoria RAM.

Solución implementada

- **Polars Lazy Mode:** `pl.read_database()` + `.lazy()` difiere la ejecución
- **Procesamiento por año:** extrae y agrega datos un año a la vez (2015–2025)
- **Agregación incremental:** solo materializa registros agregados (~miles)

Resultado: mismo CSV de salida, sin errores de memoria.

Modelos Desarrollados: Arquitectura Multi-Horizonte

Diseño propio (contribución de IA)

Entrada (t-6 ... t-1)

features del bloque
crediticio (6 meses)
por sucursal/sector

Tronco del modelo

→ CNN
→ MLP
→ LGBM

Conv1D→BN→Dense(128/64)
Flatten→Dense(128/64)
18 boosters (1/horizonte)

Salida multi-horizonte

18 × sigmoid
h1 ... h18

|
P(crisis_flag | horizonte h)

Modelo	Arquitectura diseñada	Multi-horizonte
CNN	Conv1D(64)→BN→Conv1D(128)→BN→MaxPool→Dense(128)→Dense(64)	18 × Dense(1, sigmoid)
MLP	Flatten→Dense(128, ReLU)→Dense(64, ReLU)	18 × Dense(1, sigmoid)
LightGBM	Gradient boosting con <code>scale_pos_weight</code> por horizonte	18 clasificadores independientes

Target: `crisis_flag` (score ≥ 4) · **Pérdida:** binary cross-entropy con pesos por clase (desbalance)

Nexo con la orquestación programada (Airflow)

DAG	Cron	Flujo	Vinculación con los modelos
DAG-Entrenamiento	0 3 1 * * (mensual)	estructura → CSV → datamart → EDA/EVA → [CNN // MLP // LGBM] → selección (AUC)	Diseña y entrena las 18 cabezas multi-horizonte
DAG-Inferencia	0 6 * * * (diario)	estructura → CSV → datamart → predicción → Superset	Ejecuta el mejor modelo → prob_h01 ... prob_h18

Pipeline MLOps

1. **Entrenamiento** (`dag_entrenamiento.py`): CSV $\rightarrow$ EDA $\rightarrow$ CNN + MLP + LightGBM $\rightarrow$ MLflow
2. **Inferencia** (`dag_inferencia.py`): CSV $\rightarrow$ Datamart $\rightarrow$ Predicción $\rightarrow$ Superset
3. **Registro** (MLflow): métricas, artefactos, versionado de modelos

Predicción Multi-Horizonte

- Modelo seleccionado genera `prob_h01 ... prob_h18`
- Predicciones se almacenan en `fact_predicciones`
- **LightGBM** seleccionado como mejor modelo

Aprobación Humana

1. Modelo seleccionado genera predicciones multi-horizonte
2. Predicciones se guardan en `fact_predicciones`
3. **Humano en el loop:** experto revisa y aprueba/rechaza antes de producción

5. Resultados

Comparación de Modelos

Métrica	CNN	MLP	LightGBM
AUC-ROC	0.85	0.84	0.87
Precision	0.82	0.81	0.84
Recall	0.79	0.78	0.81
F1-Score	0.80	0.79	0.82

LightGBM obtiene el mejor rendimiento global y fue seleccionado para producción.

Dashboards de Superset

5 Dashboards implementados

Dashboard	Contenido
Tendencia de Crisis	Evolución temporal por sucursal y sector
Predicciones de Crisis	Probabilidad de crisis por período
Resumen por Sucursal	Métricas agregadas (créditos, mora, judicial)
Predicción por Horizonte	Evolución por rango de plazo (corto/medio/largo)
Comparación por Segmento	Rangos por sucursal y sector + heatmap

Filtros interactivos: rango de plazo, período, sucursal, sector

Datamart y Predicciones

- **56.541 predicciones** almacenadas en `fact_predicciones`
- **18 horizontes mensuales** (`prob_h01` ... `prob_h18`)
- **3 rangos de plazo:** corto (1–3M), medio (4–6M), largo (7–18M)
- **133 períodos** de datos, **65 sucursales**, **21 sectores**

Vista analítica

`vw_predicciones_horizonte` — formato largo (1.017.738 filas) para visualización por horizonte

6. Conclusiones

Contribuciones

1. **Sistema integrado end-to-end** que conecta ETL, datamart, modelos, MLOps y dashboards
2. **Comparación rigurosa** de CNN, MLP y LightGBM bajo protocolo multi-horizonte
3. **Pipeline automatizado** con Airflow + MLflow para entrenamiento e inferencia
4. **5 dashboards interactivos** con predicciones por rango de plazo y segmento
5. **Prototipo reproducible** escalable a otras cooperativas de economía social

Limitaciones y Trabajo Futuro

Limitaciones

- Datos de una sola cooperativa (Jardín Azuayo)
- Horizontes más allá de 18 meses no evaluados
- Clasificación binaria (crisis/no crisis) sin niveles de severidad

Trabajo Futuro

- Extender a más instituciones del sector
- Incorporar modelos de series temporales (LSTM, Transformer)
- Implementar alertas automáticas basadas en predicciones
- Evaluar explicabilidad (SHAP) para toma de decisiones

Perspectivas Económicas

El sistema es un **producto reproducible, observable y escalable** para cooperativas e instituciones de economía social y solidaria.

Potencial de licenciamiento a comercios que otorguen crédito directo: almacenes de electrodomésticos, tiendas de muebles, tiendas departamentales.

Preguntas

Gracias por su atención.



Omar Vélez Bayas

omar.velez@yachaytech.edu.ec