



UNIVERSIDAD DE INVESTIGACIÓN DE TECNOLOGÍA EXPERIMENTAL YACHAY

Escuela de Ciencias Matemáticas y Computacionales

Título

Sistema Integrado de Inteligencia de Negocio para la Predicción de
Crisis Crediticias mediante las técnicas de análisis de Inteligencia
artificial y de negocio

Autor:

Omar Antonio Vélez Bayas

Tutor:

Juan Pablo Astudillo León, Ph.D.

Urcuquí, Julio 2026

Resumen

Esta tesis presenta el diseño y la implementación de un prototipo de inteligencia de negocio para integrar procesamiento de datos crediticios, predicción multi-horizonte, gestión de experimentos y visualización analítica en una institución de la economía social y solidaria del Ecuador. El sistema utiliza PostgreSQL para el almacenamiento y el datamart, Apache Airflow para orquestar los flujos de entrenamiento e inferencia, MLflow para registrar experimentos y Apache Superset para los dashboards. La evaluación compara LightGBM, una red neuronal convolucional y un perceptrón multicapa para dieciocho horizontes temporales. En los resultados reportados, LightGBM alcanzó un AUC-ROC promedio de 0,80, mientras que las implementaciones de CNN y MLP mostraron un AUC-ROC de 0,50. El rendimiento de LightGBM disminuyó con el horizonte y el recall descendió hasta 0,034 a dieciocho meses, lo que limita la interpretación operativa de las predicciones de largo plazo. Bajo la configuración evaluada, LightGBM presentó la mayor capacidad discriminativa; sin embargo, la ausencia de repeticiones, pruebas estadísticas, validación externa y una documentación completa de la etiqueta heurística impide afirmar superioridad general o causalidad. La contribución principal es la integración técnica de un flujo de datos, modelado, registro, almacenamiento analítico y visualización, presentada como un prototipo funcional que requiere validación metodológica y operativa adicional.

Palabras clave:

Riesgo crediticio; predicción multi-horizonte; LightGBM; redes neuronales; inteligencia de negocio; MLOps; datamart; Apache Airflow.

Abstract

This thesis presents the design and implementation of a business intelligence prototype that integrates credit data processing, multi-horizon prediction, experiment tracking, and analytical visualization for an Ecuadorian social and solidarity economy institution. PostgreSQL is used for storage and the data mart, Apache Airflow orchestrates training and inference workflows, MLflow records experiments, and Apache Superset provides interactive dashboards. The evaluation compares LightGBM, a convolutional neural network, and a multilayer perceptron across eighteen forecasting horizons. In the reported results, LightGBM achieved a mean ROC-AUC of 0.80, whereas the CNN and MLP implementations yielded a ROC-AUC of 0.50. LightGBM performance decreased as the horizon increased, and recall fell to 0.034 at eighteen months, which limits the operational interpretation of long-term predictions. Under the evaluated configuration, LightGBM showed the highest discriminative performance; however, the lack of repeated runs, statistical tests, external validation, and complete documentation of the heuristic target prevents claims of general superiority or causality. The main contribution is the technical integration of data processing, modeling, experiment tracking, analytical storage, and visualization into a functional prototype that requires further methodological and operational validation.

Keywords: credit risk; multi-horizon prediction; LightGBM; neural networks; business intelligence; MLOps; data mart; Apache Airflow.

Contents

Contents

List of Tables

List of Figures

1	Introducción	1
1.1	Contexto	1
1.2	Motivación	2
1.3	Planteamiento del problema	2
1.4	Pregunta de investigación	3
1.5	Hipótesis	3
1.6	Objetivo general	3
1.7	Objetivos específicos	4
1.8	Contribuciones	4
1.9	Organización del documento	4
2	Marco Teórico	6
2.1	Riesgo crediticio y clasificación binaria	6
2.2	Inteligencia de negocio, data warehouse y datamart	6
2.3	Predicción multi-horizonte	7
2.4	Clases desbalanceadas	7
2.5	Modelos evaluados	8
2.5.1	LightGBM	8
2.5.2	Red neuronal convolucional	8
2.5.3	Perceptrón multicapa	8

2.6	Validación temporal y fuga de información	9
2.7	Métricas de evaluación	9
2.8	MLOps y observabilidad	10
3	Revisión de Literatura	11
3.1	Estrategia de búsqueda	11
3.2	Predicción de riesgo crediticio	11
3.3	MLOps aplicado al riesgo crediticio	12
3.4	Síntesis comparativa	13
3.5	Brechas y posicionamiento del trabajo	13
4	Metodología	14
4.1	Diseño de la investigación	14
4.2	Diseño y arquitectura del sistema	14
4.3	Síntesis comparativa	15
4.4	Fuentes de datos y unidad de análisis	16
4.5	Procesamiento y preparación de datos	16
4.6	Ingeniería de características y variable objetivo	17
4.6.1	Generación de horizontes	19
4.7	Algoritmos seleccionados	20
4.7.1	CNN multi-horizonte	20
4.7.2	MLP multi-horizonte	21
4.7.3	LightGBM multi-horizonte	22
4.8	Hiperparámetros y estrategia de ajuste	24
4.9	Protocolo de entrenamiento, validación y prueba	25
4.10	Métricas y criterio de selección	28
4.11	Pipeline MLOps y registro de experimentos	28
4.12	Puesta en producción e inferencia	28
4.13	Diseño del datamart y dashboards	30
4.14	Recursos computacionales	30
4.15	Versionado y reproducibilidad	31

5	Resultados y Discusión	32
5.1	Caracterización del conjunto de datos	32
5.2	Resultados del procesamiento y análisis exploratorio	33
5.2.1	Correlaciones	33
5.2.2	Poder predictivo individual	34
5.2.3	Evolución temporal de la clase positiva	35
5.3	Resultados de los modelos	35
5.3.1	LightGBM	35
5.3.2	CNN	36
5.3.3	MLP	37
5.4	Comparación global	37
5.5	Ejecución automatizada y registro	39
5.6	Datamart y dashboards	39
5.7	Discusión	41
6	Conclusiones	42
6.1	Síntesis de los principales hallazgos	42
6.2	Respuesta al objetivo general	42
6.3	Respuesta a los objetivos específicos	43
6.4	Contribuciones	43
6.5	Limitaciones	44
6.6	Trabajo futuro	44
	Bibliography	46
	Appendices	49
A	Repositorios y evidencia complementaria	50
A.1	Capturas adicionales de dashboards	50
A.2	Información mínima para reproducibilidad	50
A.3	Esquema estrella del datamart	52
A.3.1	Tabla de hechos: fact_creditos_mensual	52
A.3.2	Tabla de hechos: fact_predicciones	52

List of Tables

3.1	Síntesis de trabajos relacionados según la información reportada en la tesis.	13
4.1	Componentes del sistema y tecnologías utilizadas.	16
4.2	Fuentes de datos utilizadas en el proceso ETL.	16
4.3	Trazabilidad de datos: transformación desde fuentes hasta conjuntos de entrenamiento. Los conteos exactos deben verificarse en el repositorio. . . .	17
4.4	Diccionario completo de las 21 características extraído del código fuente (<code>queries.py</code> y pipelines de modelos).	18
4.5	Configuración completa documentada de los modelos evaluados, extraída del código fuente.	23
4.6	Distribución real de los conjuntos de datos extraída del código.	25
4.7	Recursos computacionales y versiones de software. Los campos marcados como [PENDIENTE] deben completarse con la información exacta del en- torno de ejecución.	31
5.1	Distribución global de la variable objetivo.	32
5.2	Variables con mayor AUC-ROC individual según el análisis exploratorio. .	34
5.3	Métricas reportadas para LightGBM en horizontes seleccionados.	36
5.4	Comparación de los resultados reportados. Las unidades de resumen no son completamente equivalentes entre modelos.	38
5.5	Resultados reportados para las ejecuciones inicial y automatizada.	39

List of Figures

4.1	Diagrama de Arquitectura Propuesta	15
4.2	Diagrama de flujo de la definición de <code>crisis_flag</code> . Cada condición evalúa un umbral y asigna un peso; si la suma total supera 5, el bloque se etiqueta como crisis.	19
4.3	Representación conceptual de la ventana de entrada y las etiquetas multi-horizonte. Cada bloque-mes genera una secuencia de 6 meses con 21 características, y 18 etiquetas futuras correspondientes a los horizontes de predicción.	20
4.4	Comparación de arquitecturas: LightGBM entrena 18 modelos independientes (uno por horizonte), mientras que CNN y MLP son redes únicas con 18 salidas sigmoidales. Todos comparten la misma entrada de 6×21 valores.	24
4.5	Línea de tiempo de la división temporal de datos. El periodo 2015–2022 se utiliza para entrenamiento y validación, mientras que 2023–2026 se reserva para prueba.	25
4.6	Flujo de entrenamiento, registro y selección implementado en el prototipo. Los datos pasan por preprocesamiento, generación de secuencias y división temporal antes de entrenar los tres modelos.	27
4.7	Flujo de inferencia y actualización analítica. El DAG diario actualiza la vista materializada, carga el modelo y genera predicciones para los 18 horizontes.	29
4.8	Esquema conceptual del datamart analítico. Las dimensiones comparten ambas tablas de hechos: <code>fact_creditos_mensual</code> (datos históricos) y <code>fact_predicciones</code> (salida del modelo).	30

5.1	Matriz de correlaciones de Pearson entre las 21 características numéricas del conjunto analítico. Los valores cercanos a 1,0 (color intenso) indican alta correlación positiva. Se observa multicolinealidad severa entre pares como <code>num_creditos-creditos_cerrados</code> y <code>monto_total-monto_promedio</code> . La multicolinealidad afecta de manera diferente a modelos lineales y no lineales.	33
5.2	AUC-ROC calculada individualmente para cada variable predictora, evaluada contra la etiqueta <code>crisis_flag</code> . El AUC-ROC mide la capacidad de cada variable para distinguir entre bloques con y sin crisis, sin considerar interacciones con otras variables.	34
5.3	Evolución mensual de la proporción de bloques etiquetados como crisis (<code>crisis_flag=1</code>) en el periodo 2015–2026. Se observa un incremento en el periodo 2020–2021 seguido de una estabilización. Esta descripción es únicamente observacional; no se establece relación causal con eventos externos.	35
5.4	Evolución de las métricas de LightGBM a través de los horizontes evaluados.	36
5.5	Importancia de características reportada por LightGBM (“split importance”). El método cuenta la cantidad de veces que cada variable se utiliza para dividir nodos en todos los árboles del ensemble. Las variables judiciales (<code>tasa_judicial</code> , <code>creditos_judiciales</code>) predominan, lo cual puede reflejar tanto poder predictivo real como dependencia con la etiqueta <code>crisis_flag</code> (ver Sección 4.5).	37
5.6	Curva de pérdida (<code>binary_crossentropy</code>) durante el entrenamiento de la CNN. La línea continua representa la pérdida en entrenamiento y la discontinua la pérdida en validación (<code>val_loss</code>). La pérdida se estabiliza en valores elevados ($\sim 12,5$), lo que indica que el modelo no logra aprender una discriminación efectiva entre clases.	38
5.7	Vista del DAG de entrenamiento implementado en Apache Airflow.	39
5.8	Vista del DAG de inferencia implementado en Apache Airflow.	40
5.9	Dashboard para el análisis histórico de la cartera crediticia.	40
A.1	Vista complementaria del dashboard histórico de créditos.	51
A.2	Dashboard de análisis dimensional por riesgo y sector.	51

A.3	Dashboard de evolución temporal de predicciones.	52
A.4	Esquema estrella de la tabla fact_creditos_mensual . Almacena los agregados históricos de créditos por bloque-mes, incluyendo la variable objetivo crisis_flag	53
A.5	Esquema estrella de la tabla fact_predicciones . Almacena las probabilidades y predicciones binarias para los 18 horizontes temporales, generadas por el modelo seleccionado.	53

Chapter 1

Introducción

Este capítulo delimita el problema de investigación, presenta la pregunta, la hipótesis; y, establece los objetivos y las contribuciones del trabajo. El alcance se concentra en la integración técnica de datos, modelos predictivos, operaciones de aprendizaje automático y visualización; no se evalúa una reducción explicada de la mora ni se implementan funciones conversacionales o alertas automáticas.

1.1 Contexto

Las instituciones financieras de la economía social y solidaria administran información de créditos, amortizaciones, cartera y recuperación, que puede utilizarse para describir el comportamiento histórico y estimar escenarios futuros. En muchos entornos, los indicadores de morosidad, cartera, recuperación y cartera vencida; se generan a partir de procesos manuales o repositorios separados. Esta fragmentación dificulta la actualización oportuna de los reportes y limita la incorporación de resultados predictivos en los procesos analíticos.

La inteligencia de negocio permite consolidar fuentes operativas en repositorios orientados al análisis y presentar indicadores mediante dashboards. Por su parte, el aprendizaje automático permite estimar probabilidades de incumplimiento a partir de patrones latentes en los datos. La integración de ambas áreas requiere de mecanismos para automatizar el procesamiento, registrar experimentos, versionar modelos y ejecutar inferencias de forma controlada.

En este trabajo, dicha integración se aborda mediante el uso de productos de bases de datos(PostgreSQL), administradores de flujos de trabajo (Apache Airflow), plataformas del

ciclo de vida de experimentos de modelos de inteligencia artificial (MLflow) y visualización de datos (Apache Superset).

1.2 Motivación

El proyecto surge de una necesidad aplicada: reducir la dependencia de tareas manuales para consolidar información crediticia y disponer de una vista unificada que combine datos históricos y predicciones.

La institución contaba con grandes volúmenes de registros operativos, pero no con un flujo integrado que permitiera preparar los datos, comparar modelos, almacenar predicciones multi-horizonte y visualizarlas en un mismo entorno.

La motivación científica se relaciona con dos aspectos. Primero, la comparación entre modelos basados en árboles y redes neuronales bajo datos tabulares, desbalanceados y con secuencias temporales cortas. Segundo, la evaluación del efecto del horizonte temporal sobre el rendimiento predictivo. La motivación técnica consiste en llevar el modelo seleccionado desde el entorno de experimentación hacia un prototipo reproducible de entrenamiento, inferencia, registro y visualización.

1.3 Planteamiento del problema

El problema se define por la ausencia de integración entre las fuentes crediticias, el entrenamiento de modelos y las herramientas de análisis. Los datos se encuentran en tablas con propósitos operativos distintos; la preparación y actualización de reportes requiere intervención técnica; y las predicciones no están incorporadas de manera sistemática en un datamart que permita analizarlas junto con el histórico de cartera u operaciones de crédito.

Esta situación genera tres brechas. La primera es una brecha de datos, porque no existe un flujo único y documentado para integrar, limpiar y agregar la información. La segunda es una brecha analítica, debido a que los modelos no se comparan dentro de un protocolo multi-horizonte común. La tercera es una brecha operativa, ya que los resultados del modelado no se registran, almacenan y visualizan mediante un proceso automatizado.

1.4 Pregunta de investigación

La investigación aborda la siguiente interrogante:

¿Cómo diseñar e implementar una plataforma de inteligencia de negocio que integre predicción multi-horizonte de riesgo crediticio, un datamart analítico y dashboards interactivos para apoyar la identificación anticipada de escenarios de mora en una institución de la economía social y solidaria?

La pregunta se limita al diseño, la implementación y la evaluación técnica del prototipo. No implica que la plataforma propuesta baje la mora por sí sola ni que reemplace a los especialistas en el área de recuperación.

1.5 Hipótesis

Bajo el conjunto de datos, la división temporal y las configuraciones experimentales utilizadas, se espera que los modelos de Gradient Boosting alcance una capacidad de discriminar superior a las implementaciones de redes neuronales convolucionales y perceptrones multicapa para la predicción multi-horizonte de crisis crediticias. Esta hipótesis se evalúa en el contexto específico del estudio y no pretende establecer una superioridad universal de una familia de modelos.

1.6 Objetivo general

Diseñar e implementar un prototipo de inteligencia de negocio crediticia que automatice el procesamiento de datos, compare modelos de deep learning y gradient boosting para predicción multi-horizonte, y conecte el modelo seleccionado con un datamart y dashboards interactivos.

1.7 Objetivos específicos

1. Analizar los factores asociados con el rendimiento observado de las arquitecturas de inteligencia artificial en el conjunto de datos evaluado.
2. Comparar Gradient Boosting, redes neuronales convolucionales y perceptrones multicapa; mediante las métricas y configuraciones documentadas para el escenario de estudio.
3. Evaluar la variación del rendimiento predictivo conforme aumenta el horizonte temporal.
4. Diseñar e implementar un datamart en esquema estrella y dashboards que integren datos históricos y predicciones.

1.8 Contribuciones

El trabajo aporta una arquitectura de extremo a extremo que conecta ingesta, preparación de datos, entrenamiento, registro de experimentos, inferencia, almacenamiento analítico y visualización.

También presenta una comparación multi-horizonte entre tres familias de modelos y documenta el deterioro de las métricas en horizontes largos.

Finalmente, implementa un datamart con dimensiones de tiempo, riesgo, sector y sucursal, junto con dashboards orientados al análisis de cartera y predicciones.

Estas contribuciones deben interpretarse como resultados de un prototipo evaluado en una institución financiera de la economía social y solidara, por lo que la validación con otras entidades, las pruebas de utilidad con usuarios y la auditoría completa de la variable objetivo permanecen como trabajo posterior.

1.9 Organización del documento

El Capítulo 2 presenta los fundamentos de riesgo crediticio, inteligencia de negocio, predicción multi-horizonte, modelos y métricas. El Capítulo 3 resume la literatura utilizada y delimita las brechas abordadas. El Capítulo 4 describe el diseño de la investigación, el

procesamiento de datos, los modelos, la configuración experimental y los flujos de las operaciones de aprendizaje automático. El Capítulo 5 presenta y discute los resultados del análisis exploratorio, el entrenamiento, la comparación de modelos y la implementación. El Capítulo 6 sintetiza los hallazgos, responde a los objetivos y expone las limitaciones y líneas de trabajo futuro.

Chapter 2

Marco Teórico

Este capítulo presenta los conceptos necesarios para comprender el diseño del sistema y la evaluación experimental. Se priorizan los fundamentos relacionados con el problema y se separan de la descripción operativa de las herramientas, que se desarrolla en la metodología.

2.1 Riesgo crediticio y clasificación binaria

El riesgo crediticio es la probabilidad de incumplir las condiciones acordadas en el pago de créditos. En este estudio, el problema se modela como una clasificación binaria entre "crisis" y "no crisis", aplicando una regla práctica diseñada para este contexto institucional específico, y no una norma regulatoria universal.

En una clasificación binaria, los resultados se organizan en verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos. En riesgo crediticio, los falsos negativos son especialmente relevantes porque representan casos de crisis que el modelo no identifica. Por ello, una exactitud elevada puede resultar engañosa cuando la clase positiva es minoritaria. Lo que es el origen del desbalance.

2.2 Inteligencia de negocio, data warehouse y data-mart

La inteligencia de negocio comprende procesos y tecnologías que transforman datos operativos en información analítica para apoyar decisiones [1]. Un data warehouse integra información de múltiples fuentes y conserva una estructura orientada al análisis. Un data-

mart es un subconjunto enfocado en un dominio específico, como cartera o riesgo crediticio [2].

El esquema estrella organiza una tabla de hechos central y varias tablas de dimensiones. Las tablas de hechos almacenan medidas cuantitativas y claves foráneas; las dimensiones proporcionan contexto temporal, geográfico o categorizaciones propias del negocio. En esta tesis, las dimensiones corresponden a tiempo, riesgo, sector y sucursal, mientras que las tablas de hechos contienen agregados mensuales y predicciones.

2.3 Predicción multi-horizonte

La predicción multi-horizonte estima el estado futuro de una variable para varios plazos. Si x_t representa la información disponible hasta el mes t , el objetivo consiste en estimar una probabilidad $\hat{p}_{t+h}$ para cada horizonte $h \in \{1, \dots, 18\}$. Los horizontes cortos y largos no necesariamente presentan la misma dificultad, porque a mayor distancia en el tiempo aumenta la incertidumbre entre la información actual y el evento futuro.

El proyecto utiliza dos estrategias. CNN (del inglés Convolutional Neural Network) y MLP (del Multilayer Perceptron) producen dieciocho salidas simultáneas, una por horizonte. Y el modelo de Gradient Boosting con la implementación en la biblioteca LightGBM desarrollado por Microsoft que utiliza dieciocho clasificadores independientes. Estas estrategias no son idénticas: la salida conjunta puede compartir representaciones entre horizontes, mientras que los modelos independientes optimizan cada plazo por separado. Esta diferencia debe considerarse al interpretar la comparación.

2.4 Clases desbalanceadas

Un conjunto está desbalanceado cuando una clase contiene muchas más observaciones que la otra. Este escenario puede inducir modelos que predicen casi siempre la clase mayoritaria y, aun así, obtienen una exactitud alta. He y Garcia [3] describen técnicas de reponderación, remuestreo y aprendizaje sensible al costo para enfrentar este problema.

En LightGBM se utilizó el parámetro `scale_pos_weight`. En las redes neuronales se reporta el uso de pesos de muestra, aunque los artefactos disponibles no documentan con

suficiente detalle su cálculo ni su aplicación. La comparación debe considerar que cada modelo puede responder de manera distinta al desbalance.

2.5 Modelos evaluados

2.5.1 LightGBM

LightGBM es una implementación eficiente de árboles de decisión potenciados por gradiente [4]. El método construye secuencialmente árboles que corrigen los errores del conjunto anterior, siguiendo el principio general de gradient boosting [5]. Entre sus ventajas para datos tabulares se encuentran el manejo de relaciones no lineales, interacciones entre variables y escalas heterogéneas. Sin embargo, también puede sobreajustar y amplificar fugas de información si una característica contiene señales derivadas directa o indirectamente de la etiqueta.

2.5.2 Red neuronal convolucional

Las redes neuronales convolucionales aprenden filtros locales y representaciones jerárquicas [6]. En series temporales, una convolución unidimensional puede identificar patrones entre meses consecutivos. La utilidad de este enfoque depende del número de secuencias, la longitud temporal, el tratamiento del desbalance, la regularización y la configuración del entrenamiento.

2.5.3 Perceptrón multicapa

El perceptrón multicapa transforma la entrada mediante capas densas y funciones no lineales. Para una ventana de seis meses y veintiuna características, la entrada contiene $6 \times 21 = 126$ valores antes de cualquier transformación adicional. La arquitectura utilizada produce dieciocho probabilidades mediante activación sigmoide. El desempeño depende, entre otros factores, del escalado, la función de pérdida, el tamaño de lote, la tasa de aprendizaje y la cantidad de muestras.

2.6 Validación temporal y fuga de información

Cuando los datos tienen orden temporal, la división aleatoria puede permitir que información futura influya en el entrenamiento. Una división temporal conserva las observaciones más antiguas para entrenamiento y las más recientes para evaluación. El conjunto de prueba debe permanecer aislado de la selección de hiperparámetros, del early stopping y de la selección del umbral.

La fuga de información ocurre cuando una característica contiene datos que no estarían disponibles en el momento real de la predicción o cuando deriva de la misma regla utilizada para construir la etiqueta. En este estudio, las variables judiciales requieren una auditoría específica porque presentan alta importancia predictiva y podrían estar relacionadas con las condiciones que definen `crisis_flag`.

2.7 Métricas de evaluación

La exactitud, precisión, recall y F1-score se definen como:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.1)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.2)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.3)$$

$$F1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.4)$$

El AUC-ROC (el Área Bajo la Curva y la Característica Operativa del Receptor) resume la capacidad del modelo para ordenar positivos por encima de negativos a través de diferentes umbrales [7]. Un valor cercano a 0,5 indica discriminación equivalente al azar, mientras que un valor mayor no garantiza por sí solo una utilidad operativa. En conjuntos desbalanceados también es recomendable examinar PR-AUC, matrices de confusión, calibración y errores por horizonte. Estas evaluaciones no están disponibles de forma completa

en los resultados originales y se reconocen como limitaciones.

2.8 MLOps y observabilidad

MLOps(del ingles Machine Learning Operations) integra prácticas de desarrollo, datos y operación para gestionar el ciclo de vida de modelos. En este trabajo, Apache Airflow orquesta tareas; MLflow registra parámetros, métricas y artefactos; PostgreSQL almacena datos y predicciones; y Apache Superset consulta el datamart. La presencia de estas herramientas no demuestra por sí sola reproducibilidad o calidad operativa: también se requieren versiones, semillas, validaciones, manejo de fallos, monitoreo de datos y pruebas funcionales.

Chapter 3

Revisión de Literatura

Este capítulo presenta una revisión de literatura orientada a identificar enfoques de predicción de riesgo crediticio, herramientas MLOps e integración analítica. No se denomina revisión sistemática, porque los artefactos disponibles no incluyen un protocolo completo de selección, conteos de estudios ni un diagrama reproducible de filtrado.

3.1 Estrategia de búsqueda

La búsqueda reportada utilizó Google Scholar, arXiv y bases de datos científicas, con términos relacionados con credit risk prediction, LightGBM, credit scoring, MLOps y data warehouse. El periodo priorizado fue 2021–2026. Debido a que no se conservaron los conteos de resultados, los criterios detallados de inclusión y exclusión ni la fecha exacta de cada consulta, el capítulo debe interpretarse como una revisión narrativa de las fuentes seleccionadas.

3.2 Predicción de riesgo crediticio

Lessmann et al. [8] realizaron un benchmark de 41 clasificadores sobre ocho datasets, mostrando que no existe un algoritmo universalmente superior. Moscato et al. [9] apoyan la discusión sobre comparaciones reproducibles. Gunnarsson et al. [10] compararon MLP, deep belief network y ensembles usando pruebas estadísticas, confirmando que el rendimiento depende del dataset y la configuración. Yang et al. [11] estudiaron ensambles e interpretabilidad mediante SHAP. Estos trabajos muestran el uso frecuente de modelos basados

en árboles para datos tabulares y resaltan la importancia del tratamiento del desbalance y de la interpretabilidad.

La literatura revisada no respalda una superioridad universal de los árboles. Gunnarsson et al. [10], por ejemplo, reportaron que un MLP obtuvo el mejor resultado en su conjunto de datos. Esta diferencia evidencia que el rendimiento depende del tamaño de muestra, las variables, la distribución, el protocolo de evaluación y la configuración de cada modelo.

Shreya y Pathak [12] compararon XGBoost, LightGBM y Random Forest con técnicas explicativas. Nayak [13] combinó calibración, restricciones de equidad y gradient boosting. AlMarri et al. [14] compararon clasificadores basados en modelos de lenguaje con LightGBM y analizaron la alineación de sus explicaciones.

3.3 MLOps aplicado al riesgo crediticio

Testi et al. [15] presentaron una taxonomía completa para MLOps. Kreuzberger et al. [16] definieron formalmente MLOps, sus roles, componentes y arquitectura. Sculley et al. [17] documentaron la deuda técnica oculta en sistemas ML, mientras que Breck et al. [18] propusieron una rúbrica de pruebas para preparación en producción. En conjunto, estas fuentes sugieren que la orquestación, el registro de experimentos y el versionado suelen combinarse mediante varias herramientas.

Amed et al. [19] propusieron un flujo adaptativo para riesgo crediticio digital con monitoreo y reentrenamiento. Bussmann et al. [20] presentaron XAI basada en valores de Shapley para gestión del riesgo crediticio, mientras que Bucker et al. [21] diferenciaron transparencia, auditabilidad y explicabilidad en modelos crediticios. Estos enfoques muestran que un pipeline MLOps no debe limitarse a automatizar tareas; también debe incorporar validaciones, seguimiento de cambios y criterios de aprobación.

Estudio	Datos	Modelos	Horizonte	MLOps	Limitación
Lessmann et al. [8]	8 datasets	41 clasificadores	Único	No	Benchmark clásico
Gunnarsson et al. [10]	Varios datasets	MLP, DBN, ensembles	Único	No	MLP obtiene mejor resultado
Nayak [13]	Home Credit	Gradient boosting calibrado	Único	No	No reproduce escenario multi-horizonte
Amed et al. [19]	Préstamos digitales	Modelos adaptativos y MLOps	No especificado	Parcial	Arquitectura y datos distintos
Testi et al. [15]	Herramientas MLOps	Taxonomía MLOps	No aplica	Sí	Documento conceptual

Table 3.1: Síntesis de trabajos relacionados según la información reportada en la tesis.

3.4 Síntesis comparativa

3.5 Brechas y posicionamiento del trabajo

En el conjunto de fuentes revisado se observa una separación entre los estudios de modelado predictivo y los trabajos sobre MLOps. También existe poca evidencia, dentro de la selección disponible, sobre predicción simultánea para dieciocho horizontes y su integración con un datamart institucional. La tesis se posiciona en esa intersección mediante un prototipo que conecta fuentes crediticias, comparación de modelos, registro de experimentos, almacenamiento de predicciones y dashboards.

La contribución no consiste en demostrar que LightGBM es universalmente superior, sino en documentar su comportamiento frente a dos arquitecturas neuronales dentro de un escenario concreto. La brecha pendiente es metodológica: se requiere un protocolo reproducible, comparaciones equivalentes, auditoría de fuga de información, validación externa y evaluación operativa con usuarios.

Chapter 4

Metodología

Este capítulo describe el diseño de la investigación, la arquitectura del prototipo, la preparación de datos, los modelos y el protocolo de evaluación. Los resultados numéricos y su interpretación se presentan exclusivamente en el Capítulo 5.

4.1 Diseño de la investigación

El estudio es aplicado, cuantitativo y experimental en el sentido de que implementa y compara tres modelos sobre una división temporal del mismo conjunto de datos. La unidad analítica corresponde a un bloque-mes, definido por la combinación de mes, nivel de riesgo, sector económico y sucursal. Sobre cada bloque se calculan características agregadas y una etiqueta binaria de crisis.

El flujo metodológico comprende: integración de fuentes, agregación mensual, construcción de características y etiqueta, generación de ventanas temporales, entrenamiento de modelos, evaluación por horizonte, selección del modelo, registro en MLflow, inferencia, almacenamiento de predicciones y visualización.

4.2 Diseño y arquitectura del sistema

La arquitectura integra cinco componentes: PostgreSQL 15 como repositorio operativo y analítico; Apache Airflow 2.10 como orquestador; Python 3.12 y Jupyter para el desarrollo de modelos; MLflow para el registro de experimentos; y Apache Superset para la visualización.

4.3 Síntesis comparativa




Figure 4.1: Diagrama de Arquitectura Propuesta

La implementación incluye un flujo mensual de entrenamiento y un flujo diario de inferencia. Esta frecuencia corresponde a la configuración del prototipo; la tesis no presenta una evaluación de carga que demuestre que dichas periodicidades sean óptimas.

Componente	Tecnología	Ubicación	Función
Base de datos	PostgreSQL 15 [22]	Local/Cloud	Datamart analítico
Orquestación	Apache Airflow 2.10 [23]	Local/Cloud	Flujo de entrenamiento e inferencia
Tracking ML	MLflow [24]	PC local	Registro de experimentos
Dashboards	Apache Superset [25]	Local/Cloud	Visualización BI
Entrenamiento	Python 3.12 + Jupyter	PC Local	Desarrollo de modelos

Table 4.1: Componentes del sistema y tecnologías utilizadas.

4.4 Fuentes de datos y unidad de análisis

El proceso ETL integra tres fuentes institucionales.

Fuente	Magnitud	Contenido
CABECERA_PRESTAMOS	~500.000 filas	Información maestra de créditos, periodo 2015–2026
AMORTIZACAL_PRESTAMOS	~2.000.000 filas	Tabla de amortización mensual
RECUPERACION_PRESTAMOS	~100.000 filas	Información de juicios y recuperaciones

Table 4.2: Fuentes de datos utilizadas en el proceso ETL.

La Tabla 4.2b documenta la trazabilidad de los datos desde las fuentes hasta las muestras de entrenamiento, extraída del análisis del código fuente.

Nota: La restricción clave es que solo los bloques con al menos 24 meses de historial (6 meses de ventana + 18 horizontes) generan secuencias válidas. Esto reduce significativamente el número de muestras disponibles desde los 20.025 bloques-mes iniciales.

4.5 Procesamiento y preparación de datos

El procesamiento se implementa en una vista materializada y en tareas del DAG. Las etapas documentadas son: integración de las tres fuentes, validación de claves, prevención de duplicados mediante upsert, agregación mensual y cálculo de características. El proyecto no aporta un registro completo de filas eliminadas, valores faltantes, criterios de tratamiento de atípicos ni conteos posteriores a cada filtro. Estas decisiones deben versionarse junto con el código para garantizar reproducibilidad.

Etapas	Conteo	Descripción
Filas CABECERA_PRESTAMOS	~500.000	Registros maestros de créditos
Filas AMORTIZACION_PRESTAMOS	~2.000.000	Cuotas de amortización
Filas RECUPERACION_PRESTAMOS	~100.000	Juicios y recuperaciones
Filas tras integración (JOIN)	–	Inner join creditos-amortizacion, left join juicios
Bloques-mes en MV	20.025	GROUP BY mes, riesgo, sector, sucursal
Bloques con historial ≥ 24 meses	–	Requerido: ventana(6) + horizontes(18)
Secuencias generadas	–	<code>X_cnn.shape[0]</code> (variable por ejecución)
Conjunto entrenamiento (49%)	–	70% inicial $\times$ 70% interno
Conjunto validación (21%)	–	30% del train para early stopping
Conjunto prueba (30%)	–	Reservado para evaluación final

Table 4.3: Trazabilidad de datos: transformación desde fuentes hasta conjuntos de entrenamiento. Los conteos exactos deben verificarse en el repositorio.

Las redes neuronales requieren una representación secuencial. Para cada bloque se utiliza una ventana de seis meses con veintiuna características por mes, lo que corresponde a una matriz de 6×21 y a 126 valores antes de cualquier transformación adicional. La referencia original a 128 valores se corrige porque no se documentan dos variables adicionales.

4.6 Ingeniería de características y variable objetivo

El proyecto calcula veintiuna características numéricas derivadas de las tres fuentes. La Tabla 4.3 presenta el diccionario completo extraído del código fuente.

La variable binaria `crisis_flag` se construye mediante ocho condiciones heurísticas con pesos acumulativos. Si la suma de pesos supera el umbral de 5, el bloque se etiqueta como crisis (1); de lo contrario, como no crisis (0). Las ocho condiciones son:

1. **Condición 1** (peso 3): $\text{tasa_judicial} > 5\%$
2. **Condición 2** (peso 1): $\text{tasa_judicial} > 2\%$
3. **Condición 3** (peso 2): $\text{costo_judicial} > 0$ Y $(\text{costo_judicial} / \text{num_creditos}) > \text{monto_promedio} \times 10\%$

Variable	Grupo	Interpretación
num_creditos	Volumen	Número de créditos agregados en el bloque-mes
monto_total	Volumen	Suma del monto crediticio
monto_promedio	Volumen	Monto promedio de los créditos
plazo_promedio	Condición	Plazo promedio de las operaciones (cuotas)
tasa_interes_promedio	Condición	Tasa de interés promedio
saldo_promedio	Riesgo	Saldo capital promedio
total_costo_judicial	Riesgo	Suma de costos judiciales del bloque
total_gestion_cobro	Riesgo	Suma de gestiones de cobro
total_notificaciones	Riesgo	Suma de notificaciones
tot_dias_mora_promedio	Riesgo	Promedio de días en mora
tot_num_moras_promedio	Riesgo	Promedio de número de moras
mora_promedio	Riesgo	Monto promedio de mora
creditos_judiciales	Riesgo	Créditos con indicador judicial = 'S'
creditos_cerrados	Riesgo	Créditos con estado 'C' o 'L'
tasa_judicial	Riesgo	$\frac{\text{creditos_judiciales}}{\text{num_creditos}} \times 100$
tasa_cierre	Riesgo	$\frac{\text{creditos_cerrados}}{\text{num_creditos}} \times 100$
tasa_mora_90	Riesgo	Créditos con >90 días mora / $\frac{\text{creditos_mora_90}}{\text{num_creditos}} \times 100$
creditos_por_cliente	Derivada	$\frac{\text{num_creditos}}{\text{num_clientes_unicos}}$
coef_variacion_montos	Derivada	$\frac{\text{desviación_montos}}{\text{monto_promedio}} \times 100$
tasa_crecimiento_creditos	Derivada	Variación %, $\frac{\Delta \text{ num_creditos}}{\text{num_creditos_previo}}$
tasa_crecimiento_monto	Derivada	Variación %, $\frac{\Delta \text{ monto_total}}{\text{monto_total_previo}}$

Table 4.4: Diccionario completo de las 21 características extraído del código fuente (`queries.py` y pipelines de modelos).

4. **Condición 4** (peso 1): $\text{gestión_cobro} > 0$ Y $(\text{gestión_cobro} / \text{num_creditos}) > \text{monto_promedio} \times 5\%$
5. **Condición 5** (peso 2 o 1): $\text{tasa_cierre} > 30\%$ (peso 2) o $> 20\%$ (peso 1)
6. **Condición 6** (peso 1): $\text{plazo_promedio} > 36$ meses
7. **Condición 7** (peso 1): $\text{plazo_promedio} > 60$ meses

8. Condición 8 (peso 1): $\text{tasa_interes_promedio} > 15\%$

Umbral de decisión: $\sum \text{pesos} \geq 5 \Rightarrow \text{crisis_flag} = 1$. La etiqueta fue validada por juicio experto según el documento original, aunque el procedimiento de validación no está documentado.




Figure 4.2: Diagrama de flujo de la definición de **crisis_flag**. Cada condición evalúa un umbral y asigna un peso; si la suma total supera 5, el bloque se etiqueta como crisis.

Advertencia de fuga de información: Las condiciones 1, 2 y 3 utilizan variables judiciales (*creditos_judiciales*, *tasa_judicial*, *total_costo_judicial*) que también aparecen como características de entrada. Esto crea una dependencia directa entre la etiqueta y algunas variables predictoras, lo que constituye un riesgo de target leakage. Las variables judiciales muestran un poder predictivo elevado (AUC individual $> 0,9$) parcialmente porque contribuyen a la definición de la etiqueta. Se recomienda una ablación excluyendo estas variables para estimar su impacto real.

4.6.1 Generación de horizontes

La salida considera dieciocho horizontes mensuales. Para una ventana que termina en t , la etiqueta del horizonte h corresponde al estado futuro en $t + h$. CNN y MLP generan un vector de dieciocho probabilidades, mientras que LightGBM entrena un clasificador independiente por horizonte.




Figure 4.3: Representación conceptual de la ventana de entrada y las etiquetas multi-horizonte. Cada bloque-mes genera una secuencia de 6 meses con 21 características, y 18 etiquetas futuras correspondientes a los horizontes de predicción.

4.7 Algoritmos seleccionados

Se comparan tres familias para representar enfoques distintos sobre los mismos datos tabulares y temporales.

4.7.1 CNN multi-horizonte

La CNN se implementa como una red unidimensional (Conv1D) con la siguiente arquitectura completa extraída del código fuente:

- Input: ventana de 6×21 (6 meses, 21 características)
- Conv1D(64, kernel_size=3, activation='relu', padding='same')
- BatchNormalization
- Dropout(0.3)
- Conv1D(128, kernel_size=3, activation='relu', padding='same')
- BatchNormalization
- MaxPooling1D(pool_size=2)
- Dropout(0.3)
- Flatten

- `Dense(128, activation='relu')`
- `BatchNormalization`
- `Dropout(0.4)`
- `Dense(64, activation='relu')`
- `Dropout(0.3)`
- 18 salidas `Dense(1, activation='sigmoid')`, una por horizonte

Configuración de entrenamiento:

- Pérdida: `binary_crossentropy`
- Optimizador: Adam (lr por defecto = 0,001)
- Épocas máximas: 100
- Batch size: 32
- Early stopping: paciencia = 10, monitorea `val_loss`, restaura mejores pesos
- Sample weights: SÍ calcula pesos por clase (`total / (2 × n_clase)`)
- Escalado: `MinMaxScaler` (fit solo en train)
- Tratamiento de atípicos: clipping a quantiles 0,01–0,99

4.7.2 MLP multi-horizonte

El MLP se implementa como un perceptrón multicapa con aplanamiento de la secuencia temporal. La arquitectura completa es:

- Input: ventana de 6×21
- `Flatten` (aplana a vector de 126 elementos)
- `Dense(128, activation='relu')`
- `Dropout(0.3)`

- `Dense(64, activation='relu')`
- `Dropout(0.2)`
- 18 salidas `Dense(1, activation='sigmoid')`, una por horizonte

Configuración de entrenamiento:

- Pérdida: `binary_crossentropy`
- Optimizador: Adam ($lr = 0,001$)
- Épocas máximas: 100
- Batch size: 32
- Early stopping: paciencia = 10, monitorea `val_loss`, restaura mejores pesos
- Sample weights: NO utiliza ponderación por clase (a diferencia de CNN)
- Escalado: `MinMaxScaler` (fit solo en train)
- Tratamiento de atípicos: clipping a quantiles 0,01–0,99

Diferencia crítica con CNN: El MLP no implementa `sample_weights`, lo que significa que el desbalance de clases (85% no crisis vs 15% crisis) no se compensa durante el entrenamiento. Esta omisión puede explicar parcialmente por qué el MLP predice todas las observaciones como “no crisis”.

4.7.3 LightGBM multi-horizonte

LightGBM se implementa mediante dieciocho clasificadores independientes, uno por horizonte, siguiendo los principios de gradient boosting [5, 4]. La configuración completa extraída del código es:

- `objective`: `binary`
- `metric`: `binary_logloss`
- `boosting_type`: `gbdt`

Elemento	LightGBM	CNN
Salida	18 modelos binarios independientes	18 salidas sigmoidales
Arquitectura	Árboles potenciados (GBDT)	Conv1D(64,k=3), BN, Do(0,3), Conv1D(128,k=3),
Optimizador	GBDT, lr=0,05	Adam (lr=0,001)
Loss	binary_logloss	binary_crossentropy
Batch size	N/A (usa bagging)	32
Sample weights	scale_pos_weight=5,67	SÍ (total/2×n_clase)
Early stopping	50 rondas	Paciencia 10 (val_loss)
Semilla	42 (fija)	No fijada
Escalado	MinMaxScaler	MinMaxScaler
Clipping	No	SÍ (q01-q99)

Table 4.5: Configuración completa documentada de los modelos evaluados, extraída del código fuente.

- `num_leaves`: 31
- `learning_rate`: 0,05
- `feature_fraction`: 0,8
- `bagging_fraction`: 0,8
- `bagging_freq`: 5
- `seed`: 42 (semilla fija para reproducibilidad)
- `n_jobs`: -1 (usa todos los núcleos)
- Early stopping: 50 rondas sin mejora
- Número máximo de boost rounds: 1000
- Escalado: MinMaxScaler (fit solo en train)

A diferencia de las redes neuronales, LightGBM no requiere representación secuencial; cada horizonte se entrena como un problema de clasificación binaria independiente con las mismas 21 características.




Figure 4.4: Comparación de arquitecturas: LightGBM entrena 18 modelos independientes (uno por horizonte), mientras que CNN y MLP son redes únicas con 18 salidas sigmoiales. Todos comparten la misma entrada de 6×21 valores.

4.8 Hiperparámetros y estrategia de ajuste

Los hiperparámetros de LightGBM se seleccionaron mediante búsqueda manual. No se documentan el espacio explorado, el número de configuraciones ni la regla utilizada para detener la búsqueda. Para CNN y MLP se reportan las arquitecturas principales, pero no un procedimiento equivalente de ajuste. Por ello, la comparación refleja las implementaciones disponibles y no una búsqueda equilibrada de la mejor configuración de cada familia.

El valor `scale_pos_weight=5,67` es consistente con una razón aproximada entre clases

negativa y positiva, pero el cálculo exacto debe realizarse únicamente con el conjunto de entrenamiento de cada horizonte. El proyecto no presenta los conteos por horizonte necesarios para verificarlo.

4.9 Protocolo de entrenamiento, validación y prueba

La división de datos se implementa en tres etapas temporales, verificada en el código fuente:

1. **División temporal inicial** (70% / 30%): Los datos se ordenan cronológicamente y se dividen en entrenamiento (70% más antiguo) y prueba (30% más reciente).
2. **Extracción de validación** (del 70% de train): Del conjunto de entrenamiento se extrae un 30% para validación, resultando en:

Conjunto	Proporción	Uso
Entrenamiento	49% del total	Ajuste de pesos del modelo
Validación	21% del total	Early stopping, monitoreo de <code>val_loss</code>
Prueba	30% del total	Evaluación final (una sola vez)

Table 4.6: Distribución real de los conjuntos de datos extraída del código.

Division Temporal de Datos




Figure 4.5: Línea de tiempo de la división temporal de datos. El periodo 2015–2022 se utiliza para entrenamiento y validación, mientras que 2023–2026 se reserva para prueba.

El conjunto de validación se utiliza exclusivamente para early stopping (monitoreo de `val_loss` con paciencia de 10 épocas) y checkpoint del mejor modelo. El conjunto de prueba se reserva para una única evaluación al final del entrenamiento.

Limitaciones del protocolo: (1) No se reportan los conteos exactos de muestras por conjuntos y por horizonte; (2) la semilla no está fijada para CNN y MLP, lo que dificulta la reproducibilidad; (3) no se realizan repeticiones con múltiples semillas para estimar variabilidad; (4) la búsqueda de hiperparámetros fue manual y no documentada.




Figure 4.6. Flujo de entrenamiento, registro y selección implementado en el prototipo. Los datos pasan por preprocesamiento, generación de secuencias y división temporal antes de entrenar los tres modelos.

4.10 Métricas y criterio de selección

Los modelos se evalúan mediante accuracy, precision, recall, F1-score y AUC-ROC. El criterio principal implementado para seleccionar el modelo es el AUC-ROC promedio de los dieciocho horizontes registrado en MLflow. En la discusión se examina también el recall, debido a que un AUC moderado puede coexistir con una baja detección de crisis bajo el umbral utilizado.

No se reportan intervalos de confianza, pruebas estadísticas, PR-AUC ni calibración. En consecuencia, no se utiliza el término significativo en sentido estadístico y no se atribuyen diferencias observadas a una causa específica.


4.11 Pipeline MLOps y registro de experimentos

El DAG de entrenamiento se programa para el primer día de cada mes a las 03:00. Sus tareas cubren extracción, carga, preparación, entrenamiento, cálculo de métricas y registro de artefactos. La versión original ejecuta los modelos en paralelo; este diseño puede aumentar la utilización de recursos, pero no se dispone de mediciones de CPU, memoria o temperatura que permitan cuantificar el impacto.

MLflow almacena los resultados de las ejecuciones y permite recuperar el modelo seleccionado. La tesis no documenta un esquema de aprobación humana verificable, reglas de promoción, hash de datos, commit del código ni política de reversión. Por ello, el sistema se presenta como prototipo MLOps y no como una operación regulada en producción.

4.12 Puesta en producción e inferencia

El DAG de inferencia se ejecuta diariamente a las 06:00. Actualiza la vista materializada, carga el modelo registrado, genera probabilidades para los dieciocho horizontes y realiza upsert en `fact_predicciones_mensual`.



La tabla de predicciones contiene probabilidades `prob_h01–prob_h18`, predicciones binarias `pred_h01–pred_h18` con umbral 0,5, medidas resumen y metadatos de ejecución. El proyecto no presenta evaluación de calibración ni optimización del umbral, por lo que el valor 0,5 se considera una decisión de implementación y no un umbral de negocio validado.

4.13 Diseño del datamart y dashboards

El datamart adopta un esquema estrella con `dim_tiempo`, `dim_riesgo`, `dim_sector` y `dim_sucursal`. Las tablas `fact_creditos_mensual` y `fact_predicciones_mensual` almacenan los agregados históricos y las predicciones. Apache Superset consulta estas tablas para construir siete dashboards: histórico de créditos, análisis dimensional, KPIs generales, predicciones por sucursal, predicciones por sector, evolución temporal y bloques de mayor riesgo.




Figure 4.8: Esquema conceptual del datamart analítico. Las dimensiones comparten ambas tablas de hechos: `fact_creditos_mensual` (datos históricos) y `fact_predicciones` (salida del modelo).

4.14 Recursos computacionales

La Tabla 4.6 documenta los recursos utilizados para el entrenamiento de los modelos, extraída del código y la documentación del proyecto.

Tiempos de ejecución reportados: LightGBM entrenó los 18 horizontes en aproximadamente 5 minutos; CNN requirió más de 2 horas sin convergencia; MLP requirió un tiempo intermedio. Estos tiempos son aproximados y pueden variar según el hardware.

Recurso	Especificación
Procesador	[PENDIENTE: especificar CPU]
Memoria RAM	[PENDIENTE: especificar GB]
GPU	[PENDIENTE: especificar si aplica]
Sistema operativo	[PENDIENTE: especificar SO]
Python	3.12
TensorFlow/Keras	[PENDIENTE: versión]
LightGBM	[PENDIENTE: versión]
PostgreSQL	15
Apache Airflow	2.10
MLflow	[PENDIENTE: versión]
Apache Superset	[PENDIENTE: versión]

Table 4.7: Recursos computacionales y versiones de software. Los campos marcados como [PENDIENTE] deben completarse con la información exacta del entorno de ejecución.

utilizado.

4.15 Versionado y reproducibilidad

El proyecto utiliza los siguientes mecanismos para garantizar la reproducibilidad:

- **Semilla fija:** LightGBM utiliza `seed=42`; CNN y MLP no fijan semilla.
- **Registro en MLflow:** Cada ejecución registra parámetros, métricas y artefactos.
- **Contenedores Docker:** El proyecto incluye configuración para despliegue en contenedores.
- **Repositorio GitHub:** Código fuente disponible en el repositorio del proyecto.

Limitaciones de reproducibilidad: (1) CNN y MLP no fijan semilla, por lo que los resultados pueden variar entre ejecuciones; (2) no se documentan versiones exactas de todas las librerías; (3) no se adjunta el hardware específico utilizado; (4) no se preservan los datos originales por restricciones de confidencialidad.

Chapter 5

Resultados y Discusión

Este capítulo presenta los resultados disponibles y los interpreta en relación con los objetivos. Las afirmaciones se limitan a la configuración evaluada. No se declara significancia estadística porque no se reportan repeticiones ni pruebas de hipótesis.

5.1 Caracterización del conjunto de datos

El conjunto consolidado contiene 20.025 registros a nivel bloque-mes y veintiuna características numéricas. La distribución reportada para la variable objetivo es de 17.010 registros sin crisis (85%) y 3.015 con crisis (15%). Esta proporción evidencia un desbalance que hace necesario interpretar la exactitud junto con precision, recall y AUC-ROC.

El número de registros agregados no equivale directamente al número de secuencias utilizadas para entrenar los modelos. La versión original menciona 293 muestras de entrenamiento, pero no incluye los conteos necesarios para reproducir la transformación. Por esta razón, la muestra efectiva y la distribución por horizonte deben verificarse antes de considerar definitiva la evaluación.

Clase	Registros	Proporción
No crisis	17.010	85%
Crisis	3.015	15%
Total	20.025	100%

Table 5.1: Distribución global de la variable objetivo.

5.2 Resultados del procesamiento y análisis exploratorio

5.2.1 Correlaciones

La Figura 5.1 muestra correlaciones elevadas entre algunas variables. En particular, el documento original reporta una relación cercana a 1 entre `num_credits` y `credits_cerrados`, así como entre `monto_total` y `monto_promedio`. Estas relaciones pueden generar redundancia, aunque la multicolinealidad no afecta de la misma manera a árboles y redes neuronales. Los valores de VIF mencionados en la versión original no se conservan como evidencia principal porque no se documenta su cálculo completo.




Figure 5.1: Matriz de correlaciones de Pearson entre las 21 características numéricas del conjunto analítico. Los valores cercanos a 1,0 (color intenso) indican alta correlación positiva. Se observa multicolinealidad severa entre pares como `num_credits-credits_cerrados` y `monto_total-monto_promedio`. La multicolinealidad afecta de manera diferente a modelos lineales y no lineales.

Variable	AUC-ROC individual
tasa_judicial	0,926
creditos_judiciales	0,912
saldo_promedio	0,666
monto_total	0,651

Table 5.2: Variables con mayor AUC-ROC individual según el análisis exploratorio.

5.2.2 Poder predictivo individual

El análisis univariado identifica `tasa_judicial` y `creditos_judiciales` como las variables con mayor AUC-ROC individual. Las categorías cualitativas “muy alto” y “medio” se eliminan porque la tesis no define umbrales formales para ellas.




Figure 5.2: AUC-ROC calculada individualmente para cada variable predictora, evaluada contra la etiqueta `crisis_flag`. El AUC-ROC mide la capacidad de cada variable para distinguir entre bloques con y sin crisis, sin considerar interacciones con otras variables.

Estos resultados requieren una lectura prudente. Una alta capacidad discriminativa de variables judiciales puede ser válida si la información está disponible antes del horizonte predicho; también puede revelar fuga de información si esas variables forman parte de la etiqueta o reflejan un evento contemporáneo. Sin las ocho reglas de `crisis_flag`, no es posible distinguir entre ambas explicaciones.

5.2.3 Evolución temporal de la clase positiva

La Figura 5.3 muestra cambios en la proporción de crisis a lo largo del periodo. El documento original describe niveles de 5–7% antes de 2020, un pico de 20–24% durante 2020–2021 y una estabilización cercana al 15% posteriormente. Esta coincidencia temporal no permite atribuir el cambio a la pandemia sin un análisis causal y fuentes externas; por ello, se reporta únicamente como patrón descriptivo.




Figure 5.3: Evolución mensual de la proporción de bloques etiquetados como crisis (`crisis_flag=1`) en el periodo 2015–2026. Se observa un incremento en el periodo 2020–2021 seguido de una estabilización. Esta descripción es únicamente observacional; no se establece relación causal con eventos externos.

5.3 Resultados de los modelos

5.3.1 LightGBM

LightGBM produjo resultados para los dieciocho horizontes. La Tabla 5.3 reproduce los horizontes documentados y el promedio reportado. El AUC-ROC disminuye de 0,874 a un mes a 0,702 a dieciocho meses. El recall se reduce de 0,542 a 0,034, lo que indica que, con el umbral utilizado, el modelo identifica muy pocos casos positivos en el horizonte más largo.

La Figura 5.5 muestra la importancia interna de las características. La predominancia de variables judiciales coincide con el análisis univariado, pero no demuestra causalidad ni

Horizonte	Accuracy	Precision	Recall	AUC-ROC
1 mes	0,937	0,694	0,542	0,874
3 meses	0,942	0,837	0,512	0,869
6 meses	0,927	0,632	0,525	0,838
12 meses	0,906	0,447	0,369	0,765
18 meses	0,897	0,500	0,034	0,702
Promedio	0,917	0,571	0,391	0,800

Table 5.3: Métricas reportadas para LightGBM en horizontes seleccionados.




Figure 5.4: Evolución de las métricas de LightGBM a través de los horizontes evaluados.

garantiza que la señal esté disponible antes de la predicción.

5.3.2 CNN

La implementación de CNN reportó un AUC-ROC de 0,50 y una pérdida que se mantuvo alrededor de 12,5. También se observaron oscilaciones extremas en accuracy, precision y recall, compatibles con predicciones concentradas en una sola clase. Un AUC-ROC de 0,50 indica ausencia de discriminación en la evaluación; por sí solo no demuestra una causa ni permite concluir que todas las CNN sean inadecuadas para este problema.

La magnitud de la pérdida requiere revisar la función utilizada, las dimensiones de etiquetas y salidas, el escalado, los pesos de clase y el tamaño de lote. Estos elementos no están documentados con suficiente detalle para identificar el origen del comportamiento.




Figure 5.5: Importancia de características reportada por LightGBM (“split importance”). El método cuenta la cantidad de veces que cada variable se utiliza para dividir nodos en todos los árboles del ensemble. Las variables judiciales (`tasa_judicial`, `creditos_judiciales`) predominan, lo cual puede reflejar tanto poder predictivo real como dependencia con la etiqueta `crisis_flag` (ver Sección 4.5).

5.3.3 MLP

El MLP reportó una pérdida cercana a 12,47, AUC-ROC de 0,50 y predicciones concentradas en la clase no crisis, con precision y recall iguales a cero para la clase positiva. Este resultado describe el comportamiento de la implementación evaluada, pero no identifica sus causas. Entre los factores plausibles se encuentran el desbalance, el número de secuencias, la configuración de la pérdida, los pesos de muestra, el escalado y el ajuste de hiperparámetros.

5.4 Comparación global

La Tabla 5.4 corrige la inconsistencia de la tabla original: los valores de LightGBM son promedios de horizontes y no corresponden exclusivamente al horizonte de un mes. CNN y MLP se presentan con los valores globales reportados, por lo que la comparación no




Figure 5.6: Curva de pérdida (`binary_crossentropy`) durante el entrenamiento de la CNN. La línea continua representa la pérdida en entrenamiento y la discontinua la pérdida en validación (`val_loss`). La pérdida se estabiliza en valores elevados ($\sim 12,5$), lo que indica que el modelo no logra aprender una discriminación efectiva entre clases.

reemplaza una tabla completa por modelo y horizonte.

Modelo	Accuracy	Precision	Recall	AUC-ROC
LightGBM, promedio	0,917	0,571	0,391	0,800
CNN, resultado global	0,090	0,090	1,000	0,500
MLP, resultado global	0,910	0,000	0,000	0,500

Table 5.4: Comparación de los resultados reportados. Las unidades de resumen no son completamente equivalentes entre modelos.

Bajo el criterio implementado de AUC-ROC promedio, LightGBM fue seleccionado para el flujo de inferencia. La selección es coherente con los resultados disponibles, pero debe considerarse provisional por cuatro razones: no se documentan repeticiones; no existe una prueba estadística; el ajuste de hiperparámetros no fue equivalente; y las salidas de LightGBM y de las redes se estructuran de manera diferente.

5.5 Ejecución automatizada y registro

El pipeline de Airflow produjo una ejecución posterior con accuracy promedio de 0,878 y AUC-ROC promedio de 0,846, mientras que el entrenamiento inicial reportó 0,917 y 0,800, respectivamente.

Métrica	Ejecución inicial	Ejecución automatizada
Accuracy promedio	0,917	0,878
AUC-ROC promedio	0,800	0,846

Table 5.5: Resultados reportados para las ejecuciones inicial y automatizada.

La diferencia no debe atribuirse a Apache Airflow. Airflow orquesta el procedimiento, pero no mejora por sí mismo un modelo. La variación puede relacionarse con cambios en datos, particiones, configuración o aleatoriedad; estos factores no quedaron documentados. El resultado sí evidencia que el flujo automatizado fue capaz de ejecutar el entrenamiento y registrar una salida.




Figure 5.7: Vista del DAG de entrenamiento implementado en Apache Airflow.

5.6 Datamart y dashboards

La implementación almacena las predicciones en `fact_predicciones_mensual` y las expone mediante Apache Superset. Las Figuras 5.9–5.11 muestran ejemplos de los dashboards construidos.




Figure 5.8: Vista del DAG de inferencia implementado en Apache Airflow.




Figure 5.9: Dashboard para el análisis histórico de la cartera crediticia.

Las capturas demuestran que las vistas fueron implementadas, pero no constituyen una validación de utilidad. No se reportan tiempos de actualización, pruebas de integridad, disponibilidad, errores, número de usuarios ni estudios de usabilidad. La afirmación defendible es que el prototipo integra visualmente datos históricos y predicciones; su impacto en decisiones y mora requiere evaluación posterior.

5.7 Discusión

Los resultados disponibles favorecen a LightGBM en el escenario evaluado, lo que es compatible con trabajos que reportan buen desempeño de modelos de boosting en datos tabulares [8, 9]. Sin embargo, la literatura también incluye escenarios en los que un MLP supera a los árboles [10]. Por ello, las diferencias observadas deben atribuirse al conjunto de datos y a las configuraciones utilizadas, no a una propiedad universal de los algoritmos.

El deterioro con el horizonte es visible en AUC-ROC y, con mayor intensidad, en recall. La cifra de recall igual a 0,034 a dieciocho meses significa que la clasificación binaria bajo el umbral 0,5 recupera una fracción muy pequeña de las crisis. Aunque el AUC-ROC se mantiene por encima de 0,70, no es suficiente para calificar estas predicciones como confiables o útiles sin análisis de umbral, calibración y costos de error.

El bajo rendimiento de CNN y MLP puede asociarse con la muestra secuencial reducida, el desbalance, las secuencias de seis meses y la configuración de entrenamiento. No obstante, no se realizaron ablaciones que modifiquen sistemáticamente estos factores. En consecuencia, se consideran explicaciones plausibles y no causas demostradas.

La principal fortaleza del trabajo es la integración de componentes. Su principal debilidad es la trazabilidad experimental. La ausencia de las reglas de etiqueta, de un diccionario completo, de un conjunto de validación documentado y de repeticiones limita la reproducibilidad y la generalización. Estas limitaciones deben resolverse antes de utilizar el sistema como soporte para decisiones de crédito en producción.

Chapter 6

Conclusiones

6.1 Síntesis de los principales hallazgos

La investigación permitió implementar un prototipo que integra procesamiento de datos crediticios, entrenamiento automatizado, registro de experimentos, almacenamiento analítico y visualización. En la evaluación presentada, LightGBM mostró una mayor capacidad discriminativa que las implementaciones de CNN y MLP. El rendimiento de LightGBM disminuyó conforme aumentó el horizonte, y el recall presentó una reducción especialmente relevante en los plazos largos.

El análisis del código fuente permitió documentar completamente las ocho condiciones de `crisis_flag`, las 21 características, la arquitectura exacta de cada modelo y el protocolo de división de datos (49% entrenamiento, 21% validación, 30% prueba).

6.2 Respuesta al objetivo general

El objetivo general se alcanzó en lo relativo al diseño y la integración técnica de los componentes principales. Se implementaron flujos de entrenamiento e inferencia en Apache Airflow, registro en MLflow, almacenamiento en PostgreSQL y dashboards en Apache Superset. El resultado debe presentarse como un prototipo funcional. La evidencia disponible no permite concluir que la plataforma controle la mora, reduzca pérdidas o haya sido validada para apoyar decisiones en un entorno productivo.

6.3 Respuesta a los objetivos específicos

Respecto al primer objetivo, se identificaron factores plausibles asociados con el comportamiento de las redes neuronales: una muestra secuencial reducida (solo bloques con ≥ 24 meses de historial generan secuencias), desbalance de clases sin compensación en MLP, ventanas de seis meses y configuración documentada completa. El MLP no implementa `sample_weights`, lo que puede explicar su tendencia a predecir todas las observaciones como “no crisis”. No se realizaron experimentos de ablación, por lo que estos factores no pueden declararse causas demostradas.

En relación con el segundo objetivo, LightGBM alcanzó el mayor AUC-ROC bajo las configuraciones disponibles. Esta comparación no demuestra que los modelos basados en árboles sean superiores en todos los conjuntos tabulares, porque la búsqueda de hiperparámetros no fue equivalente (LightGBM usa semilla fija y tuning documentado; CNN y MLP no fijan semilla).

Para el tercer objetivo, se observó una disminución del rendimiento de LightGBM con el horizonte. El AUC-ROC pasó de 0,874 a un mes a 0,702 a dieciocho meses, mientras que el recall descendió de 0,542 a 0,034. Por tanto, los horizontes largos deben interpretarse con cautela y no pueden considerarse operativamente útiles sin calibración, selección de umbral y análisis de costos de error.

El cuarto objetivo se cumplió como implementación técnica. El datamart integra dimensiones de tiempo, riesgo, sector y sucursal, y los dashboards permiten consultar información histórica y predicciones. No se evaluó la utilidad con usuarios, la latencia ni el impacto sobre decisiones, por lo que esas dimensiones permanecen pendientes.

6.4 Contribuciones

La primera contribución es una arquitectura de extremo a extremo que enlaza ETL, modelado, MLOps, datamart y visualización. La segunda es la comparación de tres enfoques para dieciocho horizontes, junto con el análisis de la degradación temporal. La tercera es la implementación de un esquema estrella y dashboards que integran predicciones y agregados históricos.

Las contribuciones se circunscriben al prototipo y a la institución analizada. No se

afirma superioridad universal de LightGBM ni se generalizan los resultados a otras entidades financieras.

6.5 Limitaciones

El estudio presenta limitaciones metodológicas y de generalización. La definición de `crisis_flag` quedó documentada mediante ocho condiciones con pesos acumulativos (umbral ≥ 5), pero existe un riesgo confirmado de target leakage: las variables judiciales (`tasa_judicial`, `creditos_judiciales`, `total_costo_judicial`) se utilizan tanto para definir la etiqueta como como características de entrada. Esta dependencia puede inflar artificialmente el poder predictivo de esas variables y del modelo.

La división de datos sigue un protocolo temporal con tres conjuntos (49% entrenamiento, 21% validación, 30% prueba), y el early stopping utiliza exclusivamente el conjunto de validación. Sin embargo, no se reportan conteos por horizonte, no se fijan semillas para CNN y MLP, y no se realizan repeticiones para estimar variabilidad.

No se reportan PR-AUC, calibración, curvas por umbral ni análisis detallado de falsos negativos. La comparación entre modelos utiliza presupuestos de ajuste no equivalentes. Además, el estudio se realizó en una sola institución y no incluye validación externa.

Desde la perspectiva operativa, las capturas demuestran la implementación de los flujos y dashboards, pero no se presentan pruebas de rendimiento, disponibilidad, recuperación ante fallos, integridad de datos o usabilidad. Estas limitaciones impiden considerar el prototipo como un sistema productivo validado.

6.6 Trabajo futuro

El trabajo futuro debe priorizar la reproducibilidad. Se requiere registrar conteos por etapa y horizonte, fijar semillas para todos los modelos, realizar repeticiones con múltiples semillas y versionar datos, código y entornos.

Es crítica una ablación de leakage: repetir la evaluación excluyendo las variables judiciales (`tasa_judicial`, `creditos_judiciales`, `total_costo_judicial`) para estimar cuánto del poder predictivo se debe a la dependencia con la etiqueta.

La comparación de modelos debe equilibrar los presupuestos de ajuste, utilizar múltiples semillas, reportar intervalos de confianza, incluir PR-AUC, calibración y selección de umbrales basada en costos. Para las redes neuronales, se recomienda añadir `sample_weights` al MLP y explorar arquitecturas con mayor capacidad.

Finalmente, el prototipo debe evaluarse con datos de otras instituciones y mediante pruebas funcionales y de usabilidad. Solo después de estas validaciones sería posible estimar su contribución a procesos de decisión, alertas o gestión de cartera.

Bibliography

- [1] G. H. N. Laursen and J. Thorlund, *Business Analytics for Managers: Taking Business Intelligence Beyond Reporting*, 2nd ed. Wiley, 2017.
- [2] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Wiley, 2013.
- [3] H. He and E. A. Garcia, “Learning from imbalanced data,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
- [4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “Lightgbm: A highly efficient gradient boosting decision tree,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [5] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [6] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [7] T. Fawcett, “An introduction to roc analysis,” *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.
- [8] S. Lessmann, B. Baesens, H.-V. Seow, and L. C. Thomas, “Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research,” *European Journal of Operational Research*, vol. 247, no. 1, pp. 124–136, 2015.
- [9] V. Moscato, A. Picariello, and G. Sperlí, “A benchmark of machine learning approaches for credit score prediction,” *Expert Systems with Applications*, vol. 165, p. 113986, 2021.

- [10] B. R. Gunnarsson, S. vanden Broucke, B. Baesens, M. Óskarsdóttir, and W. Lemahieu, “Deep learning for credit scoring: Do or don’t?” *European Journal of Operational Research*, vol. 295, no. 1, pp. 292–305, 2021.
- [11] S. Yang, Z. Huang, W. Xiao, and X. Shen, “Interpretable credit default prediction with ensemble learning and shap,” *arXiv preprint arXiv:2505.20815*, 2025. [Online]. Available: <https://arxiv.org/abs/2505.20815>
- [12] Shreya and H. Pathak, “Explainable artificial intelligence credit risk assessment using machine learning,” *arXiv preprint arXiv:2506.19383*, 2025. [Online]. Available: <https://arxiv.org/abs/2506.19383>
- [13] S. Nayak, “Calibrated credit intelligence: Shift-robust and fair risk scoring with bayesian uncertainty and gradient boosting,” *arXiv preprint arXiv:2603.06733*, 2026. [Online]. Available: <https://arxiv.org/abs/2603.06733>
- [14] S. AlMarri, K. Juhasz, M. Ravaut, G. Marti, H. Al Ahbabi, and I. Elfadel, “Interpreting llms as credit risk classifiers: Do their feature explanations align with classical ml?” *arXiv preprint arXiv:2510.25701*, 2025. [Online]. Available: <https://arxiv.org/abs/2510.25701>
- [15] M. Testi, M. Ballabio, E. Frontoni, G. Iannello, S. Moccia, P. Soda, and G. Vessio, “Mlops: A taxonomy and a methodology,” *IEEE Access*, vol. 10, pp. 63 606–63 618, 2022.
- [16] D. Kreuzberger, N. Kühn, and S. Hirschl, “Machine learning operations (mlops): Overview, definition, and architecture,” *IEEE Access*, vol. 11, pp. 31 866–31 879, 2023.
- [17] D. Sculley *et al.*, “Hidden technical debt in machine learning systems,” in *Advances in Neural Information Processing Systems*, vol. 28, 2015.
- [18] E. Breck, S. Cai, E. Nielsen, M. Salib, and D. Sculley, “The ml test score: A rubric for ml production readiness and technical debt reduction,” in *IEEE International Conference on Big Data*, 2017, pp. 1123–1132.

- [19] S. Amed, C. Yu Hang, and S. Banerjee, “Pdx – adaptive credit risk forecasting model in digital lending using machine learning operations,” *arXiv preprint arXiv:2512.22305*, 2025. [Online]. Available: <https://arxiv.org/abs/2512.22305>
- [20] N. Bussmann, P. Giudici, D. Marinelli, and J. Papenbrock, “Explainable machine learning in credit risk management,” *Computational Economics*, vol. 57, pp. 203–216, 2021.
- [21] M. Bücker, G. Szepannek, A. Gosiewska, and P. Biecek, “Transparency, auditability, and explainability of machine learning models in credit scoring,” *Journal of the Operational Research Society*, vol. 73, no. 1, pp. 70–90, 2022.
- [22] The PostgreSQL Global Development Group, “Postgresql 15 documentation,” <https://www.postgresql.org/docs/15/>, 2024, accessed: 2024-01-15.
- [23] Apache Software Foundation, “Apache airflow documentation,” <https://airflow.apache.org/docs/>, 2024, accessed: 2024-01-15.
- [24] MLflow Contributors, “Mlflow documentation,” <https://mlflow.org/docs/latest/>, 2024, accessed: 2024-01-15.
- [25] Apache Software Foundation, “Apache superset documentation,” <https://superset.apache.org/docs/>, 2024, accessed: 2024-01-15.

Appendices

Appendix A

Repositorios y evidencia complementaria

Los recursos técnicos proporcionados se encuentran en los siguientes repositorios:

Contenedores Docker: <https://github.com/YahayUniversidad/IADegreeThesis/tree/main/Contenedores>

Desarrollo de la solución: <https://github.com/YahayUniversidad/IADegreeThesis/tree/main/Desarrollo>

Documentación relacionada: <https://github.com/YahayUniversidad/IADegreeThesis/tree/main/DocumentosBase>

Para una reproducción verificable, la versión final debe asociar los enlaces con un commit o etiqueta estable e indicar qué script genera cada tabla, figura y modelo.

A.1 Capturas adicionales de dashboards

A.2 Información mínima para reproducibilidad

La documentación final del repositorio debería incluir: definición de las ocho reglas de `crisis_flag`; diccionario de las veintiuna características; conteos de registros y secuencias por etapa; particiones temporales; configuración completa de CNN, MLP y LightGBM; semillas; versiones de librerías; especificaciones de hardware; hashes o versiones de datos; métricas por horizonte; y procedimientos para ejecutar los DAG y reconstruir los dashboards.




Figure A.1: Vista complementaria del dashboard histórico de créditos.




Figure A.2: Dashboard de análisis dimensional por riesgo y sector.




Figure A.3: Dashboard de evolución temporal de predicciones.

A.3 Esquema estrella del datamart

El datamart analítico utiliza un esquema estrella con dos tablas de hechos que comparten las mismas dimensiones. A continuación se presentan los diagramas de cada tabla de hechos.

A.3.1 Tabla de hechos: fact_creditos_mensual

A.3.2 Tabla de hechos: fact_predicciones




Figure A.4: Esquema estrella de la tabla **fact_creditos_mensual**. Almacena los agregados históricos de créditos por bloque-mes, incluyendo la variable objetivo **crisis_flag**.




Figure A.5: Esquema estrella de la tabla **fact_predicciones**. Almacena las probabilidades y predicciones binarias para los 18 horizontes temporales, generadas por el modelo seleccionado.